学校代码：11078　　学　　号：2112216064

广州大学
硕士学位论文

题目：基于机理模型及机器学习的城市污水处理厂运行模拟优化研究

学生类型：☑学术学位硕士
□专业学位硕士

学位论文作者：李坦

导师姓名及职称：余华荣 副教授

学　　院：土木与交通工程学院

学科专业：市政工程

论文提交日期：二〇二五 年 六 月

中国知网 https://www.cnki.net

学校代码： 11078　　学　　号： 2112216064

广州大学硕士学位论文

基于机理模型及机器学习的城市污水处理厂运行模拟优化研究

Operational simulation and optimization of urban wastewater treatment plants based on mechanistic model and machine learning

李坦

学　科　专　业：市政工程

研　究　方　向：污水处理数学模拟

论文答辩日期：2025.5.23

指导教师（签名）：

答辩委员会主席（签名）：

答辩委员会委员（签名）：

中国知网　https://www.cnki.net

摘要

在“双碳”战略目标下，污水处理厂的稳定运行与节能降耗对环境保护和公众健康至关重要。特别是由于污水中氨氮含量过高引起的水体富营养化一直是最严重的问题之一。有效预测出水水质，尤其是总氮（TN）浓度，对于确保污水处理厂的持续稳定运行以及环境保护具有重要意义。尽管传统机理模型（如活性污泥模型，ASMs）已被广泛应用于污水处理过程的建模，但其复杂性和参数不确定性限制了预测精度。近年来，机器学习模型为污水处理厂的出水水质预测提供新的方法。

在本研究中，以污水处理厂出水 TN 为主要控制指标，采用两种不同的方法构建污水处理厂模型：基于 ASMs 的机理模型和随机森林、XGBoost、LightGBM 等六种经典机器学习模型。以决定系数（R^2）、均方误差（MSE）及相对误差（RE）为模型评估指标全面评估了这两类模型预测该污水处理厂出水 TN 浓度的预测性能。结果表明，机理模型能够较好地捕捉出水 TN 浓度的整体趋势，但预测准确性较差。相比之下，所采用的 6 种机器学习模型均明显优于机理模型，其中随机森林的表现最佳（测试集 R^2 为 0.79，MRE 为 7.5%）。

然而，机器学习模型因其“黑箱”性质，缺乏明确的物理化学机制，为了进一步理解机器学习模型的决策机制，本研究引入 SHAP（Shapley Additive exPlanations）算法，从全局和局部层面分析输入变量对污水处理厂出水 TN 预测的影响。机理模型的敏感性分析显示，与硝化和反硝化过程相关的动力学参数和化学计量学参数是影响污水处理厂出水 TN 的关键参数，表明硝化和反硝化过程是影响出水 TN 的主要过程。而 SHAP 分析表明回流污泥和 MLSS 是机器学习模型中预测污水处理厂出水 TN 的关键特征，这一结果与机理模型的分析一致，进一步增强了机器学习模型的可解释性。

为进一步指导污水处理厂运行优化，在一组给定的进出水条件和运行数据下，选取好氧区溶解氧、内回流比和污泥回流量这三个关键工艺参数，采用响应面法耦合机理模型对污水处理厂出水 TN 进行优化。响应面分析结果表明，构建的响应面二次多项式模型拟合度较高（R^2=0.9445，F 值=223.59，P 值<0.0001），可准确描述出水 TN 浓度的变化趋势。且在最佳运行参数条件下（溶解氧=1.125 mg/L、内回流比=255%、外回流比=65%），出水 TN 去除率可达到 89.14%，TN 浓度同比降低 10.49%。此外，

中国知网 https://www.cnki.net

本文进一步构建了 TD3 强化学习算法耦合随机森林模型的多目标优化控制架构，旨在保证出水 TN 浓度达标的前提下，兼顾降低出水 TN 浓度与降低能耗。多目标优化结果表明，采用最优控制策略后，出水 TN 浓度波动幅度明显减小，曝气能耗和泵送能耗同比降低 33.12%，运行成本指数同比降低 25.16%。

综上分析，相比于机理模型，机器学习在污水处理厂出水 TN 预测中具有显著优势，且机器学习与 SHAP 分析相结合还可以有效识别影响模型预测过程的关键特征、减小机器学习“黑箱”性质的限制，为后续污水处理厂的智能控制提供了模型基础。同时 TD3 强化学习算法耦合随机森林模型进行多目标优化控制能够在保证出水 TN 浓度达标的前提下，尽可能降低污水处理厂能耗。

关键词：活性污泥模型；机理模型；机器学习；SHAP 可解释性分析；脱氮效果；多目标优化；节能降耗

中国知网 https://www.cnki.net

Abstract

Under the “dual carbon” strategic goal, the stable operation and energy-saving optimization of wastewater treatment plants (WWTPs) are crucial for environmental protection and public health. Excessive ammonia nitrogen (NH_4^+-N) in wastewater has long been a major cause of water eutrophication. Accurately predicting effluent water quality, particularly total nitrogen (TN) concentration, is essential for ensuring the continuous and stable operation of WWTPs and protecting the environment. Although traditional mechanistic models, such as Activated Sludge Models (ASMs), have been widely applied in wastewater treatment process modeling, their complexity and parameter uncertainty limit prediction accuracy. In recent years, machine learning (ML) models have provided new approaches for predicting WWTP effluent quality.

In this study, WWTP effluent TN concentration was selected as the primary control indicator, and two different modeling approaches were employed: a mechanistic model based on ASMs and six classical ML models, including Random Forest, XGBoost, and LightGBM. Model performance in predicting WWTP effluent TN concentration was comprehensively evaluated using coefficient of determination (R^2), mean squared error (MSE), and relative error (RE) as evaluation metrics. The results showed that the mechanistic model could effectively capture the overall trend of effluent TN concentration but exhibited lower prediction accuracy. In contrast, all six ML models significantly outperformed the mechanistic model, with Random Forest achieving the best performance ($R^2 = 0.79$, MRE = 7.5% on the test set).

However, due to the “black-box” nature of ML models and their lack of explicit physical and chemical mechanisms, this study introduced the SHAP (Shapley Additive Explanations) algorithm to analyze the influence of input variables on WWTP effluent TN prediction at both global and local levels. Sensitivity analysis of the mechanistic model indicated that kinetic and stoichiometric parameters related to nitrification and denitrification were the key factors affecting effluent TN, highlighting the importance of these processes in TN removal. Meanwhile, SHAP analysis revealed that return sludge flow

中国知网 https://www.cnki.net

and MLSS were the most influential features in ML models for predicting WWTP effluent TN, aligning with the findings of the mechanistic model. This consistency enhances the interpretability of ML models.

To further guide WWTP operational optimization, given a set of influent-effluent conditions and operational data, three key process parameters—dissolved oxygen (DO) in the aerobic zone, internal recirculation ratio, and sludge return flow—were selected. A response surface methodology (RSM) coupled with the mechanistic model was applied to optimize WWTP effluent TN. The response surface analysis results demonstrated a high goodness-of-fit for the constructed quadratic polynomial model ($R^2 = 0.9445$, $F = 223.59$, $P < 0.0001$), accurately describing the variation trend of effluent TN concentration. Under optimal operating conditions (DO = 1.125 mg/L, internal recirculation ratio = 255 mg/L, external recirculation ratio = 65%), the TN removal rate reached 89.14%, with a 10.49% reduction in TN concentration compared to baseline conditions. Furthermore, a multi-objective optimization control framework integrating the TD3 reinforcement learning algorithm with the Random Forest model was developed to ensure TN compliance while minimizing TN concentration and energy consumption. The optimization results indicated that the optimal control strategy significantly reduced TN concentration fluctuations, with aeration and pumping energy consumption decreasing by 33.12%, and the operating cost index decreasing by 25.16%.

In summary, compared to mechanistic model, ML models demonstrates significant advantages in predicting effluent TN in WWTPs. Moreover, integrating ML with SHAP analysis enables effective identification of key influencing features, mitigating the limitations of ML's "black-box" nature and providing a robust modeling foundation for the intelligent control of WWTPs. Additionally, coupling the TD3 reninforcement learning algorithm with Random Forest model enables multi-objective optimization, ensuring compliance with effluent TN standards while minimizing the energy consumption of WWTPs.

中国知网 https://www.cnki.net

Keywords: Activated sludge model; Mechanistic model; Machine learning; SHAP interpretability analysis; Nitrogen removal; Muti-objective optimization; Energy conservation

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景.....1
1.2 污水处理数学模拟发展概况.....3
1.2.1 机理模型.....3
1.2.2 机器学习模型.....5
1.3 污水处理系统多目标优化的发展现状.....10
1.4 课题研究意义及主体内容.....11
1.4.1 课题研究目标及意义.....11
1.4.2 课题研究思路及内容.....11
1.4.3 技术路线.....12
第二章 研究方法及污水厂数据分析.....13
2.1 数据分析及模型评估方法.....13
2.1.1 数据分析方法.....13
2.1.2 模型评估方法.....14
2.2 目标污水厂主体工艺.....15
2.3 目标污水厂运行数据分析.....16
2.4 机器学习算法原理.....22
第三章 基于机理模型的污水处理系统模拟.....27
3.1 引言.....27
3.2 机理模型的构建.....28
3.2.1 进水水质参数的确定.....28
3.2.2 全流程模型的建立.....29
3.3 机理模型的校准及验证.....30
3.3.1 敏感性分析.....30
3.3.2 模型稳态模拟校准及验证.....31
3.3.3 模型动态模拟校准及验证.....33
3.4 本章小结.....36
第四章 基于机器学习的污水处理系统模拟.....37
4.1 引言.....37
4.2 数据预处理.....38
4.2.1 数据清洗.....38
4.2.2 数据集划分.....40
4.3 机器学习模型搭建.....40
4.3.1 模型训练及超参数调优.....40

中国知网 https://www.cnki.net

4.3.2 模型预测结果分析.....41
4.4 机器学习模型可解释性分析.....48
4.4.1 SHAP 算法原理.....49
4.4.2 关键特征解析.....50
4.5 本章小结.....53
第五章 污水处理厂出水总氮影响因素分析及优化控制.....55
5.1 引言.....55
5.2 响应面法耦合 ASM 模型优化脱氮效能.....55
5.2.1 模型参数设定及因素水平设计.....55
5.2.2 响应面模型拟合及其显著性分析.....56
5.2.3 响应面优化结果分析.....57
5.3 基于强化学习的污水处理系统多目标优化分析.....59
5.3.1 双延迟深度确定性策略梯度算法(TD3).....59
5.3.2 污水处理系统的多目标优化架构建立.....60
5.3.3 多目标优化结果分析.....62
5.4 本章小结.....65
第六章 结论与展望.....67
6.1 结论.....67
6.2 展望.....68
参考文献.....69

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景

水资源是人类社会赖以生存和发展的重要自然资源，作为支撑生态系统良性循环和经济社会可持续发展的自然资源，水资源在我国环境系统中具有不可替代的地位。据《2023 年中国生态环境状况公报》，图 1-1 显示了 2023 年全国地表水水质类别比例。由图 1-1 可知，在 2023 年全国监测的 3632 个地表水国控断面中，Ⅰ类占 9%，Ⅱ类占 50.1%，Ⅲ类占 30.3%，Ⅳ类占 8.4%，Ⅴ类占 1.5%，劣Ⅴ类占 0.7%。与 2022 年相比，优良（Ⅰ类~Ⅲ类）水质断面上升 1.5%，劣Ⅴ类水质断面与 2022 年持平[1]。通过统计数据分析，可以看出我国水环境质量有所改善，优良水质比例有所提升，但劣Ⅴ类断面比例仍未明显下降，水资源环境保护仍是一项长期性重要工作。

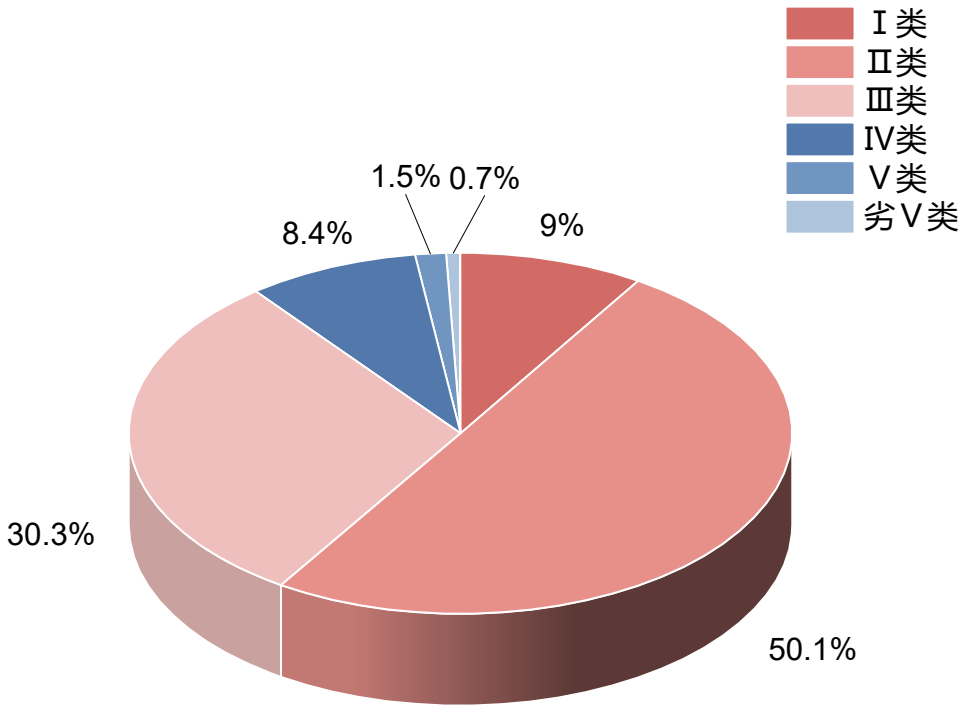


图 1-1 2023 年全国地表水水质类别比例

Figure1-1 Proportion of National Surface Water Quality Categories in 2016

地表水质的持续改善，与我国污水处理基础设施的快速完善密不可分。城市污水处理是现代化城市环境建设中至关重要的一环，它不仅涉及到水资源的回收与再利用，也直接关系到生态环境的保护和人类健康的保障。在过去的几十年里，环境水体污染、

中国知网 https://www.cnki.net

水资源短缺已成为全球面临的严峻问题。随着我国城市化进程的不断加快，污水排放量急剧增加，如何实现高效、低成本的污水处理已成为了全球面临的共同挑战，有效处理日益增加的城市废水对环境恢复和可持续发展具有深远意义[2,3]。因此，我国建设了大量的废水处理设施以处理城市废水。根据近 10 年中华人民共和国住房和城乡建设部发布的城乡建设统计年鉴的相关数据，统计了包括城市、县城、建制镇、乡、镇乡级特殊区域在内的全国污水处理厂数量，其结果见图 1-2。

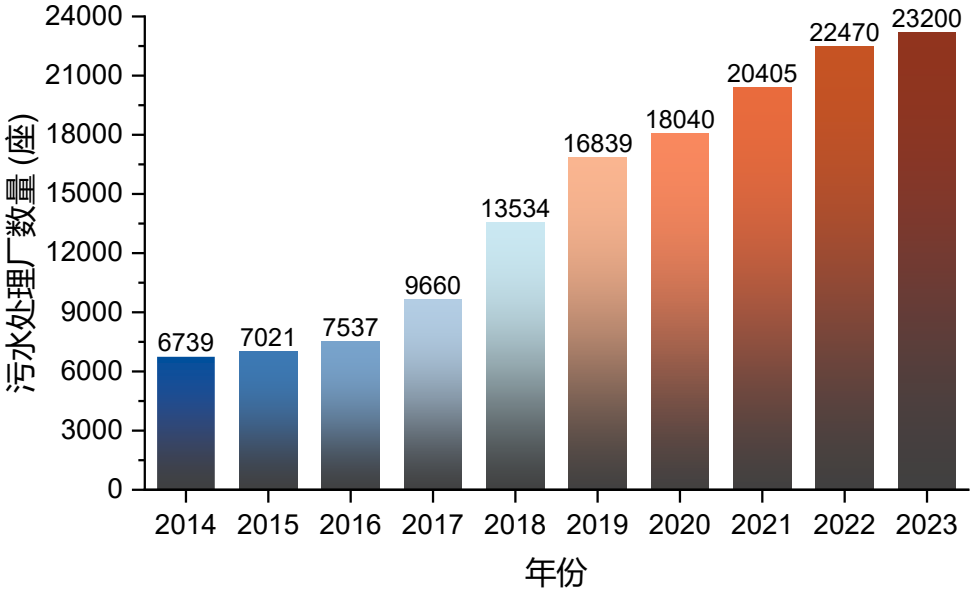


图 1-2 全国各年污水处理厂数量

Figure1-2 Number of sewage treatment plants in China in each year

由图 1-2 可知，我国市政污水处理厂数量从 2014 年的 6739 座增长至 2023 年的 23200 座，呈现快速增长态势。随着污水处理厂数量激增，年污水处理量也逐年递增，表明我国污水处理能力需要进一步提高。当前，在我国污水处理领域，活性污泥法（Activated Sludge Process, ASP）占据主流地位，该方法以活性污泥为主体，通过活性污泥中的好氧微生物与污水中的有机或无机固体物质混凝交织形成的絮状体，吸附分解水中有机物，然后把污水中的有机物转变为无污染的二氧化碳和水的处理方法[4]。活性污泥法适应性强、可控性高、建设与维护成本低，但同时具有易受进水冲击负荷、污泥膨胀风险较高、曝气能耗占总能耗比例较高但氧利用率普遍较低等缺点[5]。

尽管活性污泥法已经在大多数城市污水处理厂中得到广泛应用并取得良好的处理污水处理效果[6]，但在面临日益复杂的水质特征和越来越严格的排放标准时，传统依

中国知网 https://www.cnki.net

赖经验或简单的控制系统已经难以满足当前污水处理系统高效能和低运行成本的精细化管控需求[7]。

污水处理厂数学模拟在城市生活污水处理中具有重要意义，污水处理厂的数学建模已被广泛认为是预测出水总氮的有效工具[8-10]。污水处理厂是一个十分复杂的非线性系统，其进水流量、污染物负荷、化学环境等均处于高度波动状态。由于这些复杂性和不确定性，污水处理厂数学模拟具有挑战性[11,12]。当前污水处理系统的模拟技术主要有两个路径：机理模型和机器学习模型。机理模型如活性污泥模型（ASMs）依赖精确的生化反应方程，模拟活性污泥中微生物过程，从而对污水处理厂出水水质进行预测[13]。机器学习模型则是根据足够的历史数据，通过挖掘数据中的非线性映射关系，从而为污水处理实时调控提供决策支持。

1.2 污水处理数学模拟发展概况

1.2.1 机理模型

自 20 世纪 70 年代起，计算机技术的发展为复杂数学模型的构建于运算提供了可能。与此同时，随着对污水处理过程认识的深入，污水处理行业对精确描述活性污泥法中生物化学过程的需求愈发迫切，人们开始尝试建立数学模型来描述活性污泥法中的生物化学过程。国际水质协会（IWA）在 1987 年推出了活性污泥 1 号模型（ASM1），它奠定了现代活性污泥模型的基础。此后，IWA 又陆续推出了 ASM2、ASM2d 和 ASM3 等模型，逐步从经验驱动转向机理驱动，不断完善和扩展了对污水处理过程的描述，并在污水处理厂中广泛应用[14]。活性污泥系列模型的发展概况如表 1-1 所示。ASM1 首次以矩阵方程式形式系统描述了有机物降解与氮素转化过程。模型共包含 13 个组分变量和 8 个生化反应过程，通过 Monod 动力学方程描述异养菌和自养菌的代谢速率，通过严谨的数学公式成功描述了有机物的去除以及硝化和反硝化过程[15]。但 ASM1 未涉及生物除磷及复杂流态的影响，导致其在脱氮除磷工艺中的应用受限。国际水质协会于 1995 年推出的 ASM2 在 ASM1 的基础上实现了重大突破，成功引入了生物除磷过程的详细描述。ASM2 新增聚磷菌（PAOs）等微生物种群，全面地描述了厌氧释磷、好氧吸磷等关键反应步骤[16]。模型扩展至 19 个组分，通过引入糖原与聚羟基烷酸酯等中间代谢产物，精确描述 PAOs 在交替缺氧/好氧条

中国知网 https://www.cnki.net

件下的代谢特性，使得其在具有生物除磷功能的污水处理工艺模拟中得以广泛应用。ASM2d 作为 ASM2 的优化改进版本，进一步考虑反硝化除磷的动力学描述，精确地描述在缺氧条件下聚磷菌利用硝酸盐作为电子受体进行磷吸收的现象[17]。然而，ASM2 和 ASM2d 对化学沉淀除磷的模拟仍依赖经验参数，且未考虑硫转化等新兴过程。国际水质协会于 2000 年推出的 ASM3 对 ASM1 中的一些关键过程进行了重新诠释和优化，采用内源呼吸理论替代传统衰减系数，将微生物死亡后的物质释放细分为可缓慢降解有机物于惰性组分。ASM3 新增溶解氧对异养菌代谢的抑制效应，并引入动态温度修正因子，显著提升了低温硝化过程的模拟精度[18]。

表 1-1 活性污泥系列模型的发展

Table1-1 Development of activated sludge series models

模型名称	建立时间	主要特点	文献
ASM1	1987 年	首次以矩阵方程式形式系统描述了有机物降解与氮素转化过程。模型共包含 13 个组分变量和 8 个生化反应过程。	[15]
ASM2	1995 年	在 ASM1 的基础上引入生物除磷过程，模型扩展至 19 个组分，全面描述了厌氧释磷、好氧吸磷等关键反映步骤。	[16]
ASM2d	1999 年	是 ASM2 的改进版本，模型包括 20 个组分变量和 21 个生化反应过程，进一步考虑了聚磷菌反硝化除磷的过程。	[17]
ASM3	1999 年	对 ASM1 进行优化，模型包含 13 个组分变量和 12 个生化反应过程；采用内源呼吸理论描述微生物的衰减过程；	[18]

从基本原理来看，活性污泥模型主要基于微生物动力学、物质平衡和反应动力学构建。微生物动力学依据 Monod 方程等经典理论，详细描述微生物的生长、死亡等过程，深入探究微生物对底物的利用速率与底物浓度、微生物浓度等关键因素之间的内在联系。物质平衡则严格遵循质量守恒定律，对污水中的有机物、氮、磷等各类物质进行全面且精准的平衡计算，清晰地呈现出它们在污水处理过程中的转化路径和去除机制。反应动力学则确定各种生物化学反应的速率常数和反应机制，涵盖有机物的

中国知网 https://www.cnki.net

降解反应、硝化反应、反硝化反应以及磷的吸收和释放反应等，为准确模拟污水处理过程提供了坚实的理论支撑。

近年来，水处理领域基于 ASMs 进行了多次废水处理过程的模拟研究，并取得了令人满意的结果[19-22]。例如，Insel 等人将厌氧消化试验和废水处理厂的全厂范围模拟相结合，量化了硝化与厌氧水解速率的实际偏差，为工业废水占比较高的污水处理厂提供了校准策略[23]。Abulimiti 等人开发了一个基于 ASM 的污水处理厂模型来量化污水处理厂的温室气体排放，通过模拟精确控制溶解氧浓度以平衡污水处理厂节能降耗和减少 N_2O 的产生[24]。Layer M 等人开发了一个基于 ASM 的数学模型来分析好氧颗粒污泥系统中的同步硝化-反硝化过程，通过数学模拟优化曝气策略，成功在不影响硝化过程的前提下将 TN 去除率提高到 40%~79%[25]。Wang 等人通过结合 ASM2d、Pareto 分析和响应面法，对 A^2/O 工艺进行模拟，表明 ASM2d 模型可以很好地预测污水处理效果[26]。

尽管 ASMs 可较为地准确模拟污水处理生化反应过程，但近年来随着数据量的增加和计算机计算能力的逐步发展，ASMs 在实际应用中的不足逐步体现出来。ASMs 是一种融合了物理、生物和化学的数学描述，为了便于处理和计算，它往往是对真实情况的简化，存在许多假设，所以模型和实际总是存在一定的差异，这导致了机理模型结构的不确定性[27,28]。此外，由于污水处理厂进水水质往往存在较大的波动，通常需要经常对模型进行动态校准，然而机理模型通常涉及数十个甚至数百个模型参数，这些参数之间存在复杂的非线性关系，进一步影响了机理模型的精度和适用性[29]。机理模型的校准过程通常是高度依赖经验性的，故动态校准过程不仅非常繁琐且耗时，还难以应对污水处理厂复杂的动态变化和适时调整的需求[3,30]。因此，机理模型在实际污水处理过程的广泛应用受到极大的限制。

1.2.2 机器学习模型

我国大多数城市生活污水处理厂采用活性污泥工艺处理生活污水，依赖多种物理、生物和化学机制，并受到大量的外部干扰，具有高度非线性和不确定性[9,31]。活性污泥系统的复杂性体现在微生物群落动态演替、进水水质波动性及工艺参数强耦合性，传统机理模型虽然能够描述活性污泥系统生化过程本质，但其依赖精确动力学参数与

中国知网 https://www.cnki.net

简化假设的特性，使其难以应对污水处理系统中微生物代谢、物质传递与流体力学的高度非线性问题以及暴雨冲击、进水流量突增等突发事件。

近年来，随着数据科学和计算能力的提升，机器学习逐渐进入污水处理领域，成为建立污水处理数学模型的重要研究工具。与基于物理、化学等特定领域知识构建的机理模型不同，机器学习模型属于数据驱动模型，它依托大量实际运行数据，基于数学和统计知识的各种算法进行模型构建及模拟[32]。机器学习模型能够通过构建输入变量于输出变量之间的映射关系，直接从数据中学习并总结数据的基本关系和规则，从而能够在无需了解专业知识的条件下预测新数据的状态，并且其预测性能能够随着数据量的增加和算法的迭代而提高[33]。因此，机器学习在处理多个输入和输出之间复杂的非线性关系方面非常有效[34]。近年来，随着机器学习算法的发展和数据量的逐渐增加，数据驱动模型在水处理领域的应用逐渐增多，例如利用机器学习预测膜生物反应器（MBR）中膜污染情况及进行不确定性分析、集成遥感和机器学习技术预测城市污水处理厂的进水生化需氧量（BOD_5）[35-37]。大量研究表明机器学习非常适合应用于污水处理系统数学模拟[38]。根据模型算法及对数据依赖程度的不同，机器学习可分为监督学习、无监督学习、半监督学习与强化学习四类[39]。

（1）监督学习（Supervised learning）

监督学习基于带标签数据训练模型，监督学习的数据集明确包含输入特征及其对应的输出标签。这类算法旨在按照每个样本所对应的标签，学习输入特征与输出标签之间的映射关系，进而能够在未知标签的样本上计算得出正确的结果[40]。监督学习适用于回归和分类任务，当模型输出为一个有限值集时，采用分类算法；当模型输出为一定范围内的任意数值时，采用回归算法[41]。回归算法和分类算法的示意图如图1-1所示。

目前，常用于水处理领域的监督学习算法有线性回归、支持向量机（SVM）、随机森林、神经网络等。Wei 等人评估了随机森林、决策树和梯度提升回归器这三个模型应用于污水处理厂的性能，结果表明，这三个模型在预测全规模污水处理厂的工业和生活废水的进水流量、氨氮和总氮方面都表现出强大的预测能力[42]。Yanran Xu 等人采用五个机器学习回归模型，在缺失进水磷参数和除磷化学剂量的情况下，预测小型污水处理厂出水总磷，得到支持向量机模型的最大 R^2 为 0.637，并提出了基于历史

中国知网 https://www.cnki.net

数据的异常警报设计，实现了出水总磷最高为 79.7%的预测精度[38]。Zihao Zhao 等人为了更好地实现对出水 TN 浓度的预测和控制，在序批式反应器工艺中构建了基于可控运行参数的前馈神经网络（FFNN）高效预测模型，模型以表观气体流速和缺氧时间代替 DO 作为主要的输入参数，成功地根据进水水质参数和关键控制参数对出水 TN 进行了准确预测[8]。Hongbin Liu 等人集成偏最小二乘法、支持向量回归和人工神经网络等模型，提出了一种堆叠集成学习方法预测造纸废水出水水质指标，为实现污水处理过程的实时预测提供了新途径[43]。

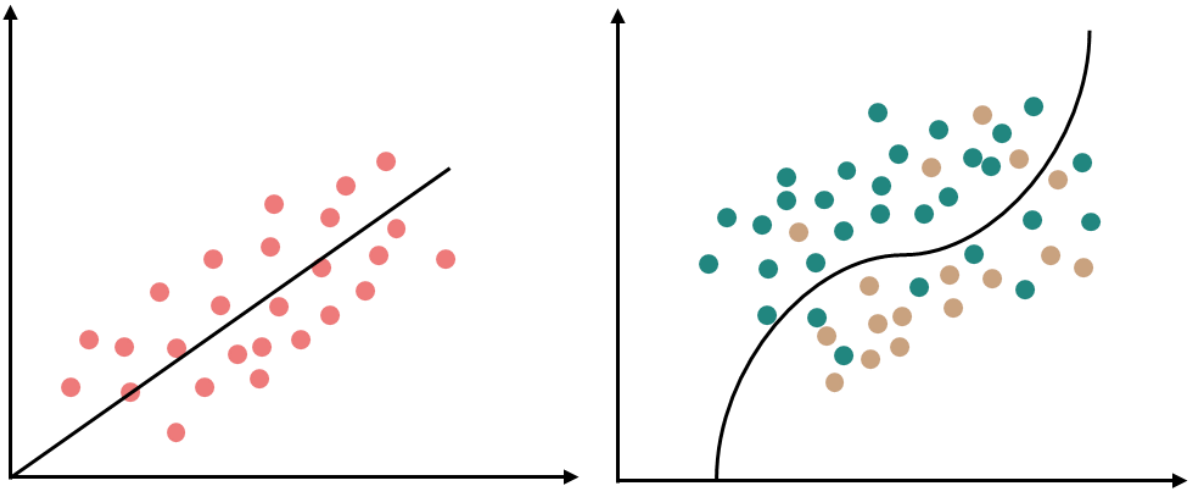


图 1-3 回归算法、分类算法示意图：（a）回归算法；（b）分类算法

Figure1-3 Schematic diagram of regression algorithm, classification algorithm: (a) regression algorithm; (b) classification algorithm

（2）无监督学习（Unsupervised learning）

与监督学习不同，无监督学习几乎不依赖标签数据；相反，无监督学习直接从无标签数据中挖掘潜在结构或模式，这使得无监督学习非常适合于探索性数据分析[44]。常见的无监督学习算法包括聚类、降维与异常检测等[45]。其中，聚类算法（K-means）是聚类分析的常用方法，它通过数据按照相似性划分为不同的簇，能够有效地发现数据中地潜在结构，揭示不同样本之间地相似性[46]。主成分分析（PCA）则是一种经典的降维方法，它通过线性变换将高维数据映射到低维空间，并提取出最能代表数据特征的几个主成分。通过降维，PCA 能够有效地去除冗余信息，从而降低数据集的维度、简化数据结构，减轻后续分析的计算负担[47]。Niu 等人采用使用遗传算法来降低输入变量维度并简化神经网络架构，成功预测了造纸厂废水处理的出水 COD 和

中国知网 https://www.cnki.net

SS[48]。Han 和 Zhang 等人采用一种基于偏最小二乘法和深度置信网络（PLS-DBN）的无监督学习方法，在膜生物反应器中进行多步提前渗透性预测，从而提前发现污染风险[49]。总体而言，无监督学习凭借其无需标签数据的特点，在处理复杂的高维数据、探索数据内在规律方面具有显著优势。

（3）半监督学习（Semi-supervised learning）

介于监督学习和无监督学习之间，半监督学习使用少量带标签数据与大量无标签数据训练模型，这种方法通常在标注数据稀缺且数据标签成本较高的场景中应用广泛[50]。与传统的监督学习算法依赖于大量有标签数据不同，半监督学习能够有效解决数据标注成本高的问题。半监督学习的核心思想是，首先利用无标签数据学习数据分布等特征，学习到数据的分布模式和内在关联性，然后再借助少量有标签数据对模型进行微调，使得模型能够更准确地进行预测。Dong Li 等人结合堆叠自编码器（SAE）与多输出神经网络（MNN），通过半监督协同训练算法利用未标记数据扩展训练集，有效解决了污水处理过程中高维数据冗余、训练样本不足及多任务预测的问题[51]。Xiaoshi Chen 等人采用集成半监督学习（SSL）-AutoML 模型，通过有限的变量输入，探究不同预处理对污泥消化过程中甲烷产量的影响，结果表明该集成模型优于传统机器学习模型，使均方误差从 11.3 降低到 9.7，提高了预测精度[52]。在实际应用中，半监督学习在如何设计合理的模型架构，确保无标签数据的利用不引入噪声以及如何优化算法的训练过程等方面也存在挑战性。

（4）强化学习（Reinforcement Learning, RL）

强化学习是机器学习的范式和方法论之一，用于描述和解决智能体在与环境的交互过程中通过学习策略来实现回报最大化或达成特定目标的问题[53]。强化学习的核心思想是通过智能体与环境的动态交互，依据环境给予的反馈信号（奖励或惩罚）来学习最优的行为策略。强化学习主要由智能体（agent）和环境（environment）两部分以及动作（action）、状态（state）和奖励（reward）三要素组成。其基本结构如图 1-4 所示。其中，智能体是一个嵌入到环境中的决策系统，能够通过与环境交互来影响环境的状态；环境则是一个外部系统，智能体处于这个系统中，能够感知到这个系统并且能够基于感知到的状态做出相应的行动；状态表示环境在某一时刻的具体情况，是对环境的描述；动作空间是智能体在特定状态下能够采取的动作集合，动作空间可

中国知网 https://www.cnki.net

以是离散的，也可以是连续的；奖励是环境对于智能体采取某一行动后的反馈信号，通常表现为一个标量，反映了智能体在该状态下采取某个动作的好坏[54]。智能体的目标是通过与环境的不断交互，最大化长期累积的奖励，从而学习出最优的策略。

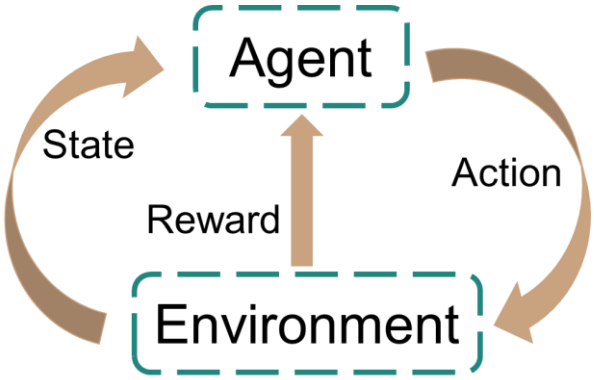


图 1-4 强化学习结构图

Figure1-4 Structure diagram of reinforcement learning

强化学习的学习过程本质上是一个通过“试错”来不断优化决策的动态过程。智能体首先在环境中进行随机搜索，获取初步的经验和数据，然后通过这些数据调整策略，使其能够在未来的决策中做出更有的选择。值得注意的是，强化学习面临的一个关键挑战是探索（Exploration）与开发（Exploitation）之间的权衡。在探索阶段，智能体需要尝试新的动作来发现可能的更优解；而在开发阶段，智能体则需要利用已知的经验来最大化即时的奖励。如何更好地平衡这两者，避免陷入局部最优解，是强化学习研究中的一个核心问题。相比于传传统方法，强化学习不需要预先设定精确的数学模型，而是依靠与环境的反复交互，自动调整策略，逐步逼近最优解。这使得强化学习在处理高维、不确定或动态变化的环境时展现出了巨大的潜力。

总而言之，强化学习旨在探讨一个智能体（agent）如何在一个复杂而不确定的环境（environment）里面去最大化它能获得的奖励或者最小化它得到的惩罚。智能体通过感知所处环境的状态（state）对执行的动作（action）的反馈（reward），来指导下一步更好的动作，从而获得最大的收益，这种通过智能体与环境的不断交互中进行学习的方法就被称作强化学习[55,56]。它为解决具有长期依赖关系的决策问题提供了有效的工具，尤其在复杂系统的优化和控制中，强化学习具有广泛的应用前景。

尽管机器学习在污水处理领域水质模拟中展现出潜力，但在实际应用中由于其“黑箱性质”导致的可解释性缺失仍阻碍了其进一步的广泛应用。在实际污水处理系

中国知网 https://www.cnki.net

统中，工艺调控决策高度依赖对于出水水质参数变化机制的清洗理解，然而传统机器学习模型难以阐明输入特征与出水指标之间的因果关联。

1.3 污水处理系统多目标优化的发展现状

随着城市化进程的加快和人口规模的持续增长，污水排放量持续增加，而日趋严格的水质排放标准进一步增加了污水处理厂的运行压力。污水处理厂的总能耗也随着污水排放量的增加不断增加，因此，污水处理厂的高能耗问题已成为全球环境领域关注的焦点[57]。通过查阅相关文献可知，在全球范围内，污水处理厂约占电力消耗的3~5%，其中曝气能耗和泵送能耗占据污水处理厂总能耗的绝大部分[58-60]。在“碳达峰，碳中和”战略目标驱动下，污水处理厂的目标是在达到高标准出水水质的同时，最大限度减少能源消耗[61]。多目标优化方法为解决这一问题提供了路径。优化是从一个问题中寻找最优解的过程，优化问题包括针对一个目标或多个目标寻找最大值或最小值。具有多个目标的问题被称之为多目标优化问题（Multi-objective Optimization Problems）[62]。多目标优化问题是由多个目标函数、决策变量和约束条件组成，其数学表达式可表示为：

$$min/\max f_1(x), f_2(x), \dots, f_n(x)$$
$$subject\ to: x \in U \tag{1-1}$$

其中，x为决策变量，$f_n(x)$为目标函数，U为可行解集，即满足所有约束性条件的解空间。

Revollar 等人提出了一种级联控制策略，通过动态调整 DO 设定值，并通过外部 PI 控制器以提高污水处理厂全局性能，并且在 BSM2 模型上验证了该方法在降低能耗与碳排放方面的有效性[63]。Holenda 等人利用模型预测控制（MPC）实现了活性污泥过程中溶解氧的高精度调节，其研究显示，MPC 在动态工况下较传统 PI 控制显著减少了控制误差[64]。Kehua Chen 等人提出了一种基于多智能体深度强化学习（MADRL）的污水处理厂可持续优化控制方法，通过结合多智能体深度确定性策略梯度（MADDPG）算法与生命周期评估（LCA），系统性优化了污水处理厂的多目标控制，为实际运营提供兼顾环境与经济的新方法[65]。Croll 等人基于 BSM1（Benchmark Simulation Model No.1）模型系统评估了四种强化学习算法在污水处理

中国知网 https://www.cnki.net

控制中的性能，结果表明双延迟深度确定性策略梯度（Twin Delayed Deep Deterministic Policy Gradient, TD_3）表现最优，在单动作控制场景中与基准控制模型相比降低曝气与泵送能耗 14.3%，同时维持出水氨氮和出水总氮达标[66]。

1.4 课题研究意义及主体内容

1.4.1 课题研究目标及意义

本文旨在探索机理模型和可解释机器学习模型在预测污水处理厂出水总氮方面的有效性。使用了基于 ASM 模型的 SUMO 软件对污水处理厂进行全厂建模，并对 ASM 模型的动力学和化学计量学参数进行了敏感性分析，然后根据敏感性分析的结果，筛选出部分重点参数对 ASM 模型进行了动态校准。之后采用了六种机器学习算法对污水处理厂进行建模。为了提高机器学习模型的可解释性，本文还加入了 SHAP 算法以提供机器学习模型的事后解释。

1.4.2 课题研究思路及内容

为了达到以上研究目标，对课题研究内容主要分为以下几个方面：

（1）以我国某城市污水处理厂为研究对象，在 ASM 模型的基础上使用 SUMO22 软件对该污水处理厂构建 Sumo2 模型，并对模型的动力学和化学计量学参数进行敏感性分析。根据敏感性分析的结果，对该机理模型分别进行稳态校准及动态校准。

（2）根据污水处理厂 2018 年 10 月~2019 年 11 月实际监测数据，分别采用六种机器学习算法搭建城市污水处理厂模型，探究机器学习模型预测污水处理厂出水 TN 浓度的可行性；为了提升机器学习模型应用于污水处理领域的可靠性，深度剖析机器学习作出准确预测的依据，通过 SHAP 算法分析影响污水处理厂出水 TN 浓度的关键特征因素。

（3）选取好氧区溶解氧浓度、内回流比和外回流比三个对污水处理厂出水 TN 浓度影响较大的工艺参数，设计并建立三因素二水平的二次多项式响应面模型。对该二次多项式模型拟合并进行显著性检验并结合该模型优化结果对确定最佳运行工艺参数。

中国知网 https://www.cnki.net

（4）基于已建立的城市污水处理厂出水 TN 预测模型，结合 TD3 算法构建强化学习模型，使污水处理厂在出水 TN 达标的基础上，能够尽可能降低污水处理厂能耗，以期获得实现出水 TN 稳定达标、处理能耗降低的优化策略。

1.4.3 技术路线

本论文的技术路线图，如图 1-5 所示。

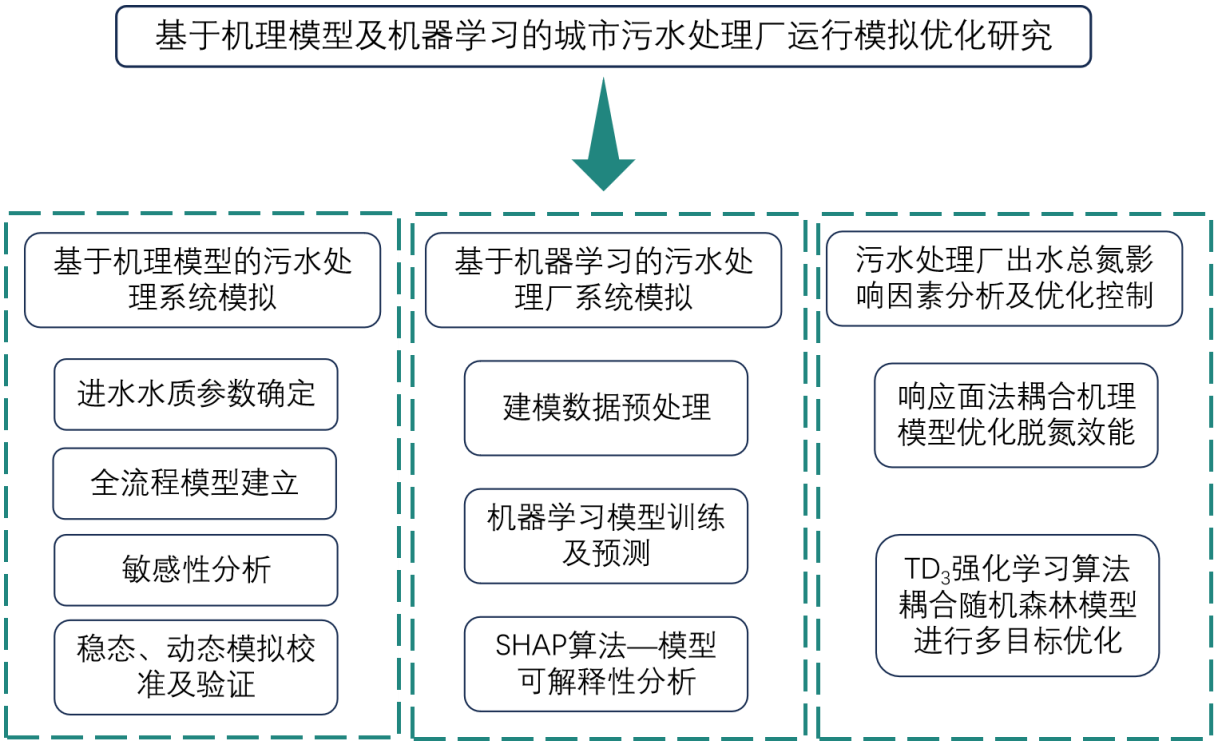


图 1-5 本研究技术路线示意图

Figure1-5 Schematic diagram of the technical route of this study

中国知网 https://www.cnki.net

第二章 研究方法及污水厂数据分析

2.1 数据分析及模型评估方法

2.1.1 数据分析方法

（1）标准差

计算污水处理厂进出水水质数据的标准差，可以直观地反应出这些水质数据的波动情况。标准差越大，说明水质数据的离散程度越高，即水质越不稳定；反之，标准差越小，表明水质越稳定。标准差计算公式为：

$$\sigma = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}} \tag{2-1}$$

其中，σ为标准差，n为样本数据总量，$\bar{x}$为样本数据平均值。

（2）相关性分析

斯皮尔曼相关系数（Spearman's Rank Correlation Coefficient），又称秩相关系数，是一种非参数统计方法，基于两变量的秩次进行相关分析。与皮尔逊相关系数不同，斯皮尔曼相关系数对原始变量的分布不做要求，也不要求变量之间存在线性关系，它反映的是两变量之间的单调关系。因此，它适用于污水处理厂相关数据的分析，尤其当数据呈现非正态分布或存在非线性趋势时。斯皮尔曼相关系数的计算公式为：

$$\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)} \tag{2-2}$$

其中ρ为斯皮尔曼相关系数，d_i为每对观测值排序后的差异，n为观测值的数量。斯皮尔曼相关系数的取值范围为[-1,1]，ρ = 1 表示两个特征为完全的正相关，ρ = -1 表示两个特征为完全的负相关，ρ = 0 表示两个特征之间不存在任何单调关系。

（3）异常值筛选

四分位距法（Interquartile Range, IQR）是一种基于分布的异常值检测方法，适用于识别数据中的极端值。其计算步骤为：首先将数据按照大小顺序排序，确定下四分位数（Q1，即 25%分位数）和上四分位数（Q3，即 75%分位数），其次计算 IQR：$IQR = Q3 - Q1$，异常值范围被定义为：

$$\text{下限：} x < Q1 - 1.5 \times IQR \tag{2-3}$$

中国知网 https://www.cnki.net

$$\text{上限：} x > Q3 + 1.5 \times IQR \tag{2-4}$$

超出该范围的数据即被视为异常值，其中，1.5 是一个经验系数，用于识别显著偏离数据分布的离群点。

（4）缺失值填充

滚动均值插补法（Rolling Mean Imputation）是一种使用时间序列数据中相邻观测值的均值来填充缺失数据的方法。具体来说，对于每个缺失值所在位置，设定一个固定长度的滚动窗口（本文中将滚动窗口设置为 12），并计算该窗口内所有非缺失值的均值，然后用该均值来填补相应位置的缺失值。该方法能够充分利用时间序列数据的局部信息，有效降低缺失数据对后续分析和模型构建的影响。

（5）标准化

数据集各输入特征数值差异较大且量纲不同，会影响模型拟合精度，降低模型训练效果。因此，有必要采用 Min-max 标准化方法将所有数据进行无量纲处理并统一至 0-1 之间。Min-max 标准化公式如下：

$$x_i^{scale} = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)} \tag{2-5}$$

其中，x_i^{scale}为标准化后的数据值，x_i为第 i 个数据值，min (x_i)和max(x_i)分别为样本中的最小值和最大值。

2.1.2 模型评估方法

本文所建立的污水处理系统数学模型均属于回归模型范畴，为了全面地评估模型的有效性和预测性能，本文采用决定系数（R^2）、相对误差（RE）、平均相对误差（MRE）、均方误差（MSE）作为模型评估指标。

（1）决定系数（R^2）

决定系数反映了模型预测结果和真实结果的拟合程度，R^2 取值为[0,1]，其值越接近于 1，表明模型预测值与实际值的拟合效果越好。其计算公式为：

$$R^2 = 1 - \frac{\sum_{i=1}^{n}\left(y_{pred,i} - y_i\right)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{2-6}$$

其中，$y_{pred,i}$为预测值，y_i为实际值，$\bar{y}$为实际平均值。

（2）相对误差（RE）

中国知网 https://www.cnki.net

相对误差通过逐点计算误差来反映模型预测相对误差的分布情况。其计算公式为：

$$RE = \frac{y_{pred,i} - y_i}{y_i} \tag{2-7}$$

（3）平均相对误差（MRE）

平均相对误差用以表示模型相对误差的总体大小。其计算公式如下：

$$MRE = \frac{1}{n}\sum_{i=1}^{n} \frac{y_{pred,i} - y_i}{y_i} \tag{2-8}$$

（4）均方误差（MSE）

均方误差衡量的是模型预测值与实际值之间的差异的平方值的平均值。模型预测值与实际值的差值越小，则均方误差越小。由于均方误差对误差值进行平方，其单位是目标变量的平方，导致它对异常值比较敏感，可能会导致过高的误差。其计算公式如下：

$$MSE = \frac{1}{n}\sum_{i=1}^{n} \left(y_{pred,i} - y_i\right)^2 \tag{2-9}$$

2.2 目标污水厂主体工艺

该污水处理厂主体工艺为改良 A^2/O 工艺，具体工艺流程如图 2-1 所示。该工艺流程包含从进水到出水经过多个物理、化学和生物处理单元。污水首先经过粗格栅去除大颗粒悬浮物、树枝等杂物，随后污水进入提升泵房提升后经过细格栅去除较为微小的悬浮物，以防止后续设备堵塞和损坏。之后，污水进入曝气沉砂池，通过曝气的方式去除较大颗粒的沙砾，避免沉积在管道和设备中影响运行。然后，污水进入改良 A^2/O 工艺处理单元，实现有机物降解与脱氮除磷。改良 A^2/O 工艺是一种强化生物脱氮除磷的活性污泥法，包含预缺氧（Pre-Anoxic）、厌氧（Anaerobic）、缺氧（Anoxic）和好氧（Aerobic）阶段。在预缺氧阶段，反硝化菌将硝酸盐还原为氮气，消除硝酸盐对后续厌氧阶段释磷的干扰；回流污泥中的硝酸盐在此阶段被反硝化消耗，避免其进入厌氧段与聚磷菌竞争碳源，从而保障厌氧阶段碳源高效用于释磷过程。在厌氧阶段，聚磷菌（Polyphosphate-Accumulating Organisms, PAOs）利用细胞内储存的聚磷酸盐（ploy-P）水解产生能量以获取有机碳源（如挥发性脂肪酸）。磷以正磷酸盐（PO_4^{3-}）的形式释放到水体中；发酵菌将可溶性有机物（如糖类）转化为 VFAs（如乙酸、丙酸），为后续缺氧和好氧阶段的微生物代谢提供碳源。在缺氧阶段，反硝化

中国知网 https://www.cnki.net

菌利用有机碳源作为电子供体，将硝态氮（NO_3^--N）先转化为中间产物亚硝酸盐（NO_2^--N）、一氧化氮（NO）和一氧化二氮（N_2O），最终还原为氮气（N_2），从而去除污水中的氮污染；部分兼性反硝化聚磷菌可利用硝酸盐作为电子受体，在缺氧条件下实现部分磷摄取。在好氧阶段由鼓风机曝气提供充足的氧气，亚硝化细菌（Ammonia Oxidizing Bacteria, AOB）将氨氮（NH_4^+-N）氧化为亚硝酸盐，之后硝化细菌（Nitrite Oxidizing Bacteria, NOB）进一步将亚硝酸盐氧化为硝酸盐；聚磷菌大量摄取磷酸盐，并将其储存为细胞内聚磷酸盐，随着剩余活性污泥排出系统。经过生物处理后，污水流入二沉池进行沉淀，利用重力沉降分离活性污泥和水，部分活性污泥被回流至生物处理单元以维持微生物浓度，剩余污泥则被排出进行污泥处理。二沉池出水经磁混凝沉淀进一步去除残余的悬浮物、胶体污染物和部分溶解性污染物。随后，经过紫外/次氯酸钠消毒处理单元后外排至自然水体。

本研究仅针对污水处理厂的污水处理系统进行建模及优化分析，未考虑污泥处理过程，故工艺流程图不包含污泥处理相关工艺。

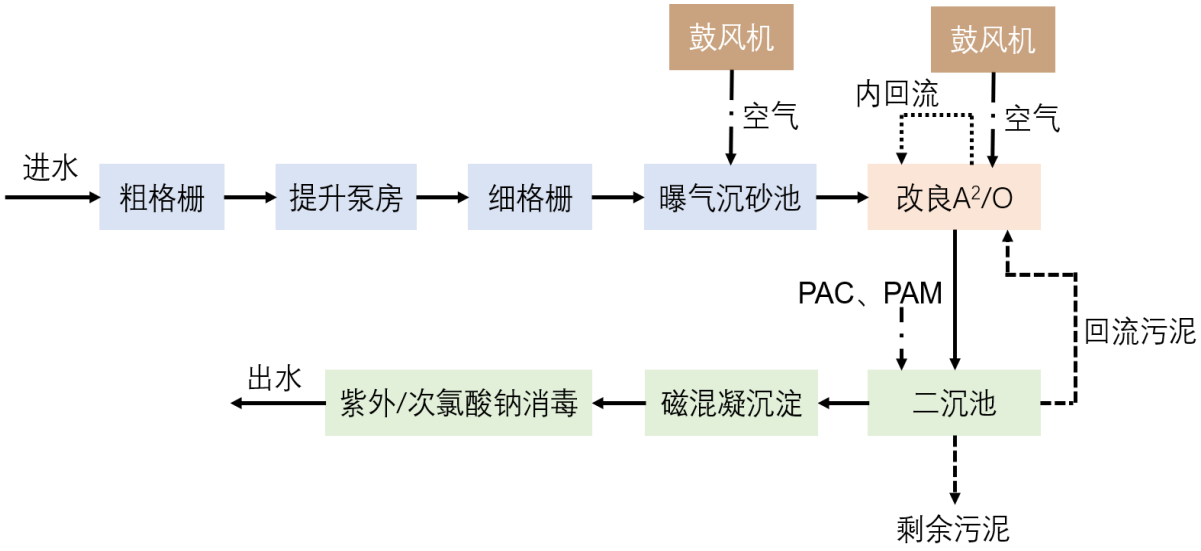


图 2-1 污水处理厂设计工艺流程图

Figure2-1 Design process of wastewater treatment plant

2.3 目标污水厂运行数据分析

本文以我国某城市污水处理厂为研究对象，通过统计学方法对目标污水厂 2018 年 10 月至 2019 年 11 月期间采集的数据进行全面分析，以掌握该污水厂在全年范围内水质与水量的分布特征和变化趋势。对进水水质参数、运行参数以及出水水质参数

中国知网 https://www.cnki.net

进行了描述性统计，主要涵盖最小值、最大值、平均值及标准差等统计量。这些指标不仅能够反映数据整体的波动情况，还可以反映数据的离散程度，为后续数据预处理奠定了基础。该水厂数据整体描述性统计如表 2-1 所示：

表 2-1 目标污水厂数据描述性统计

Table2-1 Descripitive statistics for targeted wastewater treatment plant data

类别	参数	最小值	最大值	平均值	标准差
进水水质参数	流量(m^3/h)	49051.02	199492.13	101677.48	25873.12
	pH	7.07	7.69	7.32	0.12
	COD(mg/L)	87.50	615.00	277.78	83.49
	BOD(mg/L)	32.00	185.00	94.38	28.14
	SS(mg/L)	96.00	964.00	221.11	96.87
	TP(mg/L)	1.00	6.51	3.01	0.81
	NH_4^+-N(mg/L)	4.36	28.15	16.88	4.44
	TN(mg/L)	12.33	45.88	27.81	6.39
运行参数	污泥饼量(t)	6.20	139.19	82.72	23.78
	污泥含水率(%)	76.10	79.90	79.15	0.85
	MLSS(mg/L)	3218.00	9836.50	7023.32	1487.04
	污泥回流量(m^3/d)	32062.00	178182.00	102518.10	29553.70
	DO(mg/L)	0.36	37.62	3.05	1.91
	PAC(t)	1.44	45.60	4.19	2.80
	PAM(t)	5.02	547.06	94.84	33.41
出水水质参数	COD(mg/L)	11	49	29.32	9.69
	BOD(mg/L)	2	4.4	2.26	0.54
	SS(mg/L)	5	16	6.40	1.75
	TP(mg/L)	0.01	0.5	0.08	0.07
	NH_4^+-N(mg/L)	0.02	2.4	0.34	0.25
	TN(mg/L)	2.60	11.76	6.48	1.51

(1)进水流量分析

图 2-2 展示了该污水处理厂 2018 年 10 月至 2019 年 11 月期间的进水流量变化趋势。该污水处理厂的进水流量最小值为 49051.02 m^3/d，发生在 2019 年 1 月；而最大值为 199492.13 m^3/d，发生在 2019 年 6 月，平均进水流量为 101677.48 m^3/d，标准

中国知网 https://www.cnki.net

差为 25873.12 m^3/d，表明该污水处理厂进水水量呈现较大波动。整体来看，该污水处理厂进水流量在 2018 年 10 月至 2019 年 2 月期间较为稳定，从 4 月份至 9 月份逐渐增大，且进水数据的离散度较大，随后，进水流量又逐步降低。污水处理厂进水流量的变化可能受到降雨、城市用水排放以及污水管网运行情况的影响。从整体趋势来看，该污水处理厂的进水流量在研究期间经历了季节性变化，夏季进水流量较高，冬季进水流量较低，这与降雨量和城市排水负荷的变化趋势相符。

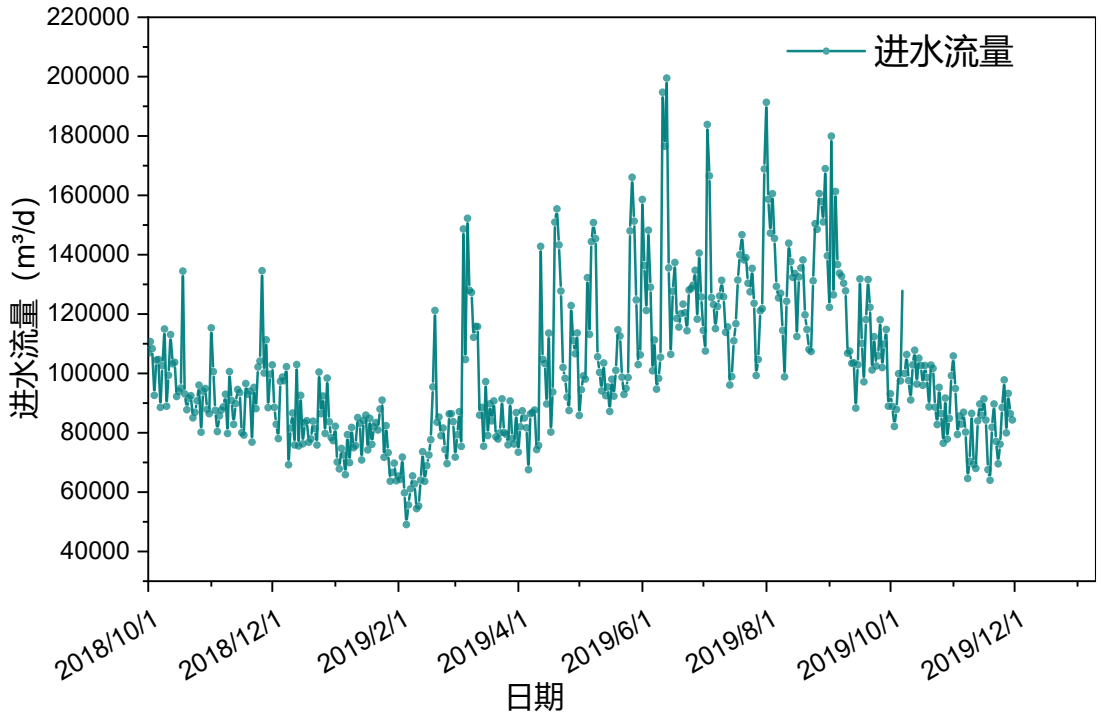


图 2-2 污水处理厂进水水量变化

Figure2-2 Influent volume variation of wastewater treatment plant

（2）进出水水质分析

2018 年 10 月至 2019 年 11 月期间，该污水处理厂进出水 COD 浓度的变化情况如图 2-3 所示。整体来看该污水处理厂的平均进水 COD 浓度为 277.78 mg/L，标准差为 83.49 mg/L，其中最高进水 COD 浓度为 615 mg/L，发生在 2019 年 1 月份，最低进水 COD 浓度为 87.50 mg/L，发生在 2019 年 8 月份，表明该污水处理厂的进水 COD 浓度波动较大。2019 年 1 月份进水 COD 浓度最高，2019 年 1 月至 4 月期间进水 COD 浓度波动较大，存在显著的峰值，6 月至 9 月进水 COD 浓度较低，且相对稳定，这可能是由于降雨量增大导致污水处理厂进水 COD 浓度下降。分析该污水处理

中国知网 https://www.cnki.net

厂出水 COD 浓度变化，得知平均出水 COD 浓度为 29.32 mg/L，最高出水 COD 浓度为 49 mg/L，最低出水 COD 浓度为 11 mg/L，标准差为 9.69 mg/L，表明该污水处理厂出水 COD 较为稳定。

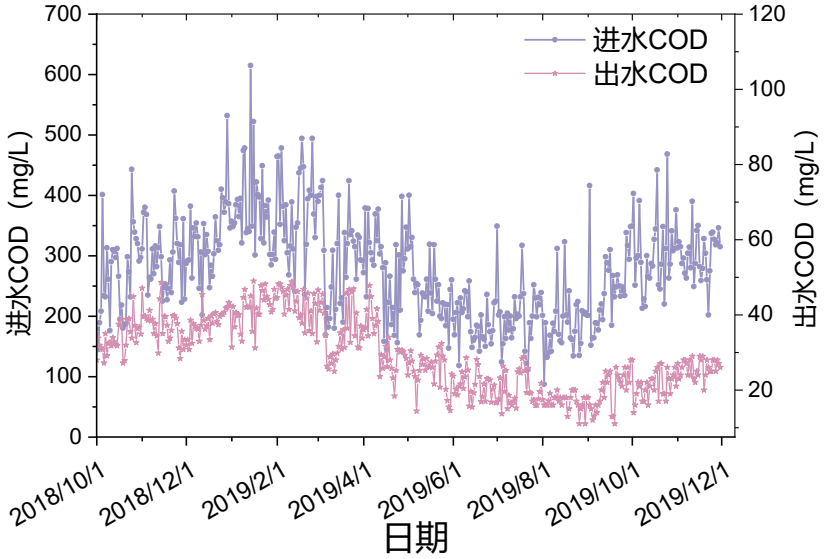


图 2-3 COD 进出水浓度变化趋势

Figure2-3 Variation trend of inlet and outlet concentration of COD

2018 年 10 月至 2019 年 11 月期间，该污水处理厂进出水 TN 浓度变化情况如图 2-4 所示，整体来看该污水处理厂的平均进水 SS 浓度为 221.11 mg/L，标准差为 96.87 mg/L，进水 SS 浓度整体呈现较大波动，其中最高进水 SS 浓度为 964 mg/L，发生在 2019 年 1 月份，说明这段时期该污水处理厂进水中无机质成分含量较高，最低进水 SS 浓度为 96 mg/L。出水 SS 浓度平均值为 6.40 mg/L，标准差为 1.75 mg/L，最高出水 SS 浓度为 6 mg/L，最低出水 SS 浓度为 5 mg/L。在 2018 年 10 月至 2018 年 12 月期间，出水 SS 浓度出现较大波动且存在部分超标情况，但整体来看达标状况良好。

中国知网 https://www.cnki.net

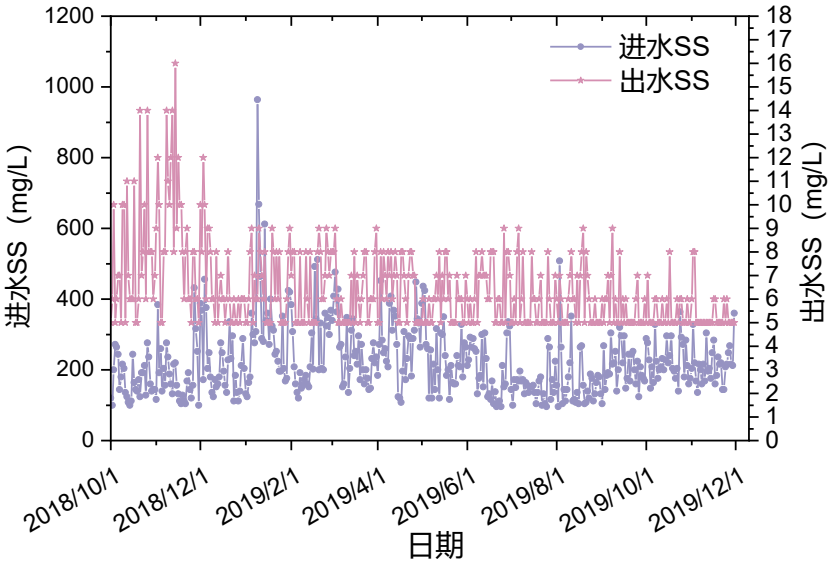


图 2-4 SS 进出水浓度变化趋势

Figure2-4 Variation trend of inlet and outlet concentration of SS

2018 年 10 月至 2019 年 11 月期间，该污水处理厂进出水 TN 浓度变化情况如图 2-5 所示，整体来看该污水处理厂的平均进水 TN 浓度为 27.81 mg/L，标准差为 27.81 mg/L，其中最高进水 TN 浓度为 45.88 mg/L，发生在 2019 年 2 月份，最低进水 TN 浓度为 12.33 mg/L，发生在 2019 年 8 月份，表明该污水处理厂进水 TN 浓度波动较大。分析该污水处理厂出水 TN 浓度变化，得知平均出水 TN 浓度为 6.48 mg/L，最高出水 TN 浓度为 11.76 mg/L，最低出水 TN 浓度为 2.6 mg/L，标准差为 1.51 mg/L，表明该污水处理厂出水 TN 较为稳定。数据分析表明该污水处理厂 6 月至 10 月出水 TN 浓度较低，而冬季出水 TN 浓度虽未超标，但相对来说脱氮效果不太理想。

中国知网 https://www.cnki.net

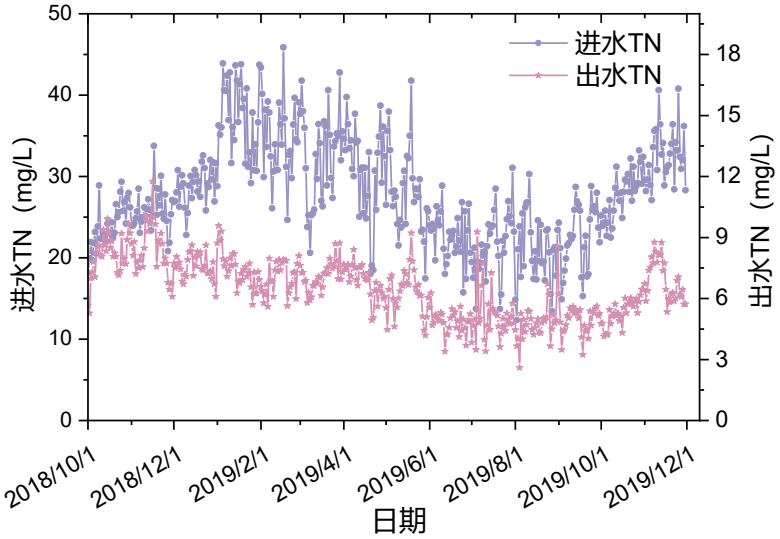


图 2-5 TN 进出水浓度变化趋势

Figure2-5 Variation trend of inlet and outlet concentration of TN

2018 年 10 月至 2019 年 11 月期间，该污水处理厂进出水 NH_4^+-N 浓度的变化情况如图 2-6 所示。整体来看该污水处理厂的平均进水 NH_4^+-N 浓度为 16.88 mg/L，标准差为 4.44 mg/L，其中最高进水 NH_4^+-N 浓度为 28.15 mg/L，发生在 2019 年 1 月份，最低进水 NH_4^+-N 浓度为 4.36 mg/L，发生在 2019 年 8 月份，表明该污水处理厂进水 NH_4^+-N 浓度波动较大。分析该污水处理厂出水 NH_4^+-N 浓度变化，得知平均出水 NH_4^+-N 浓度为 0.34 mg/L，最高出水 NH_4^+-N 浓度为 2.4 mg/L，最低出水 NH_4^+-N 浓度为 0.02 mg/L，标准差为 0.25 mg/L，表明该污水处理厂出水 NH_4^+-N 较为稳定。

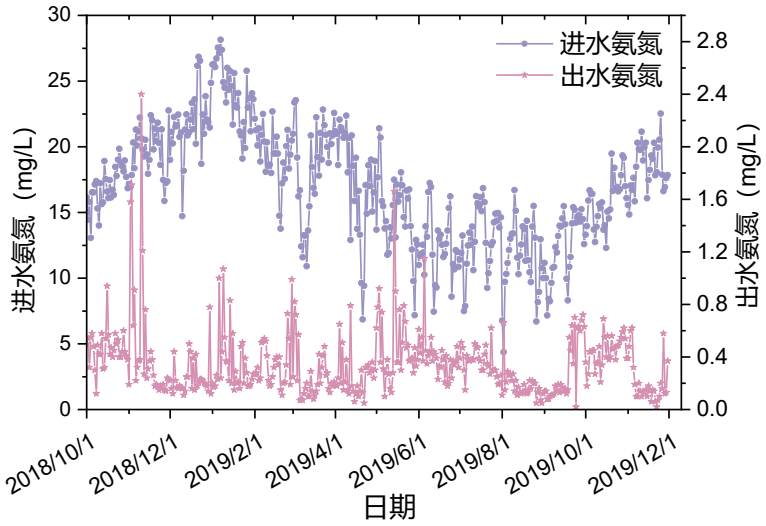


图 2-6 NH_4^+-N 进出水浓度变化趋势

Figure2-6 Variation trend of inlet and outlet concentration of NH_4^+-N

中国知网 https://www.cnki.net

2018 年 10 月至 2019 年 11 月期间，该污水处理厂进出水 TP 浓度的变化情况如图 2-7 所示。整体来看该污水处理厂的平均进水 TP 浓度为 3.01 mg/L，标准差为 0.81 mg/L，其中最高进水 TP 浓度为 6.51 mg/L，发生在 2019 年 2 月份，最低进水 TP 浓度为 1.00 mg/L，发生在 2019 年 8 月份，表明该污水处理厂进水 TP 浓度波动较大。分析该污水处理厂出水 TP 浓度变化，得知平均出水 TP 浓度为 0.079 mg/L，最高出水 TP 浓度为 0.5 mg/L，最低出水 TP 浓度为 0.01 mg/L，标准差为 0.071 mg/L，表明该污水处理厂出水 TP 较为稳定。

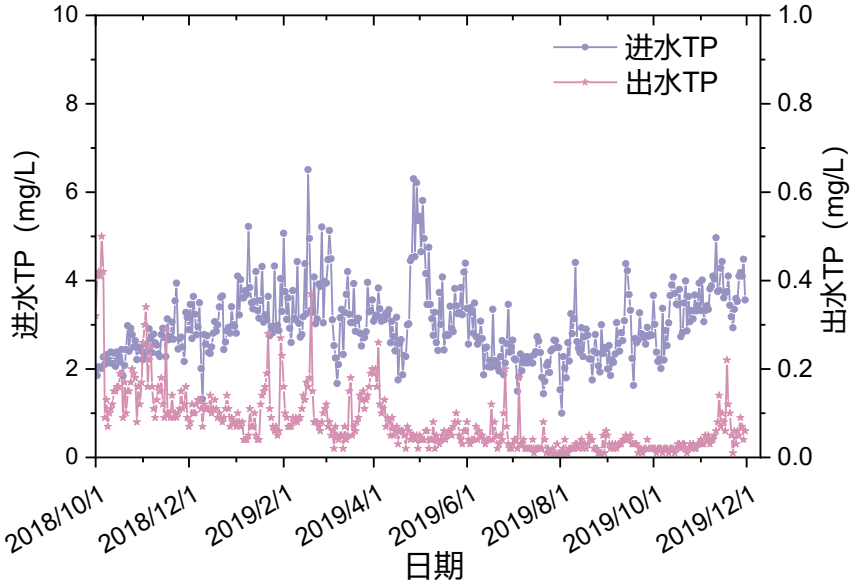


图 2-7 TP 进出水浓度变化趋势

Figure2-7 Variation trend of inlet and outlet concentration of TP

2.4 机器学习算法原理

（1）随机森林

随机森林是一种集成的机器学习算法，由众多棵决策树组成，通过集成多棵决策树的预测结果来提高整体模型的准确性和鲁棒性[67]。其核心思想主要体现在以下几个方面：首先是数据层面的自助采样法（Bootstrap Sampling），即通过有放回的重抽样方式从原始训练集中随机抽取多个不同的训练子集，每个子集用于训练一颗决策树。由于有放回的抽样，每个子集可能会包含重复的样本，同时会有一部分原始数据可能不会被采样，这些数据称为袋外数据（Out-of-Bag Data, OOB），可用于模型的误差估

中国知网 https://www.cnki.net

计；其次为特征层面的随机特征选择，即在构造每棵决策树时，随机森林并不会使用所有特征，而是在每棵决策树的节点分裂过程中，从全部特征中随机选取部分特征然后从中选择最优的特征进行分裂。随机森林的随机性使得每棵树的训练数据不同，从而降低模型的误差，同时可避免决策树过度依赖某些强相关特征，减少了每棵决策树之间的相关性，从而增强整体模型的泛化能力[68]。在模型预测时，通过集成所有决策树的输出结果，分类任务采用多数投票原则确定最终预测结果，回归任务则按照以下公式通过均值计算实现预测。

$$\hat{y} = \frac{1}{T}\sum_{t=1}^{T} f_t(x) \tag{2-10}$$

其中，$f_t(x)$表示第 t 棵决策树的预测结果，T为总决策树数，最终结果为各棵树预测值的平均值。

（2）XGBoost 模型

XGBoost 是一种高效的梯度提升决策树算法，其核心思想是利用 Boosting 思想，通过一定的方法将多个弱学习器集成为一个强学习器，本质上是用多棵决策树共同决策，并且每棵决策树的结果都是目标值与之前所有树的预测结果之差，并将所有的结果累加即得到最终的结果，从而达到整个模型提升的效果[69]。为了优化模型，XGBoost 最小化一个包含损失函数和正则化项的目标函数，公式如下：

$$L(\theta) = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k) \tag{2-11}$$

其中，$l(y_i, \hat{y}_i)$为损失函数，用于衡量预测值与真实值之间的误差；$\Omega(f_k)$为正则化项，用于控制模型复杂度，防止过拟合。正则化项通过以下公式定义：

$$\Omega(f_k) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2 \tag{2-12}$$

其中，T是树的叶子数，w_j是叶子权重，γ和λ则分别控制叶子数的惩罚和叶子权重的$L2$正则化程度。为了提高优化效率，XGBoost 使用二阶泰勒展开近似损失函数，公式为：

$$L^{(t)} = \sum_{i=1}^{n} \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \tag{2-13}$$

中国知网 https://www.cnki.net

其中，g_i和h_i分别表示损失函数的梯度和二阶梯度，这使 XGBoost 能够利用更多的信息来进行更快速的收敛。XGBoost 还通过计算每个叶子节点的最优权重来更新模型，其计算公式为：

$$w^* = -\frac{\sum_{i\epsilon I} g_i}{\sum_{i\epsilon I} g_i + \lambda} \tag{2-14}$$

XGBoost 还支持基于特征的并行化计算，这表明它可以自动利用 CPU 的多线程计算，显著提高训练效率，相比于传统的 GBDT 算法，XGBoost 能够大幅度提升计算速度并提高模型的准确性[70]。

（3）LightGBM 模型

LightGBM 是一种基于梯度提升树的机器学习算法，旨在解决传统梯度提升算法的训练速度和内存消耗问题。它采用叶子生长策略，通过选择每次最小化损失函数的节点来加速树的生长过程。与传统的按层生长的策略不同，LightGBM 通过在每次分裂时选择能最小化损失函数的叶子节点来优化训练过程。同时，LightGBM 使用直方图算法来存储连续特征值并构建直方图，以减少内存和计算开销。通过这种方式，LightGBM 能够有效地处理大规模数据集，显著提升训练速度并在训练和预测过程中表现良好[71]。

（4）支持向量机模型

支持向量机是一种支持分类和回归的监督学习算法，其核心思想是通过寻找一个最优超平面来有效分离不同类别的数据点，同时最大化边界与最近数据点之间的间隔。在处理回归任务时，支持向量回归（SVR）的目标是拟合一条回归曲线，使尽可能多的数据点都落在设定的容差范围内，同时对落在容差之外的数据点进行适当的惩罚[72]。SVR 的目标是最小化以下目标函数：

$$min_{w,b,\xi_i} \frac{1}{2} \| w \|^2 + C \sum_{i=1}^{n} \xi_i \tag{2-15}$$

其中，w为超平面的法向量；b为偏置项；ξ_i是松弛变量，表示第i个数据点偏离回归曲线的程度；C为惩罚系数，用于控制对误差的惩罚力度。

通过使用核函数，支持向量机能够将数据从原始特征空间映射到更高维的特征空间，从而可以有效处理非线性问题，提升模型的泛化能力[73]。核函数可以定义为：

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j) \tag{2-16}$$

中国知网 https://www.cnki.net

（5）K-近邻模型

K-近邻是一种简单直观的监督学习算法，用于解决分类和回归问题。它的基本原理是计算要预测的样本与训练集中所有样本之间的距离，并选择距离最近的 K 个样本作为邻居[74]。对于分类任务，K-近邻使用多数投票来确定要预测的样本的类别；对于回归任务，K-近邻将 K 个样本的平均值作为要预测的样本的预测值。K-近邻算法易于理解和实现，但在处理大规模数据集和高维特征时需要考虑计算开销和内存消耗。通常采用欧氏距离来识别最接近要预测的样本的 k 个样本，即 LP 距离，其定义公式如下：

$$L_p(x_i, x_j) = \left(\sum_{l}^{n} |x_i - x_j|^P \right)^{1/P}$$

$$x_i \in R^n, x_j \in R^n \tag{2-17}$$

$$L_\infty(x_i, x_j) = \max|x_i - x_j| \tag{2-18}$$

其中x_i是第i个特征向量；L_p是 P 范数，当 p = 1 时，它是曼哈顿距离（对应于 L1 范数），当 p = 2 时，它是欧氏距离（对应于 L2 范数）；n是样本量；L_∞无限范数[75]。

（6）多层感知机模型

多层感知机作为一种典型的前馈人工神经网络模型，其层级化结构由输入层、若干隐藏层及输出层构成。该模型采用各隐藏层神经元与相邻层的所有神经与建立权值连接的全连接架构。这种结构通过加权求和与非线性变换完成信息传递：每个神经元接收上一层神经元的加权输入，经偏置项调整后通过非线性激活函数及逆行映射，其数学表达式为：

$$y = \varphi\left(b + \sum_{j=1}^{n} \omega_j \cdot x_j \right) \tag{2-19}$$

其中，x_j是输入信号；y是输出；ω_j是神经元的权重；b是偏差；φ是激活函数[76]。多层感知机能够通过反向传播算法来学习复杂的非线性关系，通过调整权重以最小化损失函数。

该模型通过误差反向传播算法与梯度下降优化方法的协同工作机制实现参数学习。在训练过程中，系统首先通过前向传播计算网络输出，然后基于损失函数对神经网络

中国知网 https://www.cnki.net

权重的偏导数沿负梯度方向调整连接权值，通过这种迭代优化过程，模型能够逐步逼近输入输出间的非线性映射关系。

在污水处理领域，机器学习算法的选择需结合数据规模、特征维度及任务需求权衡。随机森林集成多棵决策树，通过 Bootstrap 采样与随即特征选择增强泛化性，适合高维、非线性数据的水质预测；XGBoost 基于梯度提升框架，通过二阶泰勒展开与正则化实现高效优化，在中小型数据集上表现突出，但计算资源需求较高；LightGBM 采用直方图与叶子生长策略，大幅提升训练速度，适用于大规模数据，但对稀疏数据敏感；支持向量机通过核函数映射处理高维非线性问题，适用于小样本分类与回归，但对参数调优依赖性强；K-近邻依赖距离度量，适用于小规模数据进行分类和回归任务；多层感知机作为基础神经网络，可拟合复杂非线性关系，需充足数据支持，但解释性较差且易陷入局部最优。

中国知网 https://www.cnki.net

第三章 基于机理模型的污水处理系统模拟

3.1 引言

活性污泥模型（Activated Sludge Models, ASMs）作为污水生物处理系统的数字化映射工具，通过整合微生物代谢动力学、物质守恒方程与工艺水力学特征，构建了涵盖碳、氮、磷去除的多为数学模型体系。ASMs 通过定量表征异养菌、硝化菌等微生物代谢、物质转化以及工艺参数之间的动态关系，准确模拟生物反应和污染物去除过程，为污水处理厂工艺的效能评估与优化调控提供理论基础，帮助研究人员对污水处理系统进行有效预测和调控。ASMs 通过揭示系统参数与出水指标间的动态响应关系，已成为污水处理数字化设计与智能化运营的核心决策工具。

Sumo22 是一款基于 ASMs 开发的综合性污水模拟软件，具有用户友好的图形界面，具备强大的模型库、丰富的处理单元、先进的模拟功能和多元化的模型工具。该模拟软件以开源代码的形式将模型、物料守恒定律及反应动力学方程呈现在 Excel 中，使用户可通过界面交互与代码溯源双重途径深入理解参数设定和模型运行机制。此外，Sumo22 还支持根据实际需求对模型进行自定义修改，为用户提供了灵活的模型调整和优化空间。

改良 A^2/O 工艺通过增设预缺氧段与多点回流系统，强化了脱氮除磷的协同效应，但在实际运行中常面临碳源竞争、污泥龄矛盾等复杂问题。本章以改良 A^2/O 工艺为研究对象，Sumo22 软件为模拟平台、使用 $SUMO_2$ 模型构建污水处理厂改良 A^2/O 工艺整体概化模型，首先明确 $SUMO_2$ 模型所需输入进水数据的 COD、N、P 组分细分类别。在此基础上，采用全局敏感性分析方法进行了参数敏感性分析以识别关键参数对污水处理效果的影响。为了确保模型的准确性和实用性，本研究还对模型进行了稳态和动态校准与验证，通过与实际运行数据的对比，验证了模型的预测能力和应用潜力，为污水处理厂的工艺参数优化与智能控制策略开发提供了理论依据和技术支持。

中国知网 https://www.cnki.net

3.2 机理模型的构建

3.2.1 进水水质参数的确定

在活性污泥模型建模过程中，明确进水水质的细分组分至关重要。SUMO$_2$ 按照污染物的存在形式将进水 COD 组分划分为颗粒态 COD 与溶解态 COD，溶解态 COD 又划分为胶体状 COD 和可溶性有机物 COD 其 COD 组分细分划分如图 3-1 所示：

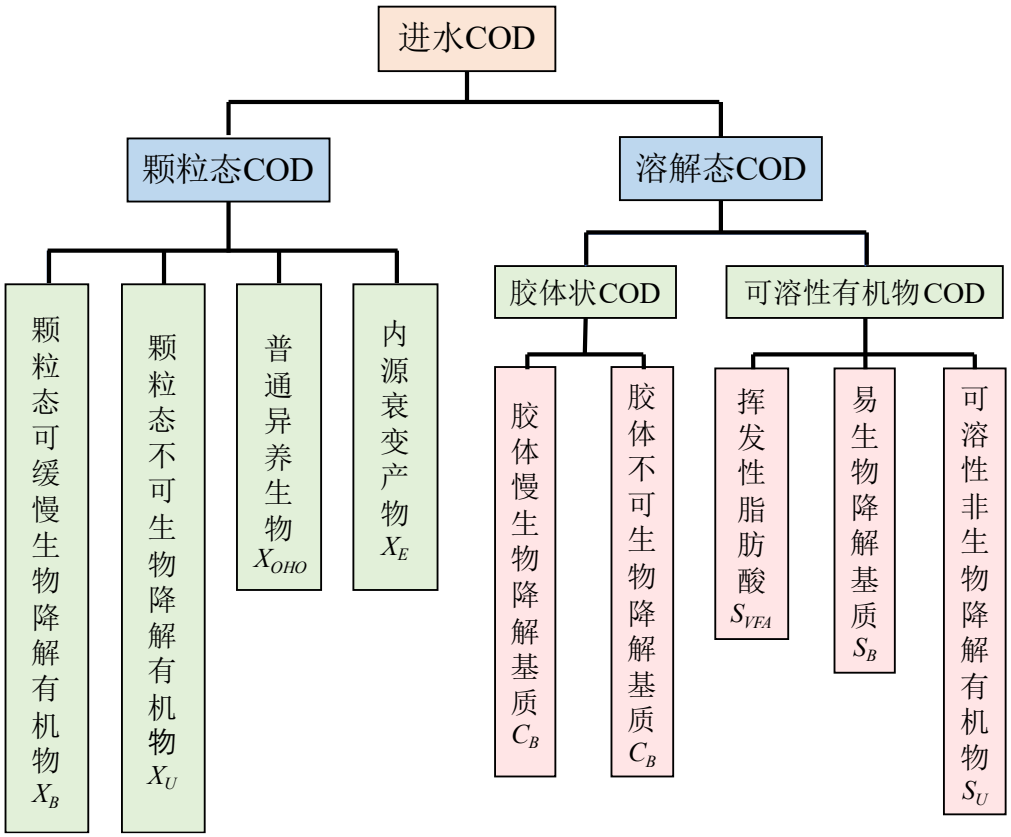


图 3-1 COD 组分树状图

Figure3-1 Dendrogram of COD components

污水处理厂进水中 C、N、P 各细分组分的具体占比以堆叠柱状图的形式展现在图 3-2 中，对于 COD 组分而言，颗粒态 COD 中可缓慢生物降解的颗粒态基质（X_B）占比为 38%，颗粒态不可生物降解有机物（X_U）占比为 14%，溶解态 COD 中胶体慢速生物降解基质（C_B）占比为 13.3%，挥发性脂肪酸（S_{VFA}）占比为 7.5%，易生物降解基质（S_B）占比为 10%，可溶性非生物降解有机物（S_U）占比为 7.5%。对于 N 组分，总氮中氨氮的占比为 53.3%。对于 P 组分，总磷中正磷酸盐的占比为 60.9%。

中国知网 https://www.cnki.net

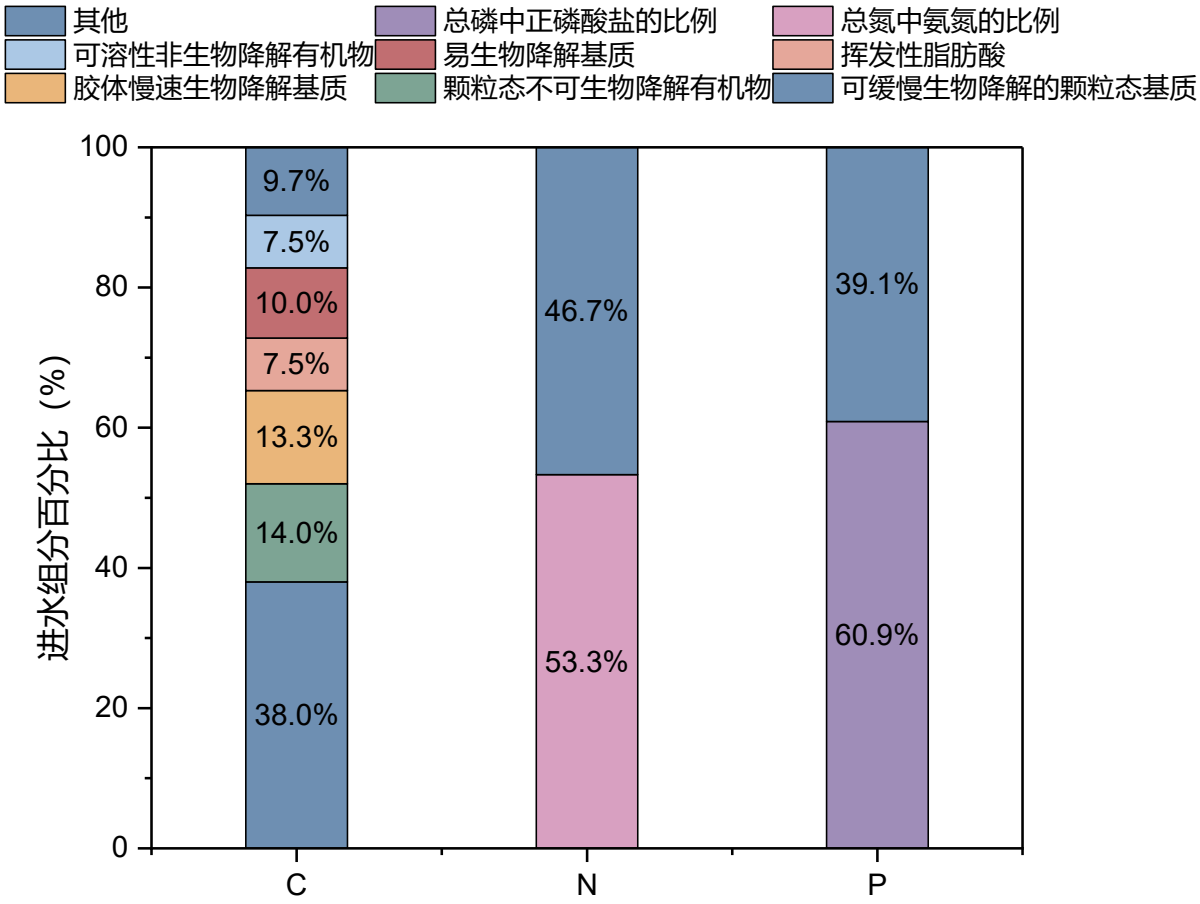


图 3-2 进水组分堆积图

Figure3-2 Stacking diagram of influent components

3.2.2 全流程模型的建立

本论文建模采用的数据来自于广东某污水处理厂，该污水处理厂主体工艺为改良 A^2/O，设计时构筑物均分为两座相同的反应池。如图 3-3 为主体工艺改良 A^2/O 运行示意图，进水首先流经格栅，然后进入曝气沉砂池，然后进入二级处理，流经 A^2/O 和二沉池，在好氧区后端设置混合液内回流泵，使混合液回流至缺氧区前端，内回流比为 200%。在二沉池前端设置除磷药剂（PAC）投加装置，后端设置混合液外回流泵。

中国知网 https://www.cnki.net

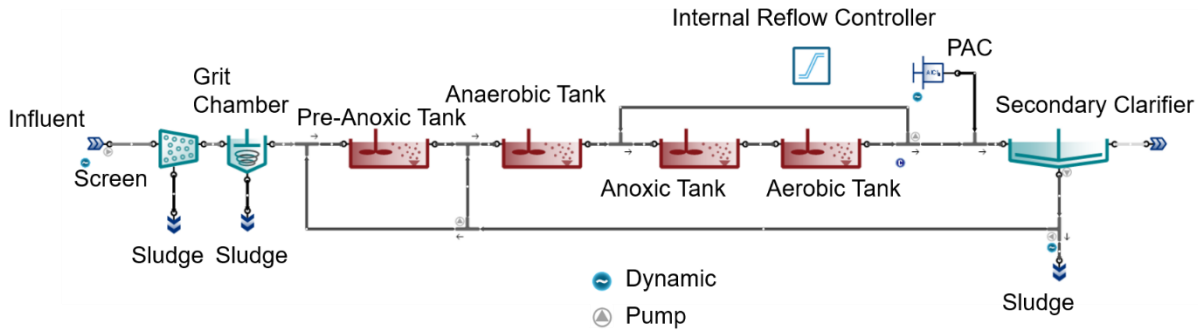


图 3-3 目标污水厂整体概化模型

Figure3-3 Overall generalized model of the target wastewater plant

3.3 机理模型的校准及验证

3.3.1 敏感性分析

活性污泥模型通常比较复杂，涉及大量动力学参数和化学计量学参数，这些参数共同影响模型的预测精度。因此，在模型构建过程中，对关键参数进行筛选并校准在活性污泥模型构建过程中至关重要，但同时也极具挑战性。本文构建的 Sumo2 模型包含众多动力学参数和化学计量学参数，通过合理校准这些参数，能够使建立的模型更准确地反映污水处理系统的实际运行情况。

为了从众多参数中筛选出对模型具有较大影响的参数，采用敏感性分析方法，即在保持其他参数不变的前提下，通过逐个调整目标参数，分析其变化对各出水指标的影响程度，从而确定污水处理系统各出水指标对不同模型参数变化的敏感性。通过敏感性分析计算 Sumo2 模型参数的敏感性系数以量化各参数的重要性，首先在所有参数为初始值X_0的状态下运行模型，模拟得到基准输出值Y_0，之后，逐个将单个参数增加 10%形成扰动值X_i，重新运行模型，模拟得到增加扰动后相应的输出值Y_i，进而根据敏感性分析公式，计算得到敏感性系数，具体的敏感性系数公式如下：

$$RSF = \frac{(Y_i - Y_0)/Y_0}{(X_i - X_0)/X_0} \tag{3-1}$$

式中：RSF—敏感性系数；

Y_0—出水指标初始输出值；

Y_i—出水指标输出值；

中国知网 https://www.cnki.net

X_0—模型参数初始值；

X_i—模型参数调整值；

当|RSF| > 0.1 时，认为该参数的波动对模型出水水质模拟有显著影响，当|RSF| < 0.1 时，认为该参数对模型出水水质模拟影响不大[24]。在进行参数校准时，优先考虑校准影响较大的参数。

根据敏感性分析的结果，筛选出六个对于该模型模拟出水水质结果影响最大的动力学与化学计量学参数，分别为 OHOs 缺氧生长的还原因子（$\eta_{OHO,anox}$）、缺氧条件下容易生物降解基质上的 OHOs 的产率（$Y_{OHO,SB,anox}$）、水解的阿伦尼乌斯系数（$\theta_{q,HYD}$）、NOB 生长的阿伦尼乌斯系数（$\theta_{\mu,NOB}$）、AOBs 的衰变率（b_{AOB}）、AOBs 的最大特定生长速率（μ_{AOB}）。相关参数的敏感性系数如图 3-4 所示。本论文后期针对 Sumo2 模型进行模拟及校准时主要调整以上参数。

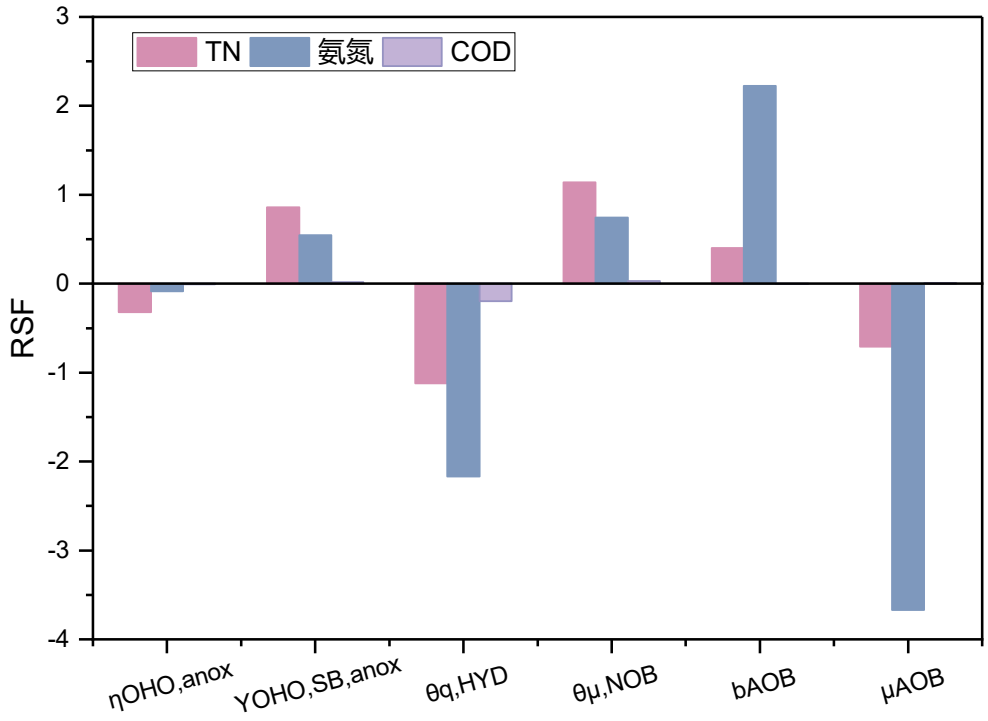


图 3-4 参数敏感性分析结果

Figure3-4 Results of parameter sensitivity analysis

3.3.2 模型稳态模拟校准及验证

稳态模拟是一种常用于污水处理过程建模的方法，其核心思想是在恒定的输入条

中国知网 https://www.cnki.net

件下，通过模型计算模拟系统最终趋于稳定的状态，以预测出水水质。稳态模拟可用于校准动力学及化学计量学参数，使模型在长期稳定运行条件下准确反映污水处理厂的实际情况，为后续动态模拟提供可靠的参数基础。

采用污水处理厂 2018 年 10 月至 2019 年 11 月各月进水水质数据的月平均值作为模型输入，基于长期运行数据对模型参数进行优化调整。考虑到污水处理过程的非线性特征以及环境条件的变化，采用逐月校准的方式对模型参数进行调整，以确保模拟结果与实际运行数据的相对误差尽可能小。在模型参数校准过程中，依据污水处理厂的实际运行数据，通过最小化模拟出水水质与实测值之间的相对误差来调整参数。每月根据当月最新的进水水质情况，在上月参数校准的基础上重新优化模型，以应对进水水质的变化。表 3-1 展示了不同月份稳态模拟优化后的模型参数值。

表 3-1 稳态模拟的每月校准参数值

Table3-1 Monthly calibration parameters values based on steady-state simulation

参数	η OHO,anox	KO2,OHO,AS	μ AOB	fX,BOD5,BODult	θ μ,OHO	θ b,OHO	θ q,SPB
默认值	0.60	0.15	0.90	0.50	1.04	1.03	1.03
2018-10	0.40	0.15	1.30	0.29	1.00	1.15	0.95
2018-11	0.35	0.10	1.35	0.29	1.00	1.15	1.10
2018-12	0.40	0.12	1.65	0.27	1.00	1.15	1.10
2019-01	0.70	0.12	1.65	0.27	1.00	1.15	1.10
2019-02	0.60	0.15	1.45	0.27	0.98	1.15	0.95
2019-03	0.65	0.15	1.60	0.27	0.98	1.15	1.10
2019-04	0.80	0.15	1.45	0.27	0.98	1.15	1.50
2019-05	1.00	0.20	1.00	0.27	1.00	1.15	1.50
2019-06	1.00	0.30	1.10	0.32	1.10	1.15	1.50
2019-07	1.00	0.17	1.10	0.32	1.10	1.15	1.50
2019-08	1.00	0.17	1.50	0.32	1.50	1.15	1.50
2019-09	0.75	0.17	1.70	0.30	1.70	1.10	1.50
2019-10	0.55	0.15	1.30	0.30	1.80	1.03	1.03
2019-11	0.75	0.17	1.70	0.30	1.70	1.10	1.50

稳态模拟的结果如表 3-2 所示，比较了模型计算得到的出水水质与实际监测数据，并分析了模型的相对误差。结果表明，通过逐月校准参数，稳态模拟的出水 COD、TN 和氨氮与实际出水值之间的平均相对误差均控制在 10%以内，说明模型在基于每月进水水质参数的平均值进行稳态模拟时，能够稳定地输出与实际情况相近的结果。此外，稳态模拟时所校准的动力学及化学计量学参数不仅提高了模型对出水水质的预

中国知网 https://www.cnki.net

测能力，还为后续动态模拟提供了可靠的参数校准基础。稳态模拟的成功，说明了该方法可有效反映污水处理厂在不同进水条件下的出水水质的变化趋势，为进一步进行动态模拟和优化运行控制策略奠定了基础。

表 3-2 稳态模拟出水水质模拟值与实际值对比

Table3-2 Comparison of simulated and actual values for steady state simulation of effluent quality

日期	出水-COD			出水-TN			出水-氨氮		
	实测值	预测值	误差	实测值	预测值	误差	实测值	预测值	误差
2018-10	33.69	33.73	0.12%	8.09	7.46	7.87%	0.46	0.48	4.22%
2018-11	37.39	36.07	3.53%	8.43	8.47	0.47 %	0.50	0.53	7.04 %
2018-12	38.01	37.85	0.42%	7.58	7.90	4.25 %	0.24	0.24	0.41 %
2019-01	41.63	39.53	5.05 %	7.46	7.90	5.90 %	0.35	0.33	6.34 %
2019-02	43.05	40.72	5.41 %	6.99	7.51	7.42 %	0.36	0.33	6.62 %
2019-03	35.47	34.54	2.61 %	7.10	7.65	7.86 %	0.25	0.26	5.15 %
2019-04	32.06	32.13	0.21 %	6.86	7.40	7.89 %	0.25	0.24	5.64 %
2019-05	25.02	27.22	8.78 %	6.30	6.62	5.14 %	0.49	0.49	0.10 %
2019-06	21.13	20.44	3.27 %	4.87	5.03	3.25 %	0.40	0.40	0.88 %
2019-07	20.15	21.51	6.76 %	5.11	5.07	0.77 %	0.36	0.39	7.57 %
2019-08	16.86	18.46	9.51 %	4.83	4.99	3.30 %	0.18	0.17	4.80 %
2019-09	21.29	22.55	5.91 %	4.95	4.46	9.88 %	0.30	0.32	4.45 %
2019-10	26.34	27.53	4.51 %	5.33	5.57	4.47 %	0.44	0.43	3.18 %
2019-11	25.93	26.99	4.08 %	6.89	6.36	7.64 %	0.21	0.21	0.91 %

3.3.3 模型动态模拟校准及验证

模型动态模拟划分为参数校准和模型验证两个阶段。在参数校准阶段，基于污水处理厂 340 天内每日进水、出水水质数据及运行数据，对模型动态模拟进行参数校准，使其能够准确模拟污水处理过程的动态变化。在模型验证阶段，采用污水处理厂剩余 86 天的独立数据集（包括每日进水、出水水质数据及运行数据），对已校准的模型进行动态验证，通过对比动态模拟输出值与实测值，并分析其相对误差，以检验模型参数校准的合理性、评估模型在不同运行条件下的适用性和预测能力。本文中选取出水 TN 作为动态模拟的关键出水指标，其动态模拟的参数校准值如表 3-3 所示。

中国知网 https://www.cnki.net

表 3-3 动态模拟参数校准值

Table3-3 Calibration parameters values based on dunamic simulation

参数	RSF	默认值	校准值
OHOs 缺氧生长的还原因子（$\eta_{OHO,anox}$）	-0.32	0.6	0.54
缺氧条件下易生物降解基质上的 OHOs 的产率（$Y_{OHO,SB,anox}$）	0.86	0.54	0.486
水解的阿伦尼乌斯系数（$\theta_{q,HYD}$）	-1.12	1.03	0.927
NOB 生长的阿伦尼乌斯系数（$\theta_{\mu,NOB}$）	1.14	1.06	0.954
AOBs 的衰变率（b_{AOB}）	0.40	0.17	0.136
AOBs 的最大特定生长速率（μ_{AOB}）	-0.71	0.9	1.35

经过参数校准后校准阶段的动态模拟结果如图 3-5 所示，模拟的出水 TN 浓度总体上和污水厂实际值吻合较好。然而，可以观察到模型预测的出水 TN 存在间歇性的峰值，且通过计算得知，校准阶段的平均相对误差为 19.22%，大部分数据的相对误差在 25%以内，但少部分模拟出水 TN 值与实际值误差较大。分析其原因，认为这一现象可能源于进水水质波动较大以及参数校准未能充分适应进水水质的极端变化，从而导致部分时段模拟值与实际值之间的误差较大。

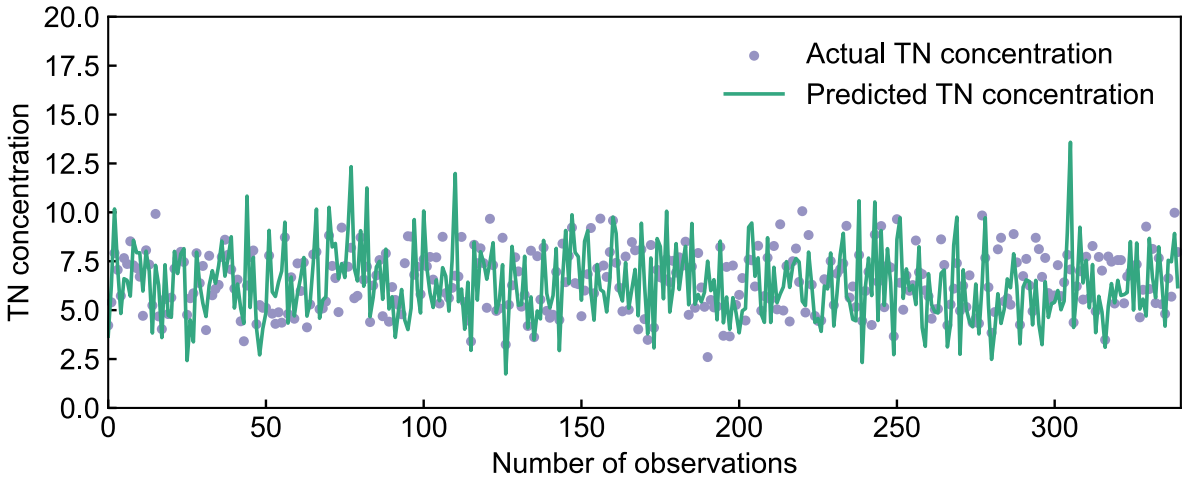


图 3-5 校准阶段动态模拟出水 TN 浓度与实际值对比

Figure3-5 Comparison of dynamic simulated effluent TN concentrations with actual values during the calibration phase

中国知网 https://www.cnki.net

为验证校准阶段参数设定的合理性，采用污水处理厂其余 86 天的数据对模型进行验证，验证结果如图 3-6 所示。在验证阶段，模型基于校准阶段确定的参数进行模拟，以检验该模型是否具有泛化性能。结果显示，模型平均相对误差为 20.10%，与校准阶段相比略高、预测效果略差，但整体上仍可较好地反映污水处理厂出水 TN 浓度的变化趋势。值得注意的是，在校准阶段我们已经对模型参数进行了校准，在验证阶段并未对模型参数进行再校准，而是直接沿用了校准阶段得到的参数值进行模拟，这表明在相同参数条件下模型对实际运行数据具有较好地预测能力。这一结果同时反映出，由于污水处理厂进水水质复杂多变、微生物群落结构处于动态变化状态以及运行参数的不断调整等多重因素的影响，活性污泥模型在实际应用中往往需要持续对动力学参数和化学计量学参数进行动态校准，才能确保模型能准确反映污水处理系统的实际运行情况，提高模拟结果的可靠性与有效性。然而，必须指出的是，活性污泥模型通常涉及众多的动力学参数和化学计量学参数，这些参数之间相互关联、相互影响，其动态校准过程往往依赖于丰富的经验知识，不仅过程复杂且耗时，且校准结果本身存在一定的不确定性，难以完全准确反映所有实际情况。这一现状说明在未来的研究中需要进一步探索更为高效、智能的参数校准方法，以提升活性污泥模型在复杂工程系统中的适用性和准确性。

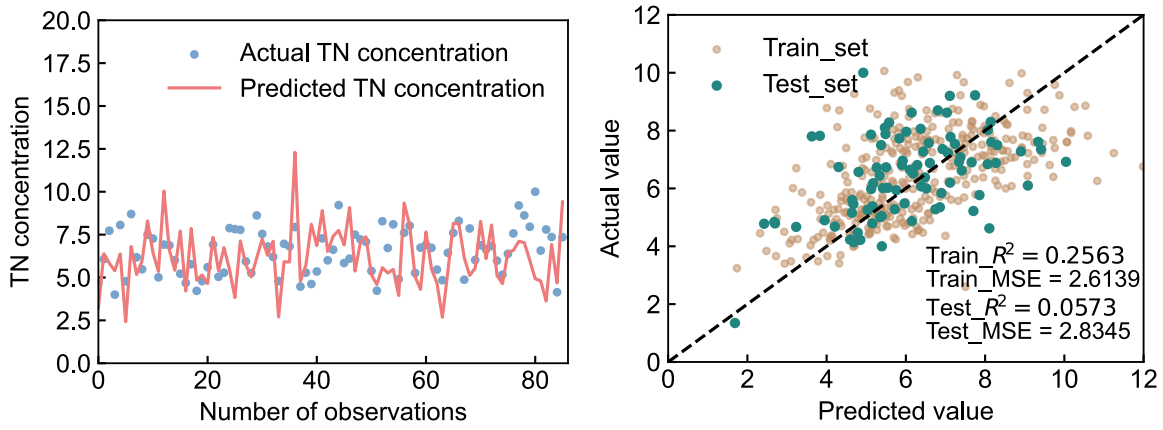


图 3-6 验证阶段动态模拟出水 TN 浓度与实际值对比

Figure3-6 Comparison of TN concentration in dynamically simulated effluent with actual values in the validation phase

根据其他相关文献，大约 20%的平均相对误差被认为是可以接受的[77]。值得注意的是，目前许多关于活性污泥模型的相关研究一般只以相对误差作为模型模拟效能

中国知网 https://www.cnki.net

的评估指标，而几乎没有给出模型模拟值与实际值之间相关性的进一步定量指标[24,78,79]。为了进一步提升污水处理厂模型评估的全面性和可靠性，本文中还计算了决定系数（R^2）作为补充指标，用于衡量模拟值与实际值之间的线性拟合程度。由图 3-5 和图 3-6 可知，该模型在校准阶段的 R^2 为 0.2563，在验证阶段的 R^2 为 0.0573，尽管已建立的模型在相对误差指标上已达到可接受水平，但其较低的 R^2 表明，模型仅能够大致捕捉到污水处理厂出水 TN 浓度的整体变化趋势，但模拟的准确性仍有待进一步提高。

3.4 本章小结

本章基于 Sumo2 模型构建了目标污水处理厂改良 A^2/O 工艺概化模型，明确了 Sumo2 模型相关进水水质各组分的划分，并对模型进行了参数敏感性分析、稳态与动态校准以及模拟验证工作，主要得到以下结论：

（1）通过敏感性分析得出以下几个模型参数对出水 TN 浓度有显著影响：OHOs 缺氧生长的还原因子（$\eta_{OHO,anox}$）、缺氧条件下易生物降解基质上的 OHOs 的产率（$Y_{OHO,SB,anox}$）、水解的阿伦尼乌斯系数（$\theta_{q,HYD}$）、NOB 生长的阿伦尼乌斯系数（$\theta_{\mu,NOB}$）、AOBs 的衰变率（b_{AOB}）、AOBs 的最大特定生长速率（μ_{AOB}）。其中 μ_{AOB} 和 b_{AOB} 共同决定了硝化过程的第一步，即氨氮向亚硝酸盐的转化；$\theta_{\mu,NOB}$ 和 $\theta_{q,HYD}$ 共同影响硝化过程的第二步，即亚硝酸盐转化为硝酸盐；$\eta_{OHO,anox}$ 和 $Y_{OHO,SB,anox}$ 均是影响反硝化过程的关键参数。

（2）经过参数校准后，Sumo2 模型在稳态模拟中，各月出水 COD、TN 和氨氮的模拟值的相对误差均在 10%以下。动态模拟中参数校准阶段出水 TN 的平均相对误差、R^2、MSE 分别为 19.22%、0.2563、2.6139，验证阶段出水 TN 的平均相对误差、R^2、MSE 分别为 20.10%、0.0573、2.8345。上述结果表明，所建立的 Sumo2 模型基本能够反映污水处理厂出水 TN 浓度的变化趋势，但模型准确性仍有待进一步提高。

中国知网 https://www.cnki.net

第四章 基于机器学习的污水处理系统模拟

4.1 引言

传统的活性污泥模型在应对污水处理系统强非线性、多变量耦合特性时存在参数复杂度高、实时预测适应性不足等问题。本章引入数据驱动方法，以污水处理厂出水总氮（TN）为核心控制指标，构建基于机器学习的污水处理模型。TN 作为表征水体富营养化风险的关键参数，其浓度控制效果直接关系到脱氮工艺的稳定性和运行成本。然而，实际运行中 TN 的去除过程涉及硝化、反硝化等多阶段生化反应，且受进水碳氮比、污泥龄、溶解氧等多因素动态耦合影响，传统经验公式难以实现精准预测。为此，本研究采用随机森林（Random Forest, RF）、极端梯度提升树（Extreme Gradient Boosting, XGBoost）、轻量梯度提升机（Light Gradient Boosting Machine, LightGBM）、多层感知机、K-近邻和支持向量机共 6 种经典的机器学习算法，分别构建城市污水处理系统出水 TN 预测模型，以期实现出水 TN 浓度的精准预测。为进一步消除机器学习“黑箱”特性对实际工程应用的制约，本章引入 SHAP（Shapley Additive exPlanations）可解释性算法，量化每个输入特征对预测结果的贡献程度，从而提高模型决策过程的可靠性，为工艺优化提供透明决策化支持。

本章研究数据来源于广东某城市污水处理厂 2018 年 10 月至 2019 年 11 月的运行记录，经过异常值提出、缺失值插补等数据预处理后，共构建 426 组有效样本数据集。其中进水特征数据包括进水流量、pH、COD、BOD、SS、TP、NH_4^+-N、TN，运行特征数据包括日均污泥饼量、污泥含水率、污泥浓度、污泥回流量、溶解氧含量、PAC 投加量、PAM 投加量。数据集按照 8：2 的比例被划分为训练集和测试集，并采用 Min-max 标准化方法消除数据量纲及数据尺度的差异。模型开发基于 Anaconda 环境下的 Jupyter Notebook 平台，依托 Python 编程语言，使用 Numpy、Pandas 库完成数据预处理，利用 Scikit-Learn、XGBoost、Optuna、Shap 等第三方库实现算法构建、超参数优化及可解释性分析，最终通过 Matplotlib 可视化工具输出特征重要性排序与 SHAP 依赖图。

中国知网 https://www.cnki.net

4.2 数据预处理

污水处理厂的数据通常众多且复杂，时常因为传感器精度和工作环境等因素导致出现噪声数据，或由于设备故障、人为疏忽等因素出现缺失数据或错误数据。此外，由于污水处理过程涉及的参数众多，且各个特征的尺度和数据分布通常存在较大差异，这进一步增加了数据分析和建模的难度。而作为一种数据驱动模型，机器学习模型的性能与数据质量密切相关，数据中的噪声、缺失值以及尺度不一致都会对模型的训练效果和预测性能产生负面影响。因此，为了有效提高模型的准确性、稳定性和泛化能力，在进行模型构建之前对原始数据进行数据预处理是必不可少的[80]。通过合理的数据清洗、标准化、缺失值处理等方法，可以有效提升数据的质量，为后续的建模和分析提供帮助。

4.2.1 数据清洗

通过相关公式计算得到各特征间的斯皮尔曼相关系数矩阵图如图 4-1 所示。如图 4-1，在 23 个进水、出水及运行特征与标签中，出水 TN 与进水氨氮、出水 COD、出水 TP 之间的相关系数均超过 0.6 为强相关。其中，出水 TN 与进水氨氮的相关系数为 0.69，与出水 COD、出水 TP 之间的相关系数分别为 0.72、0.71。另外，出水 TN 与污泥回流量之间的相关系数为-0.76，说明出水 TN 与污泥回流量之间呈负相关。此外，出水 TN 与进水流量的相关系数为-0.56，与进水 BOD 的相关系数为 0.51，与出水流量的相关系数为-0.56，与出水 BOD 间的相关系数为 0.55，与泥饼含水率之间的相关系数为-0.55。出水 TN 与其他特征之间的相关系数的绝对值均小于 0.50，相关性不明显。总体来说，现有的特征与出水 TN 之间的相关性明显，可以用于构建数据集进行机器学习的模拟。

中国知网 https://www.cnki.net

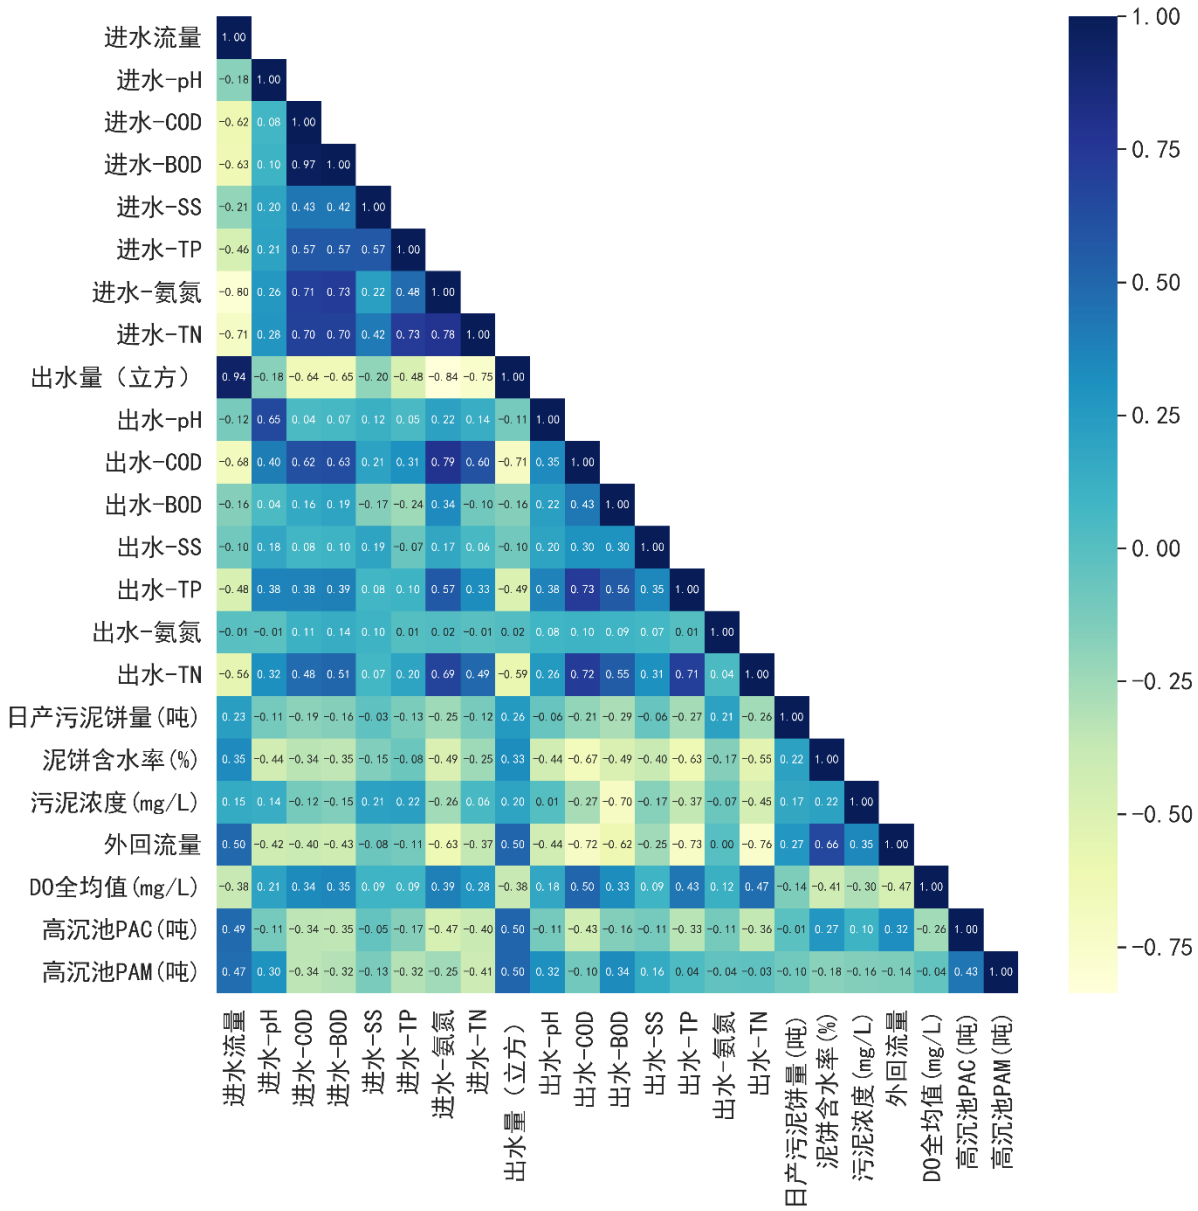


图 4-1 特征之间斯皮尔曼相关系数矩阵图

Figure4-1 Matrix plot of Spearman correlation coefficients between features

污水处理厂原始监测数据指标多、频率高、时间长，通常会由于传感器故障或数据输入错误等因素存在大量异常值，这些异常值如果没有被及时识别和剔除，会导致模型训练过程中出现错误，从而影响预测结果的准确性。因此，采用四分位距法（Interquartile Range, IQR）识别原始数据中的异常值并将其全部替换为空值，后续采用插值法进行填充再供后续建模使用。经过异常值筛选和插值法填充后的数据各输入特征量纲不同，数值差异较大，若不进行标准化，量纲较大的特征可能会在模型训练中占据主导地位，导致模型不能准确学习到输入特征与预测目标之间的映射关系。因

中国知网 https://www.cnki.net

此，在模型训练前对数据集做标准化处理，将不同量纲的数据统一转换为[0,1]区间。具体的标准化方法见 2.4.1 节。

4.2.2 数据集划分

本文中按照 8：2 的比例将经过预处理的数据集随机划分为两个互斥的数据集，即训练集和测试集，其中 80%的数据作为训练集用于训练机器学习模型，其余 20%的数据作为测试集用于检验模型拟合效果。

4.3 机器学习模型搭建

4.3.1 模型训练及超参数调优

在建立模型之后，需要对模型进行训练，其目标是模型算法通过学习训练集数据中潜在的规律和模式，使得模型预测输出与真实结果尽可能接近，从而实现对未知数据的准确预测。这一过程本质上是一个优化问题，通过最小化损失函数，模型不断更新自身以提升性能。

模型的性能通常受多个超参数的影响，然而这些超参数是在模型开始训练前设置的固定值，而不是通过训练集数据学习得到的。因此，在模型训练过程中，需要根据拟合效果不断调节模型超参数，最终找到合适的超参数组合，即“调参”过程。通常来讲，常用的调参方法有网格搜索和随机搜索。网格搜索首先预定义每个超参数的取值范围或者离散值，之后通过逐一尝试所有可能的超参数组合来寻找最优的超参数配置。网格搜索全面且精准，但计算成本高，对于超参数数量较多的模型效率极低。随机搜索是从给定的超参数空间中随机选择一定数量的超参数组合进行训练和评估，直到达到预定的评估次数或时间限制。随机搜索高效但结果不保证全局最优，有可能错过最优的超参数组合从而降低模型拟合效果。

Optuna 是一种基于贝叶斯优化的自动化调参框架，它通过构建一个代理模型来评估超参数的性能，并采用逐步优化的策略根据已有评估结果来推测最有可能改善模型性能的超参数组合，从而减少试错，提高调参效率。此外，Optuna 还能够灵活调整每个超参数的搜索范围，并通过动态调整搜索策略来专注于具有较大潜力的超参数区域，从而减少不必要的计算[81]。TPE（Tree-structured Parzen Estimator）作为

中国知网 https://www.cnki.net

Optuna 调参框架的核心优化算法，是一种基于贝叶斯优化的算法，TPE 通过构建两个概率分布，分别描述“较优”超参数组合和“较差”超参数组合，然后根据这些分布逐步指导搜索过程，选择最有可能改善模型性能的超参数组合。

4.3.2 模型预测结果分析

（1）XGBoost

使用 Optuna 自动化调参框架对 XGBoost 模型的 n_estimators、max_depth、learning_rate 等参数进行调优，最优参数组合如表 4-1 所示，模型在此条件下对训练集数据的拟合效果最好。

表 4-1 XGBoost 回归预测模型参数表

Table4-1 Table of parameters for XGBoost regression prediction model

参数名称	参数含义	取值
n_estimators	决策树的数量	350
max_depth	决策树的最大深度	5
learning_rate	学习率	0.0416
lambda_l2	L2 正则化	0.0
alpha	L1 正则化	3.9651
colsample_bytree	列采样率	0.5
subsample	子采样率	0.7
min_child_weight	子节点最小权重	1.0

该模型的训练效果及其在测试集上的预测效果如图 4-2 所示。由图 4-2 可知，XGBoost 模型训练集的 MSE 为 0.1245，R^2 为 0.9462，表明该模型已从训练数据中学习到潜在的规律及模式，较好地拟合了训练集中各输入特征与出水 TN 的关系。而 XGBoost 模型测试集的 MSE 为 0.3892，R^2 为 0.7856，尽管与训练集相比预测效果略差，但较高的 R^2 和较低的 MSE 仍可较好地预测出水 TN 的变化趋势。

中国知网 https://www.cnki.net

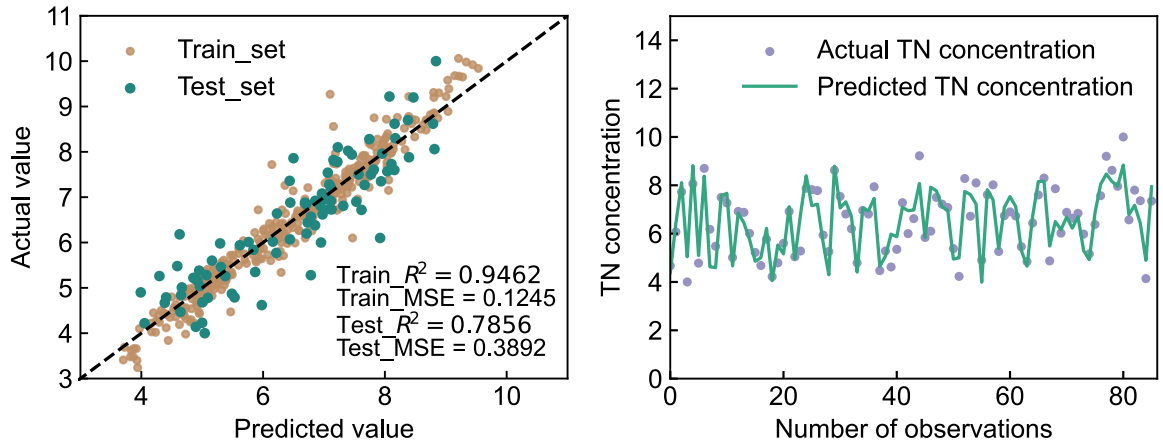


图 4-2 XGBoost 模型预测效果

Figure4-2 Prediction performance evaluation of the XGBoost model

（2）随机森林

使用 Optuna 自动化调参框架对随机森林模型的 n_estimators、max_depth、min_samples_split、min_samples_leaf 等参数进行调优，最优参数组合如表 4-2 所示，模型在此条件下对训练集数据的拟合效果最好。

表 4-2 随机森林回归预测模型参数表

Table4-2 Table of parameters for Random Forest regression prediction model

参数名称	参数含义	取值
n_estimators	决策树的数量	24
max_depth	决策树的最大深度	232
min_samples_split	节点分裂所需最小样本数	3
min_samples_leaf	叶节点所需最小样本数	2
max_features	特征的最大数量	3
bootstrap	是否采用自助法采样	“False”

训练完成后，使用最优参数组合重新构建随机森林模型，并使用测试集数据对出水 TN 进行预测，该模型的训练效果及其在测试集上的预测效果如图 4-3 所示。由图 4-3 可知，随机森林模型训练集的 MSE 为 0.0422，R^2 为 0.9818，表明该模型已从训练数据中学习到潜在的规律及模式，较好地拟合了训练集中各输入特征与出水 TN 的关系。而随机森林模型测试集的 MSE 为 0.3770，R^2 为 0.7924，尽管与训练集相比预测效果略差，但较高的 R^2 和较低的 MSE 仍可较好地预测出水 TN 的变化趋势。且与

中国知网 https://www.cnki.net

XGBoost 模型相比，随机森林模型在训练集和测试集上的表现更优。

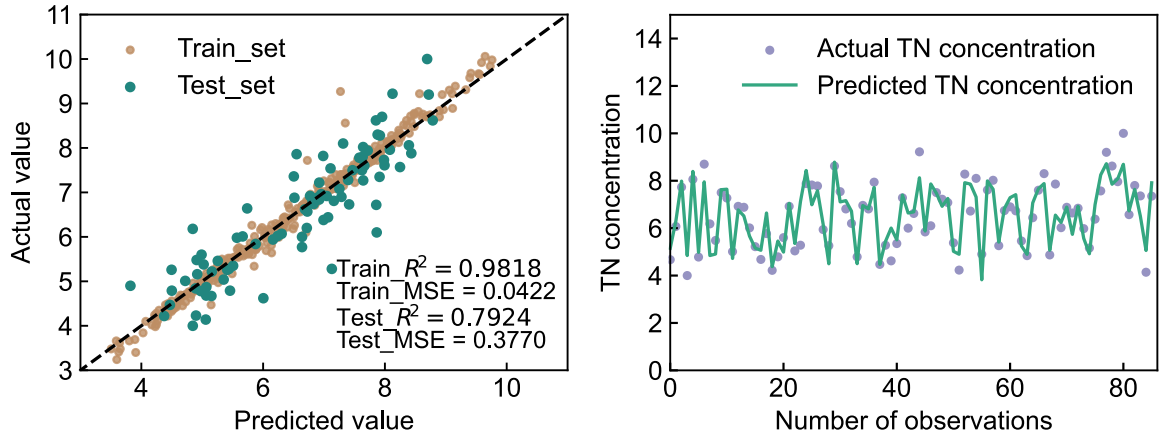


图 4-3 随机森林预测效果

Figure4-3 Prediction performance evaluation of the Random Forest model

（3）LightGBM

使用 Optuna 自动化调参框架对 LightGBM 模型的 n_estimators、max_depth、min_data_in_leaf、num_leaves 等参数进行调优，最优参数组合如表 4-3 所示，模型在此条件下对训练集数据的拟合效果最好。

表 4-3 LightGBM 回归预测模型参数表

Table4-3 Table of parameters for LightGBM regression prediction model

参数名称	参数含义	取值
n_estimators	决策树的数量	110
max_depth	决策树的最大深度	116
min_data_in_leaf	叶子节点上的最小数据数	23
num_leaves	叶子节点数	342
learning_rate	学习率	0.147957
lambda_l2	L2 正则化项	10

训练完成后，使用最优参数组合重新构建 LightGBM 模型，并使用测试集数据对出水 TN 进行预测，该模型的训练效果及其在测试集上的预测效果如图 4-4 所示。由图 4-4 可知，LightGBM 模型训练集的 MSE 为 0.0659，R^2 为 0.9715，表明该模型已从训练数据中学习到潜在的规律及模式，较好地拟合了训练集中各输入特征与出水 TN 的关系。而 LightGBM 模型测试集的 MSE 为 0.4109，R^2 为 0.7737，与训练集相

中国知网 https://www.cnki.net

比预测效果略差，且与前述模型相比，LightGBM 模型的预测效果略差于 XGBoost 与随机森林，但较高的 R^2 和较低的 MSE 仍可较好地预测出水 TN 的变化趋势。

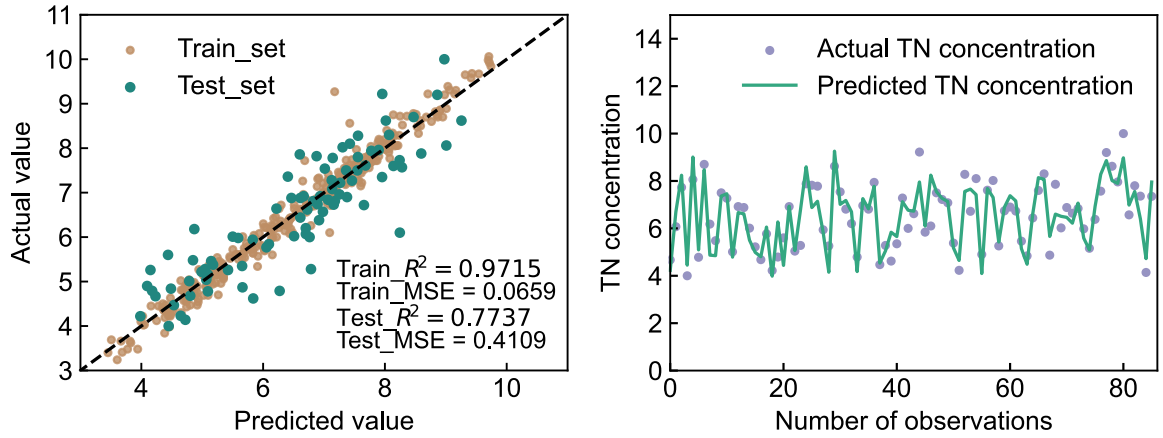


图 4-4 LightGBM 模型预测效果

Figure4-4 Prediction performance evaluation of the LightGBM model

（4）支持向量机

支持向量机回归模型搭建完成后，使用 Optuna 超参数调优框架对其惩罚系数 C、核函数 kernel、epsilon 等参数进行调整。调参结果表明当 C=1.021、kernel 为“rbf”、epsilon=0.0586、gamma=0.9319 时，模型拟合训练集数据的效果最好，该模型最优参数组合如表 4-4 所示。

表 4-4 支持向量机回归预测模型参数表

Table4-4 Table of parameters for Support vector machine regression prediction model

参数名称	参数含义	取值
C	惩罚系数	1.0210
epsilon	距离误差	0.0586
kernel	核函数	“rbf”
gamma	核函数的系数	0.9319

训练完成后，使用最优参数组合重新构建支持向量机模型，并使用测试集数据对出水 TN 进行预测，该模型的训练效果及其在测试集上的预测效果如图 4-5 所示。由图 4-5 可知，支持向量机模型训练集的 MSE 为 0.0059，R^2 为 0.8579，表明该模型已从训练数据中学习到潜在的规律及模式，较好地拟合了训练集中各输入特征与出水 TN 的关系。而支持向量机模型测试集的 MSE 为 0.0065，R^2 为 0.8017，与训练集相

中国知网 https://www.cnki.net

比预测效果略差，但较高的 R^2 和较低的 MSE 仍可较好地预测出水 TN 的变化趋势。

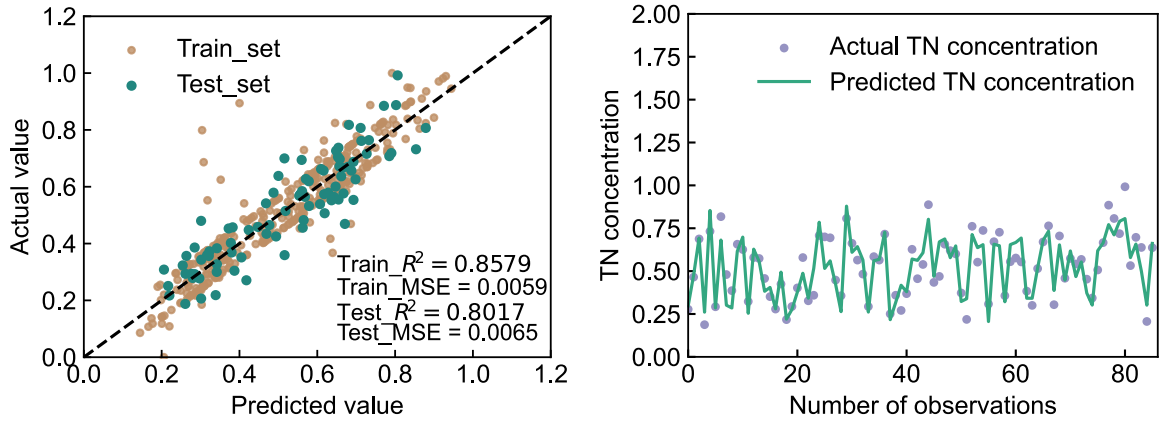


图 4-5 支持向量机预测效果

Figure4-5 Prediction performance evaluation of the Support vector machine model

（5）K-近邻

K-近邻模型搭建完成后，使用 Optuna 超参数调优框架对其 n_neighbors、weighbors、metric 等参数进行调整。调参结果表明当 n_neighbors=8、weighbors 为“distance”、metric 为“manhattan”时，模型拟合训练集数据的效果最好，该模型最优参数组合如表 4-5 所示。

表 4-5 K-近邻回归预测模型参数表

Table4-5 Table of parameters for K-nearest neighbor regression prediction model

参数名称	参数含义	取值
n_neighbors	邻居数量	8
weighbors	权重	“distance”
metric	距离度量方法	“manhattan”

训练完成后，使用最优参数组合重新构建 K-近邻模型，并使用测试集数据对出水 TN 进行预测，该模型的训练效果及其在测试集上的预测效果如图 4-6 所示。由图 4-6 可知，K-近邻模型训练集的 MSE 为 0.0094，R^2 为 0.7747，表明该模型已从训练数据中学习到潜在的规律及模式，较好地拟合了训练集中各输入特征与出水 TN 的关系。而 K-近邻模型测试集的 MSE 为 0.0095，R^2 为 0.7082，与训练集相比预测效果略差，但较高的 R^2 和较低的 MSE 仍可较好地预测出水 TN 的变化趋势。

中国知网 https://www.cnki.net

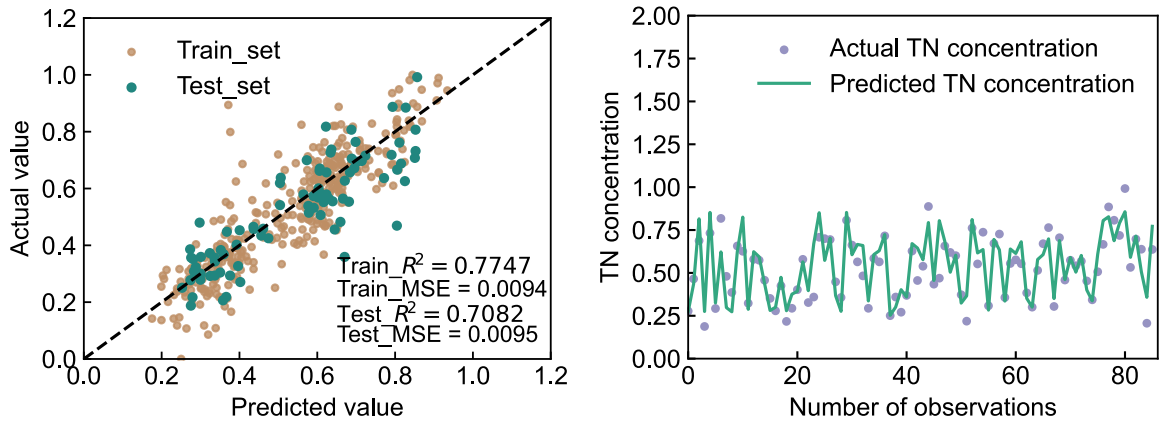


图 4-6 K-近邻预测效果

Figure4-6 Prediction performance evaluation of the K-nearest neighbor model

（6）多层感知机

多层感知机模型搭建完成后，使用 Optuna 超参数调优框架对其 learning_rate_init、activation、隐藏层数、神经元数量等参数进行调整。调参结果表明，当多层感知机模型隐藏层数为 3，神经元数量为 60、45、200，learning_rate_init=0.0351，激活函数为 Relu，max_iter=1800 时，模型拟合训练集数据的效果最好，该模型最优参数组合如表 4-6 所示。

表 4-6 多层感知机回归预测模型参数表

Table4-6 Table of parameters for multilayer perceptron regression prediction model

参数名称	参数含义	取值
learning_rate_init	学习率	0.0351
first_layer_neurons	第一层神经元数量	60
second_layer_neurons	第二层神经元数量	45
third_layer_neurons	第三层神经元数量	200
activation	激活函数	“relu”
max_iter	最大迭代次数	1800

训练完成后，使用最优参数组合重新构建多层感知机模型，并使用测试集数据对出水 TN 进行预测，该模型的训练效果及其在测试集上的预测效果如图 4-7 所示。由图 4-7 可知，多层感知机模型训练集的 MSE 为 0.0106，R^2 为 0.7452，表明该模型已从训练数据中学习到潜在的规律及模式，较好地拟合了训练集中各输入特征与出水

中国知网 https://www.cnki.net

TN 的关系。而多层感知机模型测试集的 MSE 为 0.0083，R^2 为 0.7448，与训练集相比预测效果略差，但较高的 R^2 和较低的 MSE 仍可较好地预测出水 TN 的变化趋势。

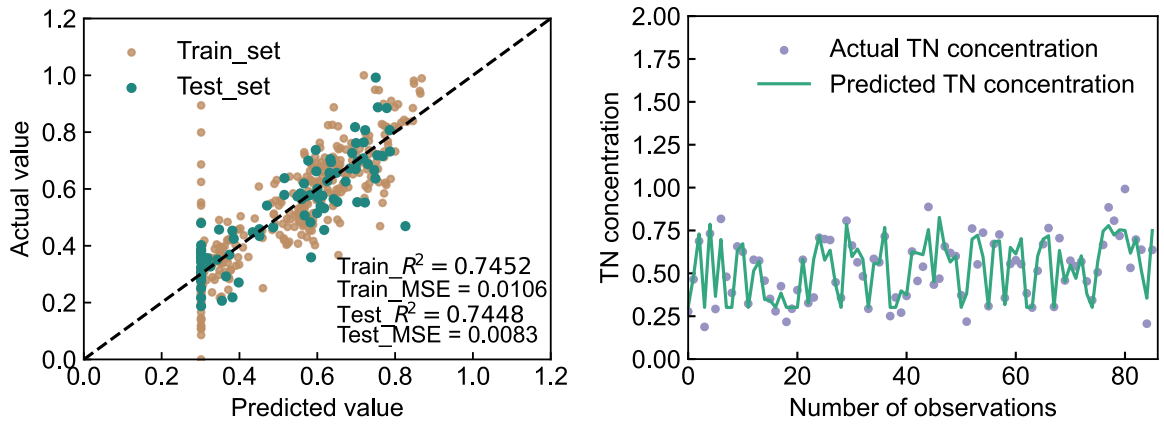


图 4-7 多层感知机预测效果

Figure4-7 Prediction performance evaluation of the multilayer perceptron model

（7）各模型预测性能对比

各模型预测性能总结如表 4-7 所示。

表 4-7 各模型预测结果对比

Table4-7 Comparison of prediction performance of different models

Model	Train_set			Test_set		
	MRE(%)	MSE	R^2	MRE(%)	MSE	R^2
XGBoost	3.94	0.1245	0.9462	7.89	0.3892	0.7856
Random Forest	1.94	0.0422	0.9818	7.50	0.3770	0.7924
LightGBM	2.91	0.0659	0.9715	7.99	0.4109	0.7737
SVM	12.59	0.0059	0.8579	13.77	0.0065	0.8017
KNN	17.97	0.0094	0.7747	15.87	0.0095	0.7025
MLP	18.62	0.0106	0.7452	14.81	0.0083	0.7448

在与机器学习相关的其他研究中，R^2 值为 0.6~1.0 之间被认为预测值于实际值间存在较强的相关性[82]。故总体来说，本研究所构建的六种机器学习模型在训练集和测试集上都表现出较高的 R^2 和较低的 MSE。对比所有模型可知，基于决策树的算法（XGBoost、Random Forest、LightGBM）预测性能最佳，支持向量机、K-近邻、多层感知机次之。尽管测试集的预测效果与训练集相比略差，但在测试集上表现出较高的 R^2 和较低的 MSE 证明了机器学习预测的准确性。

中国知网 https://www.cnki.net

为了有效和全面地评估以上机器学习模型地有效性和预测性能，还引入了相对误差（RE）作为评估指标，各模型在测试集上的 RE 分布如图 4-8 所示。从图 4-8 可以看出，XGBoost、Random Forest、LightGBM 的误差基本分布在 10%以下，只有少数误差大于 20%。而 SVR、K-近邻和多层感知机的相对误差普遍高于前三个模型，并且有一些误差较大，这也反映了这三个模型的预测稳定性不如前三个模型。

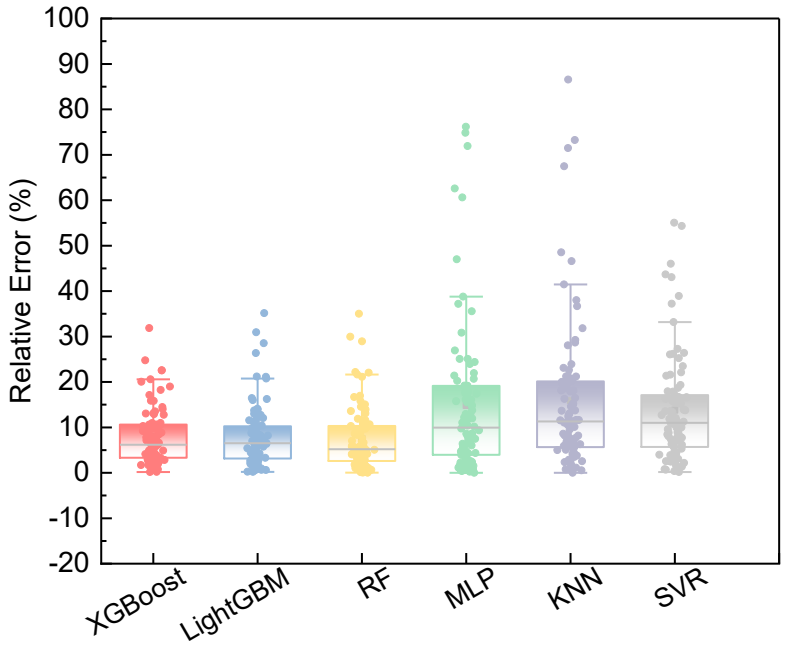


图 4-8 各机器学习模型在测试集上的相对误差结果

Figure4-8 Relative error results of the optimized machine learning models on the test sets.

综合考虑上述评估指标，随机森林在测试集上表现出较高的 R^2 和较低的 MSE，分别为 0.7924、0.3770，且其平均相对误差为 7.50%。因此，本研究认为随机森林模型为这六个机器学习模型中表现最好的模型，可供后续研究进行分析。

4.4 机器学习模型可解释性分析

根据前文的分析可知，构建的机器学习模型成功地拟合了进水水量水质、运行参数与出水 TN 之间的复杂关系，能够实现对污水处理厂出水 TN 的精准预测。然而，机器学习模型的黑盒性质限制了它解释潜在预测过程的能力，这阻碍了其在废水处理领域的进一步实际应用。因此，需要开发可靠的可解释性工具为模型的决策过程提供

中国知网 https://www.cnki.net

更清晰可信的说明。SHAP（Shapley Additive explanations）可解释分析算法是一个基于合作博弈论的强大工具，能够为每一个特征分配一个对模型输出的贡献值，提供全局和局部可解释分析[83]。通过这种方式，SHAP 能够与机器学习模型结合以有效解析模型内在机制，帮助工作人员对机器学习模型的预测结果进行分析并给出可靠的决策。

本节以随机森林模型为基础模型，采用 SHAP 算法分析各输入特征对出水 TN 浓度的影响。

4.4.1 SHAP 算法原理

SHAP 算法最初由 Lundberg 和 Lee 提出，用于解释机器学习模型的输出，该算法的核心思想是基于合作博弈论中的 Shapley 值，用来衡量每个特征对模型预测的贡献[83]。SHAP 的基本原理是，通过计算每个特征的边际贡献值来量化每个特征对预测结果的贡献，从而确定每个特征的影响力。该方法的核心是计算每个特征的 Shapley 值。具体来说，对于包含 n 个特征的模型，Shapley 值是通过计算所有可能特征的子集的边际贡献来确定的。Shapley 值计算公式如下：

$$\emptyset_i = \sum_{S \subseteq N \backslash \{i\}} \frac{|S|!\,(|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)] \tag{4-1}$$

其中，$\emptyset_i$表示特征i的 Shapley 值，N是所有特征的集合，$S \subseteq N \backslash \{i\}$表示所有不包含特征$i$的特征子集，$|S|$是子集$S$中的特征个数，$f(S)$是模型对给定特征子集的预测值，$f(S \cup \{i\}) - f(S)$表示在特征子集$S$的基础上加入特征$i$后，模型预测结果的变化，即边际贡献。

根据已构建的模型和样本数据，SHAP 值会考虑该样本数据在所有可能的特征组合中，某个特征加入时对模型输出的变化。最终，将所有可能排列的贡献加权平均得到每个特征的 Shapley 值。通过 Shapley 值的计算，SHAP 算法提供了一种公平的方式来分配特征对预测的贡献，避免了某个特征对结果的影响被高估或低估，能够帮助工作人员更好地理解模型的预测过程，增加预测结果的可靠性。值得一提的是，SHAP 算法不依赖于特定的机器学习模型，而是建立在博弈论的框架上，着眼于计算每个特征对于模型预测结果的贡献，能够解释任何机器学习模型，并且解释结果具有通用性。

在实际应用中，为了提高算法计算效率和适应不同模型的需求，SHAP 算法有

中国知网 https://www.cnki.net

TreeSHAP、DeepSHAP、KernelSHAP 等几种不同的实现方法和变种。其中 TreeSHAP 是专为树模型设计的优化算法，它通过利用树模型的结构和规则分裂来高效计算 Shapley 值，考虑到本研究进行 SHAP 算法分析时以随机森林为基础模型，因此选用 TreeSHAP 算法供后续进行分析。

4.4.2 关键特征解析

在构建了机器学习模型之后，我们使用 SHAP 算法对随机森林模型进行计算分析。SHAP 算法通过计算模型输入特征的 Shapley 值，可分析各项输入特征对出水 TN 的影响程度。各参数的贡献度如图 4-9 所示，横坐标为 Shapley 值，纵坐标为模型输入特征。由图 4-9 可知，SHAP 汇总图展示了每个输入参数的特征值范围对于预测结果的影响程度，而 SHAP 值的正负则代表某一输入特征对预测结果是正向影响或是负向影响。从图中可以看出，回流污泥量、进水 NO_3^--N、进水 NO_4^+-N、进水流量和 MLSS 在预测出水 TN 浓度方面表现出较高的重要性。回流污泥量是预测出水 TN 浓度的最关键变量，这与硝化反硝化脱氮过程的概念一致。回流污泥量和进水流量与出水 TN 浓度呈负相关，这意味着回流污泥量和进水流量的增加会降低出水 TN 浓度；相反，进水 NO_3^-N 和进水 NO_4^+N 的与出水 TN 浓度呈正相关，表明进水 NO_3^-N 和进水 NO_4^+N 浓度的增加会增大出水 TN 浓度。

中国知网 https://www.cnki.net

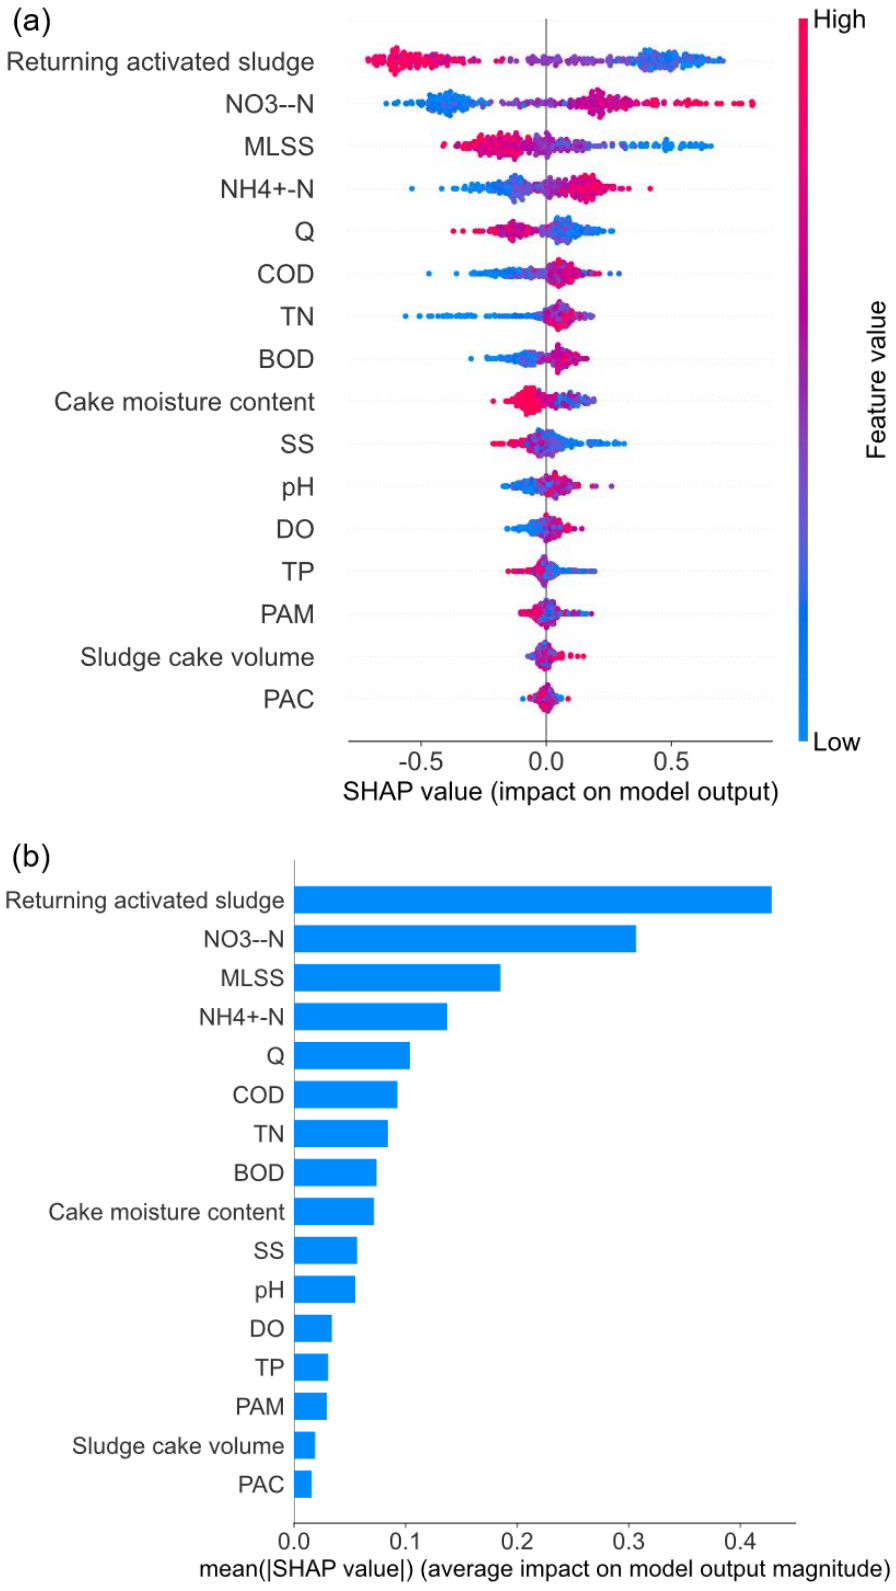


图 4-9 变量可解释分析：(a) SHAP 汇总图；(b) SHAP 绝对值均值柱状图

Figure4-9 Variable interpretability analysis: (a) SHAP summary plot; (b) Bar chart of mean absolute value of SHAP

此外，如图 4-10 所示，通过将 SHAP 值与部份依赖图的概念相结合，可以分析

中国知网 https://www.cnki.net

两个特征之间的交互作用及其对目标值预测的影响。

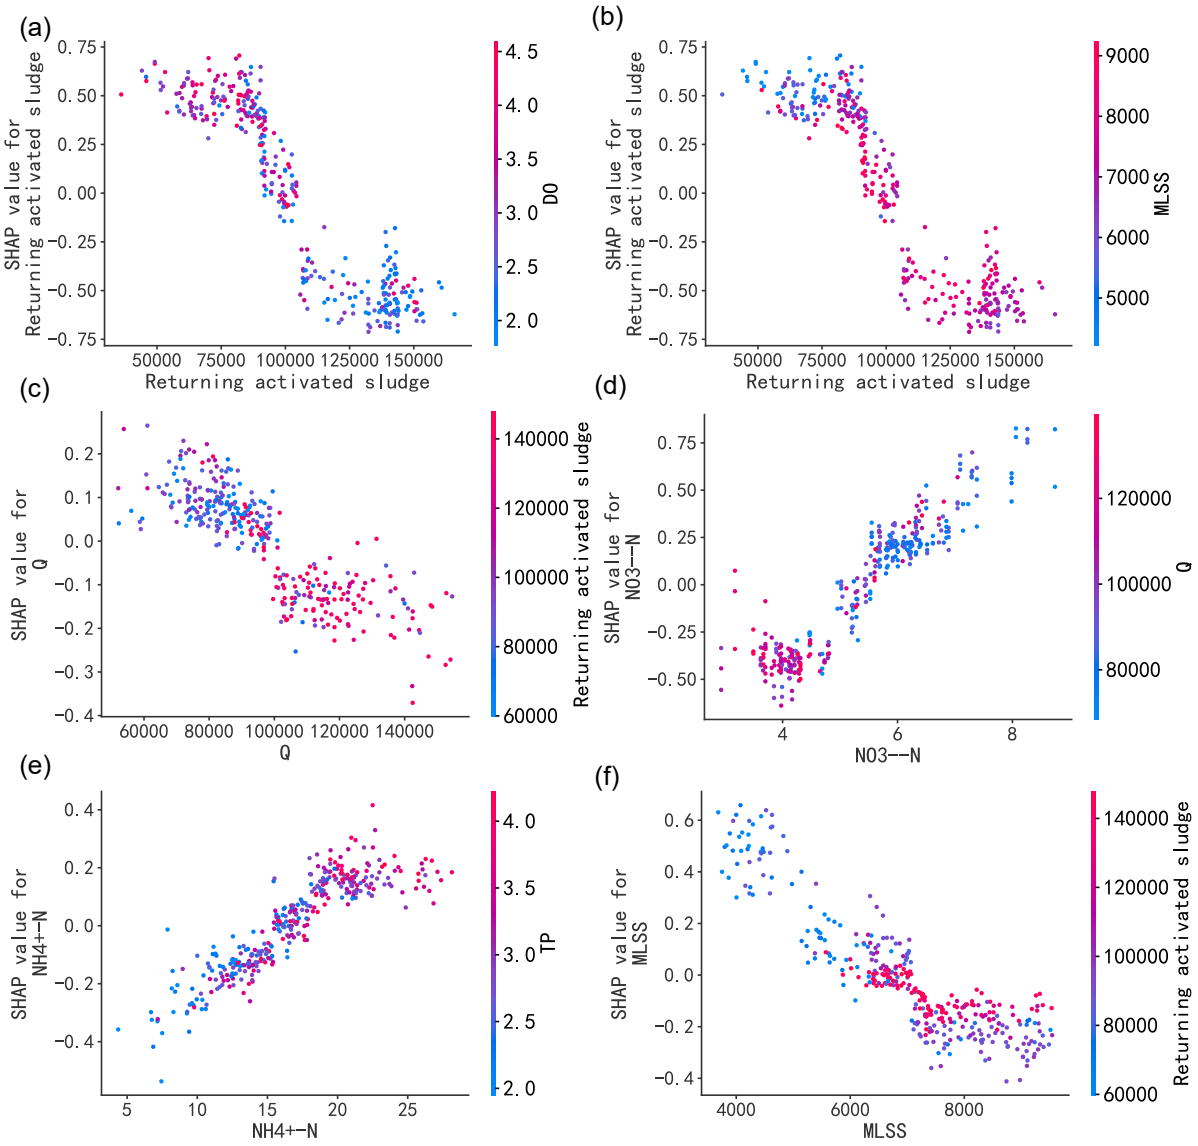


图 4-10 机器学习中重要特征间的交互。（a）至（f）分别表示回流污泥量与溶解氧、回流污泥量与 MLSS、进水流量与回流污泥量、进水 NO_3^-N 与进水流量、进水 NO_4^-N 与进水 TP、MLSS 与回流污泥量的 SHAP 依赖图

Figure4-10 Interactions between important features in machine learning. (a) to (f) represent the SHAP dependence plots for returning activated sludge with DO, returning activated sludge with MLSS, influent Q with returning activated sludge, influent NO_3^--N with influent Q, influent NO_4^+-N with influent TP and MLSS with returning activated sludge.

由图 4-10 (a) 和 (b) 可知，随着回流污泥量的增加，SHAP 值由正值变为负值；

中国知网 https://www.cnki.net

当回流污泥量从 75000m³/d 增加到 120000 m³/d 时，SHAP 值的下降更为明显。这表明，在 75000m³/d 至 120000 m³/d 的范围内，增加回流污泥量能够减少排泥量，增大污泥龄，从而有助于维持硝化和反硝化细菌的数量，增强硝化和反硝化进程，实现减低出水 TN 浓度。在较高的溶解氧浓度下，增加回流污泥量会促进硝化过程，从而进一步降低出水 TN 浓度。当 MLSS 浓度较高时，回流污泥量的适度增加将导致 SHAP 值逐渐从正值降为负值，从而有助于降低出水 TN 浓度。然而，过高的回流污泥量将导致 SHAP 值呈正向趋势。由图 4-10 (c)可知，当进水流量增加时，回流污泥量通常也会增加。这是因为增加回流污泥量可以有效维持系统内活性污泥浓度和处理负荷的平衡，确保污水处理系统能够应对高流量条件下负荷冲击，从而提高脱氮效率，稳定出水水质。图 4-10 (d)和图 4-10 (e)表明，随着进水 NO_3^-N 和进水 NO_4^+N 浓度的增加，SHAP 值逐渐升高。进水氮浓度的增加意味着废水处理系统的总氮负荷增加，系统对硝化和反硝化过程的要求更高，这会导致氮去除不完全，导致污水处理系统出水中的氮浓度升高。根据图 4-10 (f)可知，随着 MLSS 的增加，SHAP 值逐渐降低，表明较高的 MLSS 导致模型预测的总氮浓度较低。在 MLSS 较高的情况下，回流污泥量通常较高，而 MLSS 较低时，回流污泥量通常较低。较高的 MLSS 可以增加硝化和反硝化细菌的数量，从而提高硝化和反硝化过程的效率。此外，更高的 MLSS 可以更有效地利用有机碳源，增强系统的反硝化能力并提高总氮去除率。

4.5 本章小结

本章以污水处理厂出水 TN 为主要预测目标，使用 6 种经典的机器学习算法分别构建了城市污水处理系统模型，并引入 SHAP 算法对已构建模型进行事后解释，得出以下主要结论：

（1）以上 6 种机器学习模型的训练集和测试集的 R^2 均大于 0.7，MSE 均低于 0.45，MRE 均小于 20%，表明已建立的 6 种机器学习模型均精准预测了污水处理厂的出水 TN 浓度，误差均控制在合理的区间内。且机器学习模型在预测污水处理厂的出水 TN 方面与机理模型相比精准度更高。

（2）随机森林模型在这 6 种机器学习模型种表现出最佳性能和最低的误差，其 R^2=0.7924、MSE=0.3770、MRE=7.50%，表明该模型可在有限实时数据条件下实现出

中国知网 https://www.cnki.net

水 TN 的精准预测，能够为后续污水处理厂优化运行策略提供有效指导。

（3）采用 SHAP 算法解析影响污水处理厂出水 TN 的特征，发现在该数据集中回流污泥量、进水 NO_3^-N、进水 NO_4^-N、进水流量和 MLSS 在预测出水 TN 浓度方面表现出较高的重要性。

中国知网 https://www.cnki.net

第五章 污水处理厂出水总氮影响因素分析及优化控制

5.1 引言

作为污水处理过程的关键控制指标，出水 TN 浓度的精准预测与优化控制直接关系到污水处理厂的运行效能与出水水质的稳定达标。前文构建的污水处理厂模型能够成功拟合了进水水量水质参数、运行参数与出水 TN 浓度之间的复杂关系，实现了对出水 TN 浓度的精准预测。

在此基础上，本章进一步将污泥回流量、好氧区溶解氧、内回流比作为核心调控参数，系统研究其对出水 TN 浓度的影响，并探索降低出水 TN 浓度的最优控制参数。同时，针对污水处理过程中的能耗问题，并进行了能耗分析计算，以期在尽可能降低出水 TN 浓度的前提下，最大程度上使能耗降低。

5.2 响应面法耦合 ASM 模型优化脱氮效能

5.2.1 模型参数设定及因素水平设计

模拟试验以污水处理厂 2019 年 11 月的月均进出水水质为对象，主要进水水质参数如下：进水流量为 82183 m^3/d、pH 为 7.24、COD 为 302.53 mg/L、TN 为 32.53 mg/L、TP 为 3.77 mg/L，PAC 投加量设置为 3980 kg/d，外回流量为 100409 m^3/d，内回流比设置为 200%。

以出水 TN 浓度为指标，选择好氧区溶解氧浓度、内回流比、外回流比这三个影响因素，设计并进行响应面优化试验，求得最优工艺参数组合。使用 Design-Expert 13 软件进行响应面优化设计及后续分析。影响因素水平设计如表 5-1 所示：

表 5-1 响应面实验因素水平及编码

Table5-1 Response surface experiment factor levels and coding

因素	编码	水平		
		-1	0	1
好氧区溶解氧（mg/L）	A	1	2.5	4
内回流比（%）	B	50	200	300
外回流比（%）	C	30	70	120

中国知网 https://www.cnki.net

其中外回流比为污泥回流量与进水量的比值，二者在本质上是等同的。

5.2.2 响应面模型拟合及其显著性分析

基于响应面 Box-Behnken 设计了 17 组不同的试验场景，以探究好氧区溶解氧、内回流比和外回流比对出水 TN 浓度的影响。首先，利用前文已建立的 Sumo2 模型对各场景中给定的试验条件进行模拟，获得出水 TN 浓度的预测值；随后，采用响应面法对模拟数据集进行分析，构建出水 TN 浓度与操作参数间的定量关系模型，并通过模型优化从而确定最佳参数。响应面模拟试验设计及出水 TN 模拟结果如表 5-2 所示：

表 5-2 响应面模拟试验设计及结果

Table5-2 Response surface simulation test design and results

Std	场景	好氧区溶解氧（mg/L）	内回流比（%）	外回流比（%）	出水 TN 浓度（mg/L）
12	1	2.5	300	100	10.9
2	2	4	50	65	5.62
17	3	2.5	175	65	5.13
4	4	4	300	65	5.61
8	5	4	175	100	10.84
5	6	1	175	30	7.01
7	7	1	175	100	8.24
10	8	2.5	300	30	9.09
15	9	2.5	175	65	5.13
1	10	1	50	65	3.86
13	11	2.5	175	65	5.13
11	12	2.5	50	100	10.78
9	13	2.5	50	30	9.57
16	14	2.5	175	65	5.13
3	15	1	300	65	3.73
6	16	4	175	30	9.64
14	17	2.5	175	65	5.13

为探究各影响因素对出水 TN 浓度的影响，采用响应面法构建线性、二次及三次

中国知网 https://www.cnki.net

多项式模型，并通过显著性检验与拟合优度指标筛选得出二次多项式模型为最优模型。该二次多项式模型的方差分析结果如表 5-3 所示，模型 F 值为 223.59，且 P 值 <0.0001，表明该二次多项式模型极显著，较好地描述了各因素与响应值之间的关系。A、B 和 C 的 P 值均小于 0.05，表明它们对出水 TN 浓度有显著影响。

表 5-3 二次多项式模型方差分析结果

Table5-3 Analysis of variance results for the quadratic polynomial model

方差来源	平方和	自由度	均方	F 值	P 值	显著性
模型	105.09	9	11.68	223.59	< 0.0001	significant
A-A	9.83	1	9.83	188.31	< 0.0001	
B-B	0.0313	1	0.0313	0.5984	0.4645	
C-C	3.71	1	3.71	71.09	< 0.0001	
AB	0.0036	1	0.0036	0.0689	0.8005	
AC	0.0002	1	0.0002	0.0043	0.9495	
BC	0.0900	1	0.0900	1.72	0.2307	
A^2	2.62	1	2.62	50.16	0.0002	
B^2	0.5571	1	0.5571	10.67	0.0137	
C^2	88.76	1	88.76	1699.49	< 0.0001	
残差	0.3656	7	0.0522			
总和	105.46	16				

模型出水 TN 浓度与各因素的相关性的二次多项式模型可以表示为：$TN = 16.8983 + 2.47323A - 0.011277B - 0.473413C + 0.00016AB - 0.000143AC + 0.000034BC - 0.350556A^2 + 0.000023B^2 + 0.003748C^2$。该二次多项式模型的 Predicted R^2 为 0.9445，Adjusted R^2 为 0.9921，二者差异仅为 0.0475，远小于 0.2，表明该模型对新数据的预测能力与对现有数据的拟合度高度一致，模型极具有回归性，反映了该二次多项式模型可靠地描述了污水处理厂的出水 TN 浓度。

5.2.3 响应面优化结果分析

根据响应面模拟试验结果及响应曲线方程可绘制出方程的响应曲面图，见图 5-1。图 5-1(a)和图 5-1(c)表明，外回流比分别与溶解氧、内回流比的交互作用都很显著，说明外回流量对出水 TN 浓度的影响程度很大，这与 4.4 节的结论一致。随着外回流

中国知网 https://www.cnki.net

比的增加，出水总氮浓度呈现先降低后增加的趋势。这表明在特定范围内，增加外回流量有助于降低出水总氮浓度，但持续增加可能会导致过度曝气，反硝化作用被抑制，从而导致出水 TN 浓度升高。出水 TN 浓度随内回流比的增大呈现缓慢降低的趋势。图 5-1 (b) 表明内回流比与溶解氧的交互作用不显著。

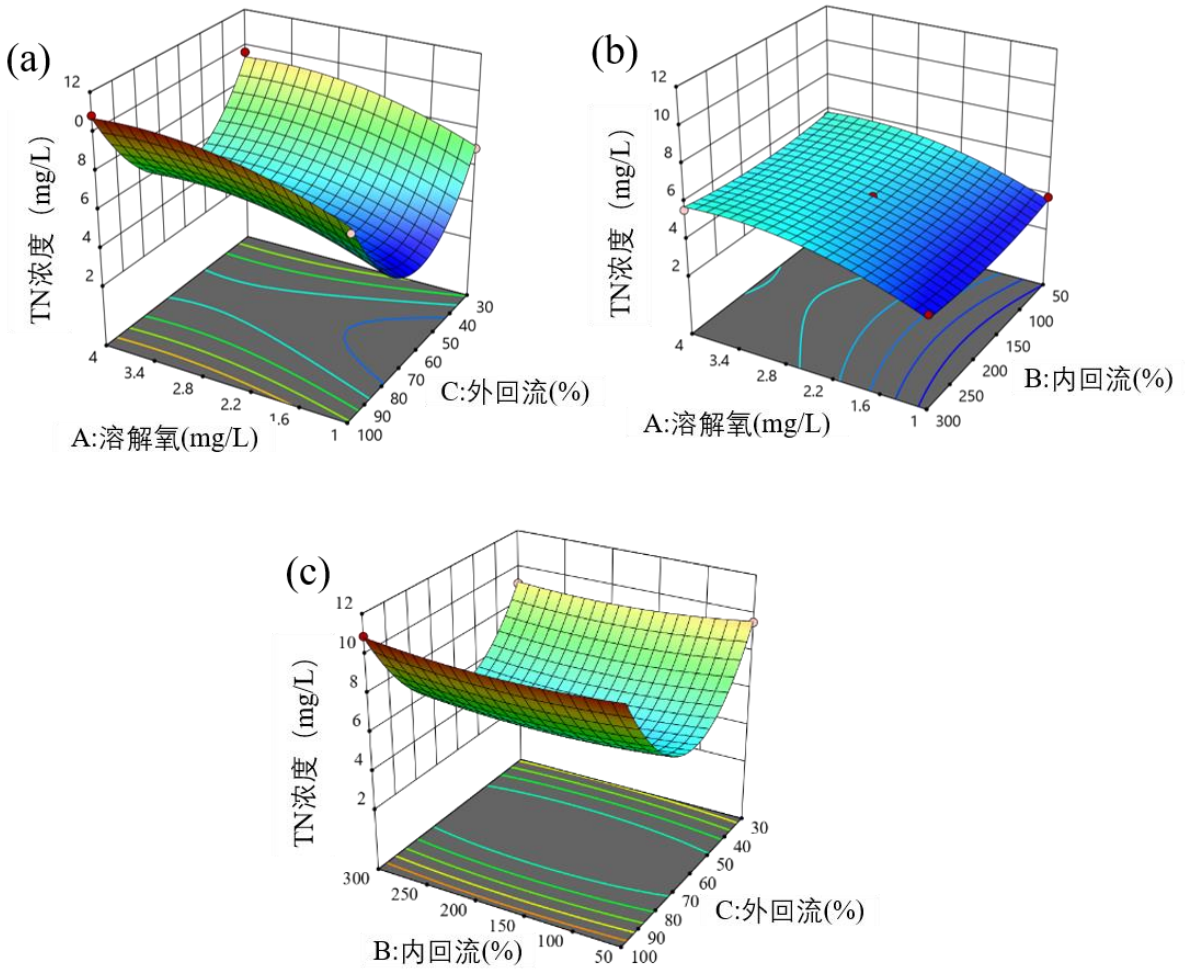


图 5-1 基于响应面分析变量对出水总氮浓度的影响

Figure5-1 Effect of respon surface analysis based variables on effluent total nitrogen concentration

根据响应面试验及分析结果，得出该污水处理厂降低出水 TN 浓度的最佳参数为：溶解氧为 1.125 mg/L，内回流比为 255 mg/L ，外回流比为 65%。在这种情况下出水 TN 去处理率可达到 89.14%，此时，通过模拟可得出最佳出水 TN 浓度为 3.533 mg/L，与前文已建立的模型模拟的出水 TN 浓度为 3.947 mg/L 相比，采用最佳参数运行时出水 TN 浓度可降低约 10.49%。

中国知网 https://www.cnki.net

5.3 基于强化学习的污水处理系统多目标优化分析

5.2 节是以污水处理厂 2019 年 11 月的月均进出水水质为对象，以降低出水 TN 浓度为目标探究最佳控制参数。本节以污水处理厂 2018 年 10 月份至 2019 年 12 月份连续进出水水质参数及运行参数为对象，以降低出水 TN 浓度和降低能耗为目标，进行多目标优化分析。

5.3.1 双延迟深度确定性策略梯度算法（TD3）

双延迟深度确定性策略梯度算法（Twin Delayed Deep Deterministic Policy Gradient, TD3）是一种针对连续控制任务设计的深度强化学习算法，其核心思想是通过改进深度确定性策略梯度算法（DDPG）的不足，解决价值函数过估计和策略训练不稳定的问题[84]。TD3 算法通过引入三个关键技术——双重 Q 学习（Double Q-Learning）、延迟策略更新（Delayed Policy Updates）和目标策略平滑正则化（Target Policy Smoothing Regularization），显著提升了算法在高维连续动作空间中的稳定性和收敛性能。

在传统的 DDPG 算法中，由于采用自举（Bootstrapping）方式更新 Critic 网络，估计误差容易积累，造成 Q 值系统性高估，进而使策略网络过早陷入局部最优解。TD3 通过构建两个独立的 Critic 网络，在计算目标 Q 值时选取两个网络中的较小值作为更新目标值，从而有效抑制了 Q 值的过估计现象。这一双重 Q 学习机制借鉴了离散动作空间算法中的 Double DQN 思想，但在连续动作空间中需结合确定性策略的特点进行适配。此外，TD3 采用延迟策略更新的策略，即 Critic 网络的更新频率高于 Actor 网络。具体而言，Critic 网络每完成若干次参数更新后，才对 Actor 网络进行一次优化。这种设计缓解了策略网络因价值函数估计不准确而导致的振荡问题，使得策略改进过程更加平稳。为进一步提升算法的稳定性，TD3 在目标策略网络生成动作时引入了平滑正则化机制。具体来说，当计算目标 Q 值时，算法会在目标策略网络的输出动作上添加高斯噪声，并通过裁剪（Clipping）操作限制噪声幅度，从而生成一个更加平滑且稳健的目标动作。这一正则化方法有效缓解了因函数近似误差导致的策略退化风险，使得 Critic 网络对动作变化的评估更具鲁棒性。综上所述，TD3 通过多项结构性改进，在不显著增加计算负担的前提下，有效提升了算法在复杂动态环境

中国知网 https://www.cnki.net

下的表现，已成为解决连续控制问题的重要工具之一。

5.3.2 污水处理系统的多目标优化架构建立

本节以出水质量指数（EQI）、运行成本指数（OCI）为评价指标研究分析污水处理过程的多目标优化问题。这类非线性的多目标优化问题可被描述为：

$$Minimize\ f = (EQI, OCI)$$

$$Subject\ to\ Dim \tag{5-1}$$

$$Dim(\text{决策变量}) = (\text{溶解氧，污泥回流量，} PAC)$$

其中，出水质量指数以出水 TN 为指标，运行成本指数主要包括曝气能耗、泵送能耗和混合能耗。如图 5-2 所示，出水 TN 及能耗的多目标优化控制架构是基于 TD3 强化学习算法及前文已构建的随机森林模型构建的。由图 5-2 可知，强化学习 TD3 算法通过智能体不断地执行给定动作，并于环境进行交互，智能体通过感知所处环境的状态以及获取环境对执行的动作的反馈，来指导下一步更好的动作，从而获得最大的收益。

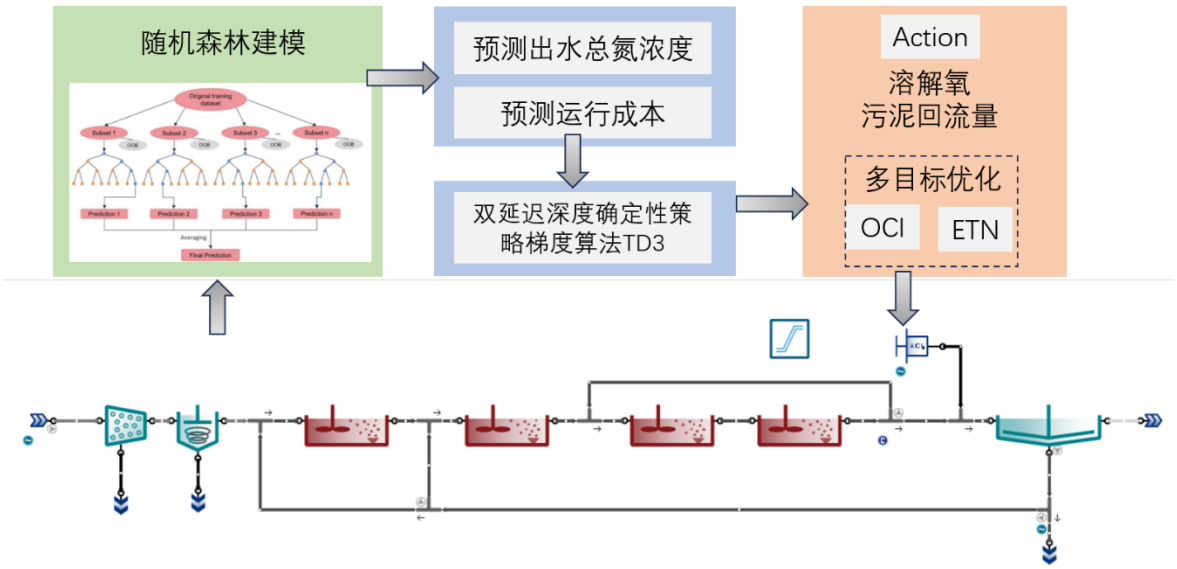


图 5-2 多目标优化架构

Figure5-2 Multi objective optimization architecture

根据强化学习算法的逻辑原理，本研究中的“Agent”为应用了 TD3 强化学习算法的控制系统，将污泥回流量、溶解氧含量作为“Action”，而前文已构建的随机森林模型作为“Agent”的运行交互环境，“State”即是该污水处理系统在某一时刻的具

中国知网 https://www.cnki.net

体情况，出水 TN 浓度、曝气能耗、泵送能耗及混合能耗作为“Agent”调控得到的“Reward”。在该污水处理系统多目标优化控制架构中，“Agent”基于实时进水及运行参数，动态调整污泥回流量和溶解氧浓度，并根据环境对该动作的反馈来不断优化下一步的动作。系统通过评估“Reward”，最终将获得最佳“Reward”的污泥回流量和溶解氧含量确定为当前进水水质参数条件下的最优控制策略。各参数具体设置如下：

（1）“Action”设置

选择污泥回流量与溶解氧浓度作为“Action”。该污水处理厂的回流污泥量处于 32062 m^3/d 至 178182 m^3/d 之间，溶解氧浓度处于 0.36 mg/L 至 37.62 mg/L 之间。污泥回流量与溶解氧浓度在该区间内的有限数组组合构成该多目标优化系统的“Action”集合。

（2）环境设置

环境是一个广泛的交互系统，由应用了 TD3 强化学习算法的控制系统与已构建的随机森林模型共同构成的。由第四章研究结论可知，随机森林模型可在有限实时数据条件下实现出水 TN 的精准预测，能够为后续污水处理厂优化运行策略提供有效指导。在环境中，智能体通过观察“State”、选择“Action”、获取“Reward”，不断学习如何在当前情况下做出更好的决策。

（3）“Reward”设置

综合考虑出水水质达标与能耗控制目标，“Reward”依据出水质量指数（EQI）和运行成本指数（OCI）进行计算。其中出水质量指数与所选出水指标及其排放限值有关，在本节中选择出水 TN 为主要控制指标，运行成本指数主要包括曝气能耗、泵送能耗和混合能耗：

$$OCI = AE + PE + ME \tag{5-2}$$

其中AE为曝气能耗，具体计算公式为：

$$AE = \frac{DO_{sat}}{1.8 \times 1000} V_{CAST} K_{L\alpha} \tag{5-3}$$

其中，DO_{sat}为饱和溶解氧浓度，V_{CAST}为曝气池体积，$K_{L\alpha}$为氧传递系数。

PE为泵送能耗，具体计算公式为：

$$PE = 0.004 \times Q_{IMLR} + 0.008 \times Q_{RAS} + 0.05 \times Q_{WAS} \tag{5-4}$$

其中，Q_{IMLR}为内回流量，Q_{RAS}为污泥回流量，Q_{WAS}为剩余污泥排放量。

中国知网 https://www.cnki.net

ME为混合能耗，具体计算公式为：

$$ME = 24 \times \sum_{CSTR=1}^{n} 0.005 \times V_{CSTR} \tag{5-5}$$

“Reward”具体计算公式如下所示：

$$Reward = \begin{cases} -\left(\mathrm{EQI} + \dfrac{OCI}{1000}\right), if\ TN < 6 \\ -\left[10 \times (EQI - 6) + \left(\dfrac{OCI}{1000}\right)\right], if\ TN \geq 6 \end{cases} \tag{5-6}$$

结合该污水处理厂的实际运行情况，将出水 TN 的控制目标设定为 6 mg/L，并设定相应的惩罚机制，设定出水 TN 的惩罚系数为 10，当出水 TN 浓度每超出目标值 1mg/L，惩罚项增加 10，使得 TN 超出目标值时的奖励值大幅下降，从而更严格地约束出水 TN 浓度。

5.3.3 多目标优化结果分析

选取该污水处理厂 2018 年 10 月份至 2019 年 12 月份进水水质水量参数及运行参数进行多目标优化模拟调控，探究降低出水 TN 浓度、节能降耗作用效果。

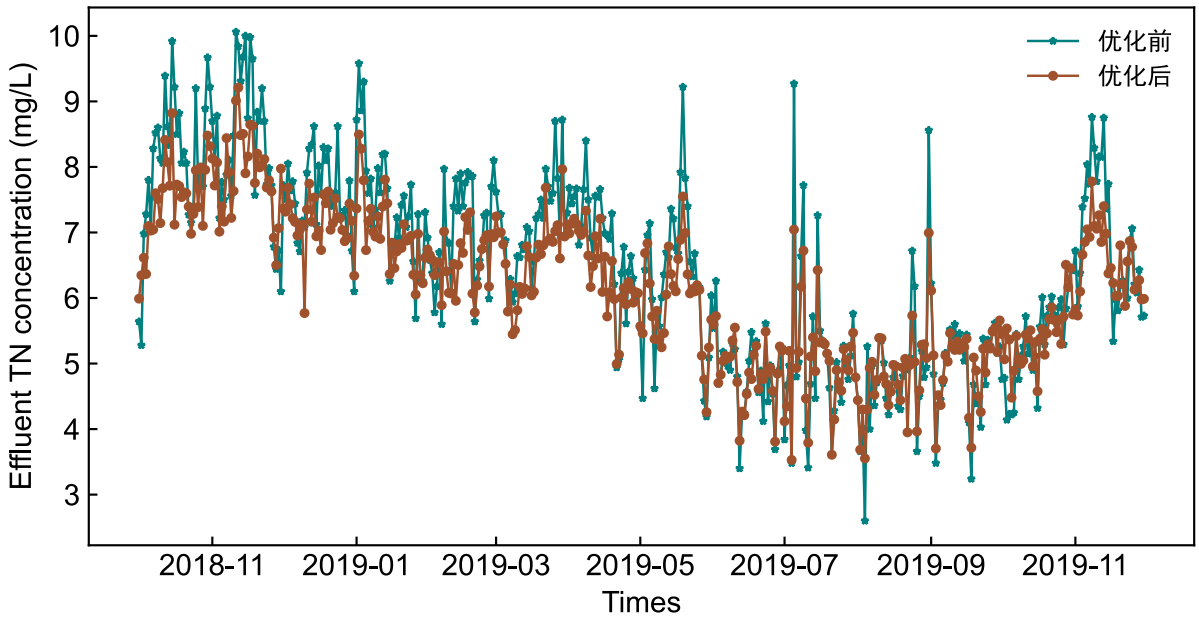


图 5-3 模拟调控前后出水 TN 浓度对比

Figure5-3 Comparison of effluent TN concentration before and after simulated regulation

中国知网 https://www.cnki.net

该污水厂 2018 年 10 月份至 2019 年 12 月份的模拟调控前后的出水 TN 浓度变化情况如图 5-3 所示。由图 5-3 可知，进行模拟调控前，该污水处理厂 2018 年 10 月份至 2019 年 12 月份平均出水 TN 浓度为 6.48 mg/L，最高出水 TN 浓度为 11.76 mg/L，标准差为 1.51 mg/L，可以看出进行模拟调控前的出水 TN 波动较为剧烈。而经该方法模拟调控后，该污水处理厂 2018 年 10 月份至 2019 年 12 月份出水 TN 平均浓度仅为 6.20 mg/L，同比下降约 4.46%，标准差 1.14 mg/L，同比降低约 24.5%，波动幅度明显减弱。

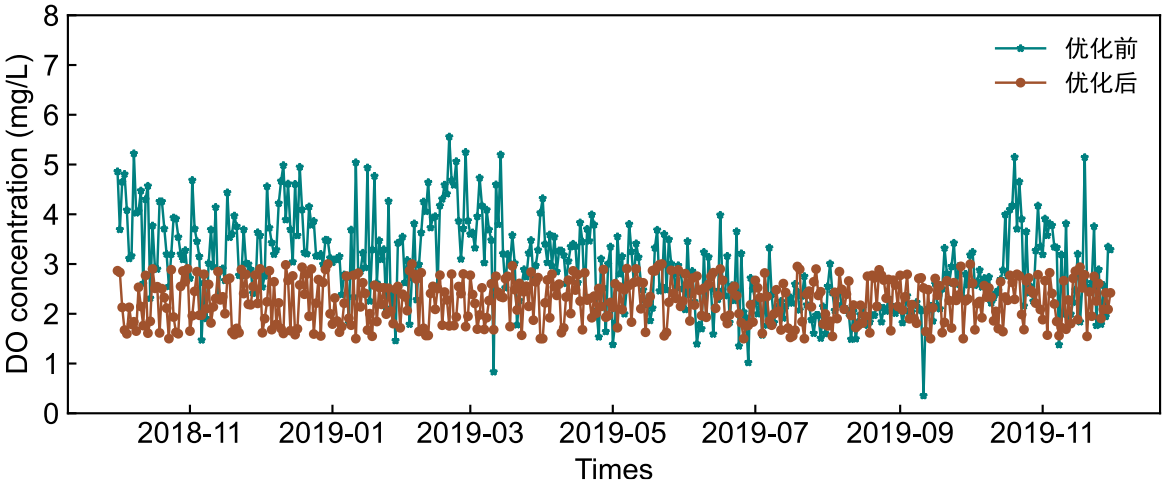


图 5-4 模拟调控前后溶解氧浓度对比

Figure5-4 Comparision of dissolved oxygen concentration before and after simulated regulation

该污水处理厂 2018 年 10 月份至 2019 年 12 月份的模拟调控前后溶解氧浓度变化趋势如图 5-4 所示。如图 5-4 所示，采用最优控制策略模拟调控后，溶解氧浓度大多低于原有工艺溶解氧浓度，调控后该污水处理厂溶解氧浓度平均为 2.26 mg/L，与模拟调控前的平均溶解氧为 2.96 mg/L 相比下降了 23.65 %，表明该方法在降低出水 TN 浓度的同时能够减少曝气量，可有效避免过量曝气导致的曝气能耗过大的问题。

中国知网 https://www.cnki.net

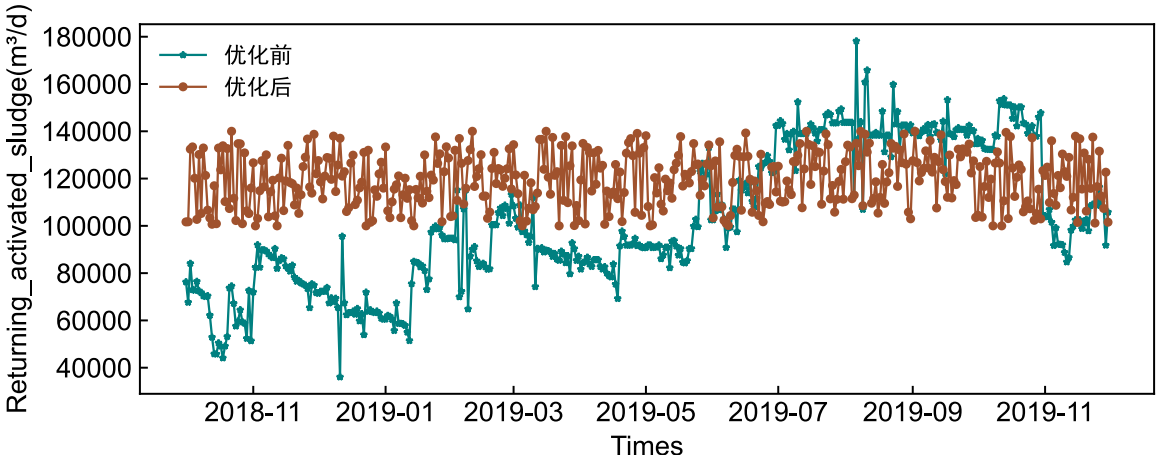


图 5-5 模拟调控前后回流污泥量对比

Figure5-5 Comparison of returning activated sludge volume before and after simulated regulation

该污水处理厂 2018 年 10 月份至 2019 年 12 月份的模拟调控前后回流污泥量变化趋势如图 5-5 所示。采用最优控制策略模拟调控后，污泥回流量稳定在 100000m³/d~140000m³/d 之间。结合图 5-3 模拟调控前后出水 TN 的变化情况可知，2018 年 11 月至 2019 年 5 月污水处理厂出水 TN 浓度相对较高，而这期间污泥回流量较低，推断由于污泥回流量较低、污泥停留时间缩短，导致好氧区的活性污泥浓度下降，硝化菌的数量减少，影响硝化反应进程，从而影响出水 TN 的去除。采用多目标优化模拟调控后，2018 年 11 月至 2019 年 5 月期间的污泥回流量较原有工艺有所增加，表明系统为降低出水 TN 浓度趋向于将污泥回流量调高。多目标优化调控后出水 TN 浓度的降低也验证了系统采取控制策略的有效性。

中国知网 https://www.cnki.net

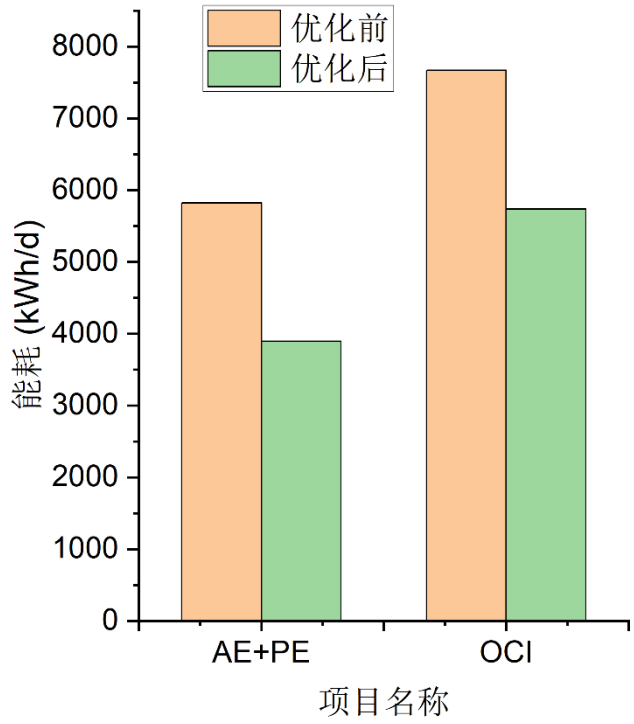


图 5-6 模拟调控前后能耗对比

Figure5-6 Comparision of energy consumption before and after simulated regulation

图 5-6 对比了该污水处理厂 2018 年 10 月份至 2019 年 12 月份期间模拟调控前后曝气能耗、泵送能耗及运行成本指数的变化，模拟调控前平均曝气、泵送能耗为 5822.81kwh/d，模拟调控后曝气、泵送能耗为 3894.56 kwh/d，采用多目标优化模拟调控后同比降低了 33.12%。多目标优化模拟调控前总的运行成本指数为 7664.81 kwh/d、模拟调控后运行成本指数为 5736.56 kwh/d，同比降低了 25.16%。

综上所述，基于出水 TN 及能耗的多目标优化控制架构在进行模拟调控后可使该污水处理厂出水 TN 浓度明显下降、波动幅度明显减小；同时，在保证出水 TN 浓度下降的同时，优化污泥回流量和溶解氧浓度，达到污水处理节能降耗的目的。

5.4 本章小结

本章选取好氧区溶解氧、内回流比、污泥回流量这三个对污水处理厂出水 TN 影响较大的工艺参数，在 5.2 节中设计并建立三因素三水平的二次多项式响应面模型，并进行了显著性检验，在 5.3 节中采用强化学习算法耦合随机森林模型构建了以降低出水 TN 浓度和降低能耗为目标的多目标优化系统架构，进行多目标问题的权衡求解，

中国知网 https://www.cnki.net

主要得出以下结论：

（1）二次多项式响应面模型的 R^2 为 0.9445，模型 F 值为 223.59，且 P 值 <0.0001，表明该模型极显著且具有回归性，较为可靠地描述了污水处理厂的出水 TN 浓度。

（2）通过 ASM 模型耦合响应面分析对污水处理厂出水 TN 浓度进行优化。结果表明在当前进水水质条件下降低出水 TN 浓度的最佳运行参数为：溶解氧为 1.125 mg/L，内回流比为 255%，外回流比为 65%。在该运行参数下出水 TN 去处理率可达到 89.14%，此时，通过模拟可得出最佳出水 TN 浓度为 3.533 mg/L，同比降低约 10.49%。

（3）以出水 TN 及能耗为目标，基于 TD3 强化学习算法与随机森林模型构建了多目标优化控制架构，研究在保证出水 TN 浓度达标的前提下，最大限度降低出水 TN 浓度、降低能耗的最优控制策略。结果表明，经最优控制策略模拟调控后，出水 TN 浓度波动幅度明显减小，平均出水 TN 浓度为 6.48mg/L，同比降低 4.46%，平均曝气、泵送能耗同比降低 33.12%，运行成本指数同比降低 25.16%。

中国知网 https://www.cnki.net

第六章 结论与展望

6.1 结论

本论文围绕城市污水处理厂出水 TN 浓度的预测及优化控制，对比分析了机理模型和机器学习模型的预测性能，运用 SHAP 算法耦合机器学习进一步分析机器学习的预测过程。在此基础上，采用响应面法耦合机理模型对降低出水 TN 浓度的最优控制参数进行了探究。除此之外，为进一步达到污水处理厂出水 TN 稳定达标与节能降耗的目标，基于 TD3 强化学习算法构建了多目标优化架构，得到的主要研究结论如下：

（1）通过对构建的 Sumo2 模型进行敏感性分析，得出 OHOs 缺氧生长的还原因子（ηOHO,anox）、缺氧条件下易生物降解基质上的 OHOs 产率（YOHO,SB,anox）、水解的阿伦尼乌斯系数（θq,HYD）、NOB 生长的阿伦尼乌斯系数（θμ,NOB）、AOBs 衰变率（bAOB）以及 AOBs 最大特定生长速率（μAOB）这六个与硝化和反硝化过程密切相关的动力学和化学计量学参数对出水 TN 浓度具有显著影响。模型动态模拟出水 TN 的结果表明，Sumo2 模型能够有效反应出水 TN 的变化趋势，但模型预测精度不高，仍需进一步提升。

（2）随机森林、XGBoost、LightGBM 等六种经典机器学习模型在预测污水处理厂出水 TN 时表现出强大的预测能力。其中，随机森林模型表现最佳（R^2=0.7924，MSE=0.3770，MRE=7.50%），预测精度明显优于机理模型，可谓污水处理厂优化运行策略提供有力支持。此外，采用 SHAP 算法解释分析随机森林模型的预测过程，结果表明，回流污泥量、进水 NO_3^--N、进水 NH_4^+-N、进水流量和 MLSS 是影响出水 TN 浓度的关键因素，这与机理模型敏感性分析的结果一致，表明机器学习模型耦合 SHAP 可解释性分析能够进一步增强机器学习的可靠性和适用性。

（3）通过响应面分析（RSM）和强化学习（RL）方法优化污水处理厂的运行策略。二次多项式响应面模型的 R^2为 0.9445，F 值为 223.59，P 值<0.0001，表明模型拟合效果良好。基于 ASM 模型与响应面分析优化得出的最佳运行参数为：溶解氧 1.125 mg/L，内回流比 255%，外回流比 65%，此时出水 TN 去除率达 89.14%，优化后出水 TN 浓度为 3.533 mg/L，同比降低 10.49%。

中国知网 https://www.cnki.net

（4）为进一步达到污水处理厂出水 TN 稳定达标与节能降耗的目标，基于 TD3 强化学习算法耦合随机森林模型构建了多目标优化控制架构，研究结果表明，该优化策略可使出水 TN 浓度平均降低 4.46%，曝气与泵送能耗同比降低 33.12%，运行成本指数同比降低 25.16%，为污水处理厂的精细化运行管理提供了理论支持和实践指导。

6.2 展望

（1）本研究中机理模型的敏感性分析及动态参数校准方法是根据相关文献及经验手动进行参数校准，后续可探究更高效的自动化调参工具及算法。

（2）本文所建立的模型只采用了一个污水处理厂的运行数据，污水处理工艺单一，数据类型不够全面，后续可扩展污水处理工艺类型，探究模型在不同类型的污水处理场景中的应用潜力。

中国知网 https://www.cnki.net

参考文献

[1] 生态环境部发布《2023 中国生态环境状况公报》[EB/OL].

[2] Kesari K K, Soni R, Jamal Q M S, et al. Wastewater Treatment and Reuse: a Review of its Applications and Health Implications[J]. Water, Air, & Soil Pollution, 2021, 232(5): 208.

[3] Corominas Ll, Rieger L, Takács I, et al. New framework for standardized notation in wastewater treatment modelling[J]. Water Science and Technology, 2010, 61(4): 841-857.

[4] 央初卓玛, 蔡露, 唐宇, 等. 活性污泥法处理城市污水研究进展[J]. 辽宁化工, 2024, 53(2): 269-271.

[5] Judd S. The MBR Book: Principles and Applications of Membrane Bioreactors for Water and Wastewater Treatment[M]. 2006.

[6] Tiar S M, Bessedik M, Abdelbaki C, et al. Steady-State and Dynamic Simulation for Wastewater Treatment Plant Management: Case Study of Maghnia City, North-West Algeria[J]. Water, 2024, 16(2): 269.

[7] 芮栋妮, 马燕燕, 叶林. 机器学习方法在污水处理系统中的应用[J]. 环境工程, 2022, 40(6): 145-153.

[8] Zhao Z, Wang Z, Yuan J, et al. Development of a Novel Feedforward Neural Network Model Based on Controllable Parameters for Predicting Effluent Total Nitrogen[J]. Engineering, 2021, 7(2): 195-202.

[9] Yang Y, Kim K R, Kou R, et al. Prediction of effluent quality in a wastewater treatment plant by dynamic neural network modeling[J]. Process Safety and Environmental Protection, 2022, 158: 515-524.

[10] Zaghloul M S, Achari G. Application of machine learning techniques to model a full-scale wastewater treatment plant with biological nutrient removal[J]. Journal of Environmental Chemical Engineering, 2022, 10(3): 107430.

[11] Rout P R, Zhang T C, Bhunia P, et al. Treatment technologies for emerging contaminants in wastewater treatment plants: A review[J]. Science of The Total

中国知网 https://www.cnki.net

Environment, 2021, 753: 141990.

[12] Vučić V, Süring C, Harms H, et al. A framework for P-cycle assessment in wastewater treatment plants[J]. Science of The Total Environment, 2021, 760: 143392.

[13] Zhao G yao, Suzuki S, Deng J hao, et al. Machine learning estimation of biodegradable organic matter concentrations in municipal wastewater[J]. Journal of Environmental Management, 2022, 323: 116191.

[14] Jeppsson U. Modelling Aspects of Wastewater Treatment Processes[M]. 2016.

[15] Henze M, Grady Jr L, Gujer W, et al. Activated Sludge Model No 1[J]. Wat Sci Technol, 1987, 29.

[16] W. Gujer, M. Henze, T. Mino, et al. The activated sludge model no. 2: Biological phosphorus removal[J]. Water Science and Technology, 1995, 31(2): 1-11.

[17] Henze M, Gujer W, Mino T, et al. Activated Sludge Model No.2d, ASM2D[J]. Water Science and Technology, 1999, 39(1): 165-182.

[18] Gujer W, Henze M, Mino T, et al. Activated Sludge Model No. 3[J]. Water Science and Technology, 1999, 39(1): 183-193.

[19] Wu X, Yang Y, Wu G, et al. Simulation and optimization of a coking wastewater biological treatment process by activated sludge models (ASM)[J]. Journal of Environmental Management, 2016, 165: 235-242.

[20] Nopens I, Batstone D J, Copp J B, et al. An ASM/ADM model interface for dynamic plant-wide simulation[J]. Water Research, 2009, 43(7): 1913-1923.

[21] Buaisha M, Balku S, Yaman Ş Ö. Heavy Metal Removal Investigation in Conventional Activated Sludge Systems[J]. Civil Engineering Journal, 2020, 6(3): 470-477.

[22] Fenu A, Guglielmi G, Jimenez J, et al. Activated sludge model (ASM) based modelling of membrane bioreactor (MBR) processes: A critical review with special regard to MBR specificities[J]. Water Research, 2010, 44(15): 4272-4294.

[23] Insel G, Ozyildiz G, Okutman-Tas D, et al. A comprehensive evaluation of process kinetics: A plant-wide approach for nutrient removal and biogas production[J]. Water Research, 2022, 217: 118410.

中国知网 https://www.cnki.net

[24] Abulimiti A, Wang X, Kang J, et al. The trade-off between N2O emission and energy saving through aeration control based on dynamic simulation of full-scale WWTP[J]. Water Research, 2022, 223: 118961.

[25] Layer M, Villodres M G, Hernandez A, et al. Limited simultaneous nitrification-denitrification (SND) in aerobic granular sludge systems treating municipal wastewater: Mechanisms and practical implications[J]. Water Research X, 2020, 7: 100048.

[26] Wang Z, Ji T, Zhu Z, et al. Optimization of the Anaerobic-Anoxic-Oxic Process by Integrating ASM2d with Pareto Analysis of Variance and Response Surface Methodology[J]. Water, 2022, 14(6): 940.

[27] Duarte M S, Martins G, Oliveira P, et al. A Review of Computational Modeling in Wastewater Treatment Processes[J]. ACS ES&T Water, 2024, 4(3): 784-804.

[28] Wang D, Thunéll S, Lindberg U, et al. A machine learning framework to improve effluent quality control in wastewater treatment plants[J]. Science of The Total Environment, 2021, 784: 147138.

[29] Xie S, Hai F I, Zhan X, et al. Anaerobic co-digestion: A critical review of mathematical modelling for performance optimization[J]. Bioresource Technology, 2016, 222: 498-512.

[30] Liwarska-Bizukojc E, Olejnik D, Biernacki R, et al. Calibration of a complex activated sludge model for the full-scale wastewater treatment plant[J]. Bioprocess and Biosystems Engineering, 2011, 34(6): 659-670.

[31] Eddy I M &, Tchobanoglous G, Stensel H D, et al. Wastewater Engineering: Treatment and Resource Recovery[M]. 5th edition. New York: McGraw Hill, 2013.

[32] Alvi M, Batstone D, Mbamba C K, et al. Deep learning in wastewater treatment: a critical review[J]. Water Research, 2023, 245: 120518.

[33] Vamathevan J, Clark D, Czodrowski P, et al. Applications of machine learning in drug discovery and development[J]. Nature Reviews Drug Discovery, 2019, 18(6): 463-477.

[34] Jordan M I, Mitchell T M. Machine learning: Trends, perspectives, and prospects[J]. Science (New York, N.Y.), 2015, 349(6245): 255-260.

中国知网 https://www.cnki.net

[35] Zhong S, Zhang K, Bagheri M, et al. Machine Learning: New Ideas and Tools in Environmental Science and Engineering[J]. Environmental Science & Technology, 2021, 55(19): 12741-12754.

[36] Kovacs D J, Li Z, Baetz B W, et al. Membrane fouling prediction and uncertainty analysis using machine learning: A wastewater treatment plant case study[J]. Journal of Membrane Science, 2022, 660: 120817.

[37] Qambar A S, Khalidy M M A. Prediction of municipal wastewater biochemical oxygen demand using machine learning techniques: A sustainable approach[J]. Process Safety and Environmental Protection, 2022, 168: 833-845.

[38] Xu Y, Wang Z, Nairat S, et al. Artificial Intelligence-Assisted Prediction of Effluent Phosphorus in a Full-Scale Wastewater Treatment Plant with Missing Phosphorus Input and Removal Data[J]. ACS ES&T Water, 2024, 4(3): 880-889.

[39] Huang R, Ma C, Ma J, et al. Machine learning in natural and engineered water systems[J]. Water Research, 2021, 205: 117666.

[40] Introducing Data Science: Big data, machine learning, and more, using Python tools. [EB/OL]. 2016.

[41] 皇甫小留, 王晶瑞, 龙鑫隆, 等. 机器学习在水处理系统中的应用[J]. 给水排水, 2022, 58(11): 153-165.

[42] Wei X, Yu J, Tian Y, et al. Comparative Performance of Three Machine Learning Models in Predicting Influent Flow Rates and Nutrient Loads at Wastewater Treatment Plants[J]. ACS ES&T Water, 2024, 4(3), 1024-1035.

[43] Liu H, Xin C, Zhang H, et al. Effluent Quality Prediction of Papermaking Wastewater Treatment Processes Using Stacking Ensemble Learning[J]. IEEE Access, 2020, 8: 180844-180854.

[44] Jiawei Han, Micheline Kamber, Jian Pei. Data Mining: Concepts and Techniques[M]. 2012.

[45] Pang G, Shen C, Cao L, et al. Deep Learning for Anomaly Detection: A Review[J]. ACM Computing Surveys, 2022, 54(2): 1-38.

中国知网 https://www.cnki.net

[46] Jain A K. Data clustering: 50 years beyond K-means[J]. Pattern Recognition Letters, 2010, 31(8): 651-666.

[47] Jolliffe I T, Cadima J. Principal component analysis: a review and recent developments[J]. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 2016, 374(2065): 20150202.

[48] Niu G, Yi X, Chen C, et al. A novel effluent quality predicting model based on genetic-deep belief network algorithm for cleaner production in a full-scale paper-making wastewater treatment[J]. Journal of Cleaner Production, 2020, 265: 121787.

[49] Han H G, Zhang S. An early warning system for MBR based on multi-step prediction and deep belief network classifier[A]//2017 Chinese Automation Congress (CAC)[C]. 2017: 7442-7447.

[50] G J P. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow SECOND EDITION Concepts, Tools, and Techniques to Build Intelligent Systems[M]. 2019.

[51] Li D, Yang C, Li Y, et al. A deep semi-supervised learning framework towards multi-output soft sensors development and applications in wastewater treatment processes[J]. Journal of Water Process Engineering, 2024, 57: 104654.

[52] Cheng X, Xu R, Wu Y, et al. Predicting and Evaluating Different Pretreatment Methods on Methane Production from Sludge Anaerobic Digestion via Automated Machine Learning with Ensembled Semisupervised Learning[J]. ACS ES&T Engineering, 2024, 4(3): 525-539.

[53] Li Y. Deep Reinforcement Learning: An Overview[A]. arXiv, 2018.

[54] Ghasemi M, Ebrahimi D. Introduction to Reinforcement Learning[A]. arXiv, 2024.

[55] Panov A I, Yakovlev K S, Suvorov R. Grid Path Planning with Deep Reinforcement Learning: Preliminary Results[J]. Procedia Computer Science, 2018, 123: 347-353.

[56] Bhopale P, Kazi F, Singh N. Reinforcement Learning Based Obstacle Avoidance for Autonomous Underwater Vehicle[J]. Journal of Marine Science and Application, 2019, 18(2): 228-238.

中国知网 https://www.cnki.net

[57] Zhang S, Wang H, Keller A A. Novel Machine Learning-Based Energy Consumption Model of Wastewater Treatment Plants[J]. ACS ES&T Water, 2021, 1(12): 2531-2540.

[58] McCarty P L, Bae J, Kim J. Domestic Wastewater Treatment as a Net Energy Producer–Can This be Achieved?[J]. Environmental Science & Technology, 2011, 45(17): 7100-7106.

[59] Singh P, Kansal A. Energy and GHG accounting for wastewater infrastructure[J]. Resources, Conservation and Recycling, 2018, 128: 499-507.

[60] Maktabifard M, Zaborowska E, Makinia J. Achieving energy neutrality in wastewater treatment plants through energy savings and enhancing renewable energy production[J]. Reviews in Environmental Science and Bio/Technology, 2018, 17(4): 655-689.

[61] Mao Z, Li X, Zhang X, et al. Optimization of effluent quality and energy consumption of aeration process in wastewater treatment plants using artificial intelligence[J]. Journal of Water Process Engineering, 2024, 63: 105384.

[62] Gunantara N. A review of multi-objective optimization: Methods and its applications[J]. Cogent Engineering, 2018, 5(1): 1502242.

[63] Revollar S, Vilanova R, Vega P, et al. Wastewater Treatment Plant Operation: Simple Control Schemes with a Holistic Perspective[J]. Sustainability, 2020, 12(3): 768.

[64] Holenda B, Domokos E, Rédey Á, et al. Dissolved oxygen control of the activated sludge wastewater treatment process using model predictive control[J]. Computers & Chemical Engineering, 2008, 32(6): 1270-1278.

[65] Chen K, Wang H, Valverde-Pérez B, et al. Optimal control towards sustainable wastewater treatment plants based on multi-agent reinforcement learning[J]. Chemosphere, 2021, 279: 130498.

[66] Croll H C, Ikuma K, Ong S K, et al. Systematic Performance Evaluation of Reinforcement Learning Algorithms Applied to Wastewater Treatment Control Optimization[J]. Environmental Science & Technology, 2023, 57(46): 18382-18390.

[67] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.

中国知网 https://www.cnki.net

[68] Zhu Y, Lian B, Wang Y, et al. Machine learning modelling of a membrane capacitive deionization (MCDI) system for prediction of long-term system performance and optimization of process control parameters in remote brackish water desalination[J]. Water Research, 2022, 227: 119349.

[69] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[A]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining[C]. San Francisco California USA: ACM, 2016: 785-794.

[70] Lu H, Ma X. Hybrid decision tree-based machine learning models for short-term water quality prediction[J]. Chemosphere, 2020, 249: 126169.

[71] Ke G, Meng Q, Finley T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[J]. 2017.

[72] Smola A J, Schölkopf B. A tutorial on support vector regression[J]. Statistics and Computing, 2004, 14(3): 199-222.

[73] Boser B E, Guyon I M, Vapnik V N. A training algorithm for optimal margin classifiers[A]//Proceedings of the fifth annual workshop on Computational learning theory[C]. Pittsburgh Pennsylvania USA: ACM, 1992: 144-152.

[74] Cover T, Hart P. Nearest neighbor pattern classification[J]. IEEE Transactions on Information Theory, 1967, 13(1): 21-27.

[75] Wang R, Yu Y, Chen Y, et al. Model construction and application for effluent prediction in wastewater treatment plant: Data processing method optimization and process parameters integration[J]. Journal of Environmental Management, 2022, 302: 114020.

[76] Tayebi H A. Using RBF and MLP models in predicting Reactive Red 198 removal from aqueous solution by SBA-15/CTAB composite[J]. DESALINATION AND WATER TREATMENT, 2017, 66: 263-273.

[77] Cheng H H, Huang P W, Whang L M. Optimization of biological nitrogen removal in full-scale municipal WWTPs using activated sludge model simulation[J]. Chemosphere, 2024, 362: 142939.

中国知网 https://www.cnki.net

[78] Koch G, Kühni M, Siegrist H. Calibration and validation of an ASM3-based steady-state model for activated sludge systems—part I:: prediction of nitrogen removal and sludge production[J]. Water Research, 2001, 35(9): 2235-2245.

[79] Wang J H, Zhao D J, Liao W S, et al. An online intelligent management method for wastewater treatment supported by coupling data-driven and mechanism models[J]. Journal of Water Process Engineering, 2023, 53: 103653.

[80] Kotsiantis S, Kanellopoulos D, Pintelas P. Data Preprocessing for Supervised Learning[J]. International Journal of Computer Science, 2006, 1: 111-117.

[81] Akiba T, Sano S, Yanase T, et al. Optuna: A Next-generation Hyperparameter Optimization Framework[A]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining[C]. New York, NY, USA: Association for Computing Machinery, 2019: 2623-2631.

[82] Sun Y, Clarke B, Clarke J, et al. Predicting antibiotic resistance gene abundance in activated sludge using shotgun metagenomics and machine learning[J]. Water Research, 2021, 202: 117384.

[83] Lundberg S, Lee S I. A Unified Approach to Interpreting Model Predictions[A]. arXiv, 2017.

[84] Fujimoto S, Hoof H van, Meger D. Addressing Function Approximation Error in Actor-Critic Methods[A]. arXiv, 2018.

中国知网 https://www.cnki.net